

C01 — Od rekordu do wyniku: pierwsza rozmowa z danymi

Zarządzanie informacją — ćwiczenie i zadanie Z01 — 2026/27

ID: [UZUPELNIJ_ID]

2026/27

Spis treści

Początek pracy na tych zajęciach	2
Po co otwieramy tabelę	2
Jak pracować z tym zestawem	3
Warsztat: projekt, skrypt i wynik	3
Trzy miejsca, których nie należy mylić	3
LEARN 1: co opisuje pojedynczy wiersz	4
Słownik małej tabeli	4
LEARN 2: obiekt i wartość	5
Typ w programie i skala pomiaru	6
LEARN 3: brak danych zmienia mianownik	6
Czytamy pierwszy wzór	7
LEARN 4: liczba, proporcja i procent	8
Średnia i mediana odpowiadają na różne pytania	8
LEARN 5: wykres trzeba odczytać, a nie tylko obejrzyć	9
Jak z wyniku powstaje zdanie	9
Łączymy wykres z obserwacją	10
CHALLENGE — samodzielny opis portalu	10
CHALLENGE 1: Portal studenta: opis rekordu	10
CHALLENGE 2: Skąd pochodzi wynik?	11
CHALLENGE 3: Czy brak można zastąpić zerem?	11
CHALLENGE 4: Krótka informacja dla opiekuna portalu	12
CHALLENGE 5: Deklaracja nie jest obserwacją	12
Zapis i oddanie	13
Co jest oceniane	13
Rozwinięcia do powtórki — poza rdzeniem spotkania	14
Podgląd pełnego badania S02	14
Słownik jest częścią pełnych danych	15
Trzy dodatkowe przykłady odczytu	16
Powrót po zajęciach: czytanie komunikatów bez zgadywania	16
Instalacja na własnym komputerze	17

Samokontrola przed następnym spotkaniem	18
Od liczby w raporcie do osoby w tabeli	18
Dwie tabele z takim samym procentem	18
Punkty procentowe a procentowa zmiana	18
Krótką próbą redakcyjną	19
Kontekst badawczy	19

Początek pracy na tych zajęciach

Otwórz RStudio. Pakiet kursu jest już zainstalowany w sali; nie instalujesz go ponownie. W konsoli poniżej edytora wpisz swoje ID i adres prywatnego repozytorium otrzymany w kursie, a następnie wykonaj polecenia. Ten blok jest instrukcją do konsoli, nie chunkiem uruchamianym przy tworzeniu PDF.

```
library(badaniaZI)
ID <- "TWOJE_ID"
zaloguj_github()
rozpocznij_zajecia(
  "C01", id_studenta = ID,
  repo_url = "ADRES_TWOJEGO_PRYWATNEGO_REPOZYTORIUM"
)
```

Dokończ logowanie na stronie GitHub otwartej w przeglądarce. Hasło i drugi składnik podajesz wyłącznie tam, nie w konsoli R. Sprawdź potwierdzony login i ID odtworzonej pracy. ID wpisujesz raz w tej sesji; pliki pracy mają je zachować także po zamknięciu RStudio.

Polecenie otwiera własny `zadanie.Rmd` i zapamiętuje katalog pracy. Nie przełączaj teraz projektu przez `.Rproj`, bo nowa sesja R utraci logowanie. Pracuj w otwartym Rmd, nie w źródłach pakietu. Uruchom pierwszy chunk przygotowania, potem wykonuj LEARN i CHALLENGE. Przy problemie poproś prowadzącego o pomoc; nie usuwaj pracy ani nie wpisuj cudzego ID.

Pierwszy blok ładuje gotowy skrypt `analiza.R`, który przygotowuje dane i funkcje tego zestawu. Uruchom go przed pozostałymi blokami; nie musisz zmieniać jego zawartości. Wyniki kolejnych przykładów pochodzą z tej samej zapisanej analizy.

Po co otwieramy tabelę

Biblioteka chce wiedzieć, dlaczego część osób ma trudności ze znalezieniem dokumentu w katalogu. Sam licznik wizyt nie odpowiada na to pytanie. Potrzebujemy informacji, co próbowała zrobić konkretna osoba, ile trwało zadanie i czy znalazła właściwy dokument. Chcemy też poznać jej ocenę katalogu. Te informacje mogą się uzupełniać, ale mogą też prowadzić do różnych ocen sytuacji.

Wyobraź sobie dwie osoby. Pierwsza po dwóch minutach wybiera niewłaściwy rekord i jest przekonana, że odniosła sukces. Druga potrzebuje dziewięciu minut, ale odnajduje właściwe wydanie i sprawdza lokalizację. Zdanie „pierwsza osoba lepiej wyszukuje, bo jest szybsza” pomija poprawność. Zdanie „druga lepiej ocenia swoje umiejętności, więc musi być skuteczniejsza” myli deklarację z obserwacją. Już na pierwszych zajęciach uczymy się zatrzymywać przed takim przeskokiem.

Dzisiejszym rezultatem jest krótka, własna odpowiedź oparta na odczytanym wyniku. R wykona przygotowane obliczenia. Ty rozpoznasz obserwację, zmienną, jednostkę i mianownik. Nie piszesz programu do analizy danych. Uczysz się sprawdzać, czy zdanie, które chcesz napisać, rzeczywiście wynika z tabeli.

W LEARN pracujemy na małej tabeli sześciu osób korzystających z katalogu. CHALLENGE dotyczy ośmiu innych osób szukających informacji w portalu studenckim. Oba zbiory są syntetyczne i odrębne: zachowaj sposób rozumowania, lecz nie przepisuj liczb między scenariuszami. Pełniejszy przykład S02 z pakietu znajdziesz w rozwinięciu po części obowiązkowej.

Jak pracować z tym zestawem

Przeznacz około 5 minut na odtworzenie pracy, 30 minut na pięć bloków LEARN, 50 minut na pięć CHALLENGE i 5 minut na zapis oraz oddanie. Pracujesz przez całe spotkanie w tym jednym Rmd. W LEARN uruchamiasz gotowe przykłady i porównujesz wynik z podaną interpretacją. W CHALLENGE piszesz samodzielnie pięć krótkich akapitów w oznaczonych miejscach, poza blokami kodu. Gdy nie wiesz, jak odczytać wynik, pytasz prowadzącego.

Nie ma osobnego zeszytu do przepisywania odpowiedzi. Rozwinięcia po CHALLENGE służą powtórce i nie dodają obowiązkowych zadań. PDF ma pokazywać wyniki oraz Twój tekst; powstaje z zapisanego Rmd podczas oddania.

Przy każdym bloku najpierw przeczytaj dwa zdania wyjaśnienia. Zatrzymaj się przed uruchomieniem i przewidź, jakiego rodzaju wyniku oczekujesz: jednej liczby, kolumny, tabeli czy wykresu. Po wykonaniu porównaj oczekiwanie z wynikiem. Taka kontrola jest początkiem rozumowania statystycznego, nawet kiedy działanie arytmetyczne jest proste.

Warsztat: projekt, skrypt i wynik

Trzy miejsca, których nie należy mylić

R jest programem wykonującym polecenia. RStudio jest środowiskiem, które pozwala wygodnie edytować pliki, uruchamiać kod i oglądać wyniki. Pakiet **badaniaZI** dostarcza danych, materiałów i gotowych funkcji kursowych. Można wyobrazić sobie tę relację jako pracownię, narzędzia i przygotowaną procedurę pomiaru.

Konsola wykonuje polecenie od razu. Edytor przechowuje tekst skryptu, który da się zapisać i uruchomić ponownie. Panel Environment pokazuje obiekty istniejące w bieżącej sesji. Obiekt widoczny w tym panelu nie musi być zapisany w pliku. Po zamknięciu sesji może zniknąć; dlatego analiza powinna wynikać z zapisanych plików.

Element	Co w nim widzisz?	Do czego wracasz po zajęciach?
Projekt .Rproj	Zapis ustawień przestrzeni pracy	Nie przełączasz go po zalogowaniu
Skrypt .R	Polecenia i funkcje	Uruchamiasz analizę od początku
Dokument .Rmd	Polecenia, bloki R i własny tekst	Uruchamiasz chunk i piszesz odpowiedź pod wynikiem
Plik .md	Pomocniczą dokumentację, np. instrukcję	Sprawdzasz zasady, nie przepisujesz tu odpowiedzi z Rmd
Tabela .csv	Zapisane dane lub wynik	Sprawdzasz źródło liczby
PDF/HTML	Czytelną wersję opracowania	Porównujesz tekst, tabelę i wykres

Funkcja `rozpocznij_zajecia()` otwiera roboczy `zadanie.Rmd` w bieżącej sesji i zapamiętuje jego przestrzeń. Nie otwieraj potem pliku `.Rproj`: przełączenie projektu uruchamia nową sesję R, w której trzeba ponownie się zalogować. Przestrzeń ćwiczeń nie oznacza rozpoczęcia projektu badawczego na zaliczenie; ten poznasz na C09. Ścieżki rozpoznaje pakiet, bez `setwd()` i bez wpisywania adresów z komputera prowadzącego. Sprawdź nazwę oraz ID pracy w komunikacie startowym.

Dokument PDF przedstawia stan obliczeń wykonanych podczas jego budowania. Jeśli zmienisz parametr w skrypcie, stary PDF nie zaktualizuje się sam. Z kolei plik źródłowy `.Rmd` łączy treść z analizą, a osobny `.R` przechowuje przygotowane obliczenia. Taki układ pozwala skupić się na znaczeniu wyniku i nadal zachować możliwość jego odtworzenia.

LEARN 1: co opisuje pojedynczy wiersz

Otwieramy małą tabelę, aby ustalić znaczenie kolumn przed obliczaniem jakiegokolwiek miary. Każdy wiersz przedstawia jedną osobę i jedno zadanie. Zwróć uwagę na NA: to informacja o braku pomiaru, nie o czasie równym zeru.

```
obserwacje <- pokaz_tabele(mini, "Sześć osób wykonujących zadanie")
print(obserwacje)
```

Sześć osób wykonujących zadanie

id	grupa	czas_min	powodzenie
u01	nowi	6	1
u02	nowi	8	1
u03	doświadczeni	12	0
u04	nowi	NA	NA
u05	doświadczeni	9	1
u06	nowi	5	0

Przeczytaj trzeci wiersz pełnym zdaniem: osoba u03 jest w grupie doświadczonych, zarejestrowany czas wynosi 12 minut, a zadanie nie zakończyło się powodzeniem. Kod 0 nie oznacza tutaj brakującej odpowiedzi ani zerowego czasu. Jego znaczenie wynika z definicji kolumny.

Wiersz u04 mówi mniej. Wiemy, do której grupy przypisano osobę, lecz nie znamy czasu ani wyniku zadania. Nie dopowiadamy, że osoba nie umiała wyszukiwać. Mogła wystąpić awaria rejestracji lub przerwanie pomiaru; bez dodatkowej informacji nie potrafimy wybrać wyjaśnienia.

Pomocnicza funkcja obraca wybrany rekord do postaci „pole — wartość”. Dzięki temu łatwiej oddzielić nazwę zmiennej od jej realizacji dla konkretnej osoby. Zmień wyłącznie numer z 3 na 4, jeśli chcesz porównać oba przypadki.

```
osoba <- odczyt_rekordu(mini, numer = 3)
print(osoba)
```

Odczyt jednej osoby

pole	wartosc
id	u03
grupa	doświadczeni
czas_min	12
powodzenie	0

Pytanie kontrolne: czy kilka kolumn opisujących jedną osobę oznacza kilku badanych? Nie. Kolumny są różnymi informacjami o obserwacji. Podobnie sześć kliknięć tej samej osoby nie tworzy automatycznie sześciu niezależnych respondentów.

W prawdziwym badaniu jeden wiersz może oznaczać osobę, zadanie, sesję albo zdarzenie. Dlatego zdanie „mam 150 obserwacji” nie jest kompletne, dopóki nie wiadomo, czego to obserwacje. W kursowym zbiorze po usunięciu identycznych duplikatów pracujemy na poziomie osoby.

Słownik małej tabeli

Nazwy kolumn nie zastępują definicji pomiaru. W tej tabeli czas zapisuje obserwator w minutach, a powodzenie oznacza zgodność znalezionej dokumentu z poleceniem. Ani grupa doświadczenia, ani identyfikator nie są oceną kompetencji.

```
sloownik <- slownik_obserwacji()
print(sloownik)
```

Definicje czterech kolumn

kolumna	znaczenie	skala
id	Identyfikator osoby	identyfikator
grupa	Wcześniejsze doświadczenie z katalogiem	nominalna
czas_min	Czas obserwowanego zadania [min]	ilorazowa
powodzenie	0 = niepowodzenie, 1 = powodzenie	nominalna

Przykładowy odczyt: „Wynik osoby u03 to 12 minut i niepowodzenie w jednym zadaniu. Przynależność do grupy doświadczonych nie zmienia kodu wyniku i nie pozwala wyjaśnić, dlaczego zadanie się nie udało”. Tak opisujemy obserwację, bez diagnozowania cech osoby.

LEARN 2: obiekt i wartość

Obiekt jest nazwanym wynikiem przechowywanym w sesji R. W skrypcie przygotowano obiekt `czasy`, który zawiera kolumnę czasu z małej tabeli. Wpisanie jego nazwy nie zbiera nowych danych; pokazuje wartości, które już zostały przygotowane.

Uruchom poniższy blok i odczytaj kolejność liczb. Nawias `[1]` widoczny na początku wydruku informuje o pozycji pierwszego wyświetlanego elementu. Nie jest wartością zmiennej, identyfikatorem osoby ani dodatkową obserwacją.

```
print(czasy)
```

```
## [1] 6 8 12 NA 9 5
```

Wektor przechowuje serię wartości jednego rodzaju. Tutaj ma sześć miejsc, z których jedno jest brakujące. Dlatego długość wektora i liczba zmierzonych czasów nie muszą być takie same.

Teraz wybieramy trzeci element wektora oraz odpowiadającą mu komórkę tabeli. Oba polecenia powinny zwrócić 12. Kwadratowy nawias oznacza wybór, a przecinek w nawiasie tabeli rozdziela wskazanie wiersza od wskazania kolumny.

```
czas_z_wektora <- czasy[3]
print(czas_z_wektora)
```

```
## [1] 12
```

```
czas_z_tabeli <- mini[3, "czas_min"]
print(czas_z_tabeli)
```

```
## [1] 12
```

Pierwsze polecenie mówi „trzeci czas”, drugie „czas w trzecim wierszu tabeli”. Jeśli tabela zostanie posortowana, trzeci wiersz może dotyczyć innej osoby. Identyfikator i numer wiersza pełnią więc różne role. Przy odsyłaniu do konkretnego rekordu warto użyć ID, a nie tylko aktualnej pozycji na ekranie.

Znak dolara wybiera kolumnę po nazwie. Cudzysłów służy zapisaniu tekstu, a wielkość liter w nazwie ma znaczenie. Literówka nie zmienia danych, lecz może uniemożliwić wykonanie polecenia; komunikat błędu trzeba wtedy czytać jako informację o nazwie lub strukturze.

Poniższe dwa odczyty pokazują serię czasów i serię etykiet grup. Zastanów się, dla której serii sensowne jest obliczenie średniej. Sama obecność obiektu w R nie oznacza, że każda funkcja statystyczna będzie dla niego właściwa.

```
print(mini$czas_min)
```

```
## [1] 6 8 12 NA 9 5
```

```
print(mini$grupa)
```

```
## [1] "nowi"          "nowi"          "doświadczeni" "nowi"          "doświadczeni"
## [6] "nowi"
```

Nie uczymy się tych znaków dla pamięciowego odtworzenia składni. Mają pozwolić rozpoznać, z której części tabeli pochodzi prezentowana liczba. Gotowy skrypt ukrywa szczegóły analizy, ale nie powinien ukrywać jej wejścia.

Typ w programie i skala pomiaru

W R liczby, teksty i wartości logiczne są przechowywane inaczej. Funkcja `class()` pokazuje klasę obiektu. Nie rozstrzyga jednak, czy zmienna liczbową jest czasem, numerem kategorii czy identyfikatorem.

Porównaj klasę kolumny czasu i klasy etykiet grup. Następnie sprawdź kolumnę powodzenia. Fakt, że program przechowuje 0 i 1 jako liczby, nie zmienia definicji tej zmiennej jako dwóch kategorii wyniku.

```
print(class(mini$czas_min))
```

```
## [1] "numeric"
```

```
print(class(mini$grupa))
```

```
## [1] "character"
```

```
print(class(mini$powodzenie))
```

```
## [1] "numeric"
```

Średnia kodu 0/1 ma szczególny sens: jest proporcją jedynek. Nie wynika z tego, że wolno uśredniać dowolne kody. Gdyby kategorie kanału pomocy zakodowano 1, 2, 3 i 4, średnia 2,7 nie opisywałaby „przeciętnego kanału” w użyteczny sposób.

W arkuszu kalkulacyjnym liczba zapisana jako tekst może wyglądać prawie tak samo jak liczba numeryczna. R może wtedy odmówić uśrednienia. W C02 sprawdzimy import liczb z przecinkiem dziesiętnym. Dzisiaj wystarczy zasada: zanim zinterpretujesz wynik, sprawdź, czy program odczytał kolumnę zgodnie ze słownikiem.

Widziany zapis	Możliwy sens	Czego trzeba się dowiedzieć
12	Dwanaście minut	Jednostka i sposób pomiaru czasu
„12”	Tekst zawierający cyfry	Czy import poprawnie rozpoznał liczbę
1	Powodzenie	Kodowanie 0/1 i definicja sukcesu
3	Środkowa kategoria odpowiedzi	Dokładne brzmienie skali
NA	Brak wartości	Czy pomiaru nie wykonano, czy nie zapisano
u03	Identyfikator	Jaka jednostka ma ten identyfikator

LEARN 3: brak danych zmienia mianownik

Mianownik odpowiada na pytanie „spośród ilu?”. Dla średniego czasu powinien oznaczać liczbę ważnych pomiarów czasu, a dla odsetka powodzeń liczbę znanych wyników zadania. Całkowita liczba wierszy może być przydatna do opisu pliku, lecz nie jest automatycznym mianownikiem wszystkich miar.

Funkcja pomocnicza liczy osobno rekordy, ważne wartości i braki. Zastosuj ją do czasu oraz powodzenia. W tym małym przykładzie liczebności są równe, ale w rzeczywistym zbiorze mogą się różnić.

```
liczebnosci <- mianowniki_observacji(mini)
print(liczebnosci)
```

Czas

zmienna	rekordy	wazne	braki
czas_min	6	5	1

Powodzenie

zmienna	rekordy	wazne	braki
powodzenie	6	5	1

Na sześć rekordów mamy pięć ważnych czasów. Ich suma wynosi 40 minut. Średnia wśród zmierzonych czasów to $40/5 = 8$ minut. Dzielenie przez sześć potraktowałoby brak tak, jakby wnosił zero do sumy i jedną osobę do mianownika.

Porównanie poniżej pokazuje skutek takiej decyzji. Obie wersje używają tej samej sumy, ale druga tworzy niezaobserwowany zerowy czas. Różnica między wynikami nie jest odkryciem o użytkownikach, tylko skutkiem błędnego traktowania braku.

```
porownanie <- pokaz_tabele(kontrola_braku, "Brak a wymyślony pomiar zerowy")
print(porownanie)
```

Brak a wymyślony pomiar zerowy

postepowanie	suma_min	mianownik	srednia_min
Pięć zmierzonych czasów	40	5	8.000
Brak błędnie zastąpiony zerem	40	6	6.667

Pomijanie braku w obliczeniu także nie usuwa całego problemu. Średnia 8 minut dotyczy osób z ważnym pomiarem. Jeśli brak powstał dlatego, że najtrudniejsze zadania przerywano, zmierzone osoby mogą nie reprezentować wszystkich prób. Poprawny rachunek jest konieczny, ale nadal trzeba znać proces powstawania braków.

Pytanie kontrolne: czy można napisać „średni czas sześciu osób wyniósł 8 minut”? Dokładniej: „wśród pięciu osób z zarejestrowanym czasem średnia wyniosła 8 minut; dla jednej osoby czasu brakowało”. Drugie zdanie pokazuje zarówno wynik, jak i zakres dostępnej informacji.

Czytamy pierwszy wzór

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}.$$

Czytamy: „średnia to suma ważnych wartości podzielona przez ich liczbę”. Indeks i numeruje składniki sumy. W tym zapisie n obejmuje pięć zmierzonych czasów, a nie sześć miejsc w pierwotnym wektorze. Można również zapisać sumę wyłącznie po indeksach z ważnymi wartościami; sens mianownika musi pozostać ten sam.

Symbol	Jak nazwać?	Co oznacza tutaj?	Jednostka
x_i	i-ty pomiar	Czas jednej osoby	min
$\sum x_i$	suma pomiarów	Łącznie 40 minut	min
n	liczba ważnych pomiarów	Pięć zarejestrowanych czasów	osoby
$\bar{x}$	średnia w próbie	Ośiem minut na ważny pomiar	min
N	liczebność określonego zbioru	Wymaga podania, jakiego zbioru	osoby lub rekordy

Litery N i n bywają używane w publikacjach niejednolicie. Nie rozpoznajemy mianownika wyłącznie po wielkości litery. Szukamy definicji w opisie metody lub podpisie tabeli. Na dalszych zajęciach będziemy podobnie czytać N kompletnych par i liczebności dwóch grup.

Funkcja `mean()` wykonuje rachunek średniej. Argument `na.rm = TRUE` oznacza pominięcie brakujących wartości w tym konkretnym obliczeniu. Nie wpisuje nowych danych do tabeli i nie usuwa całego rekordu z projektu.

```
suma_minut <- sum(czasy, na.rm = TRUE)
print(suma_minut)

## [1] 40

srednia_minut <- mean(czasy, na.rm = TRUE)
print(srednia_minut)

## [1] 8
```

Jeśli zmienimy jednostkę z minut na sekundy, suma i średnia wzrosną sześćdziesięciokrotnie. Wzór nadal opisuje tę samą cechę osób. Kontrola jednostek pozwala wykryć pozornie zaskakujące wyniki, np. średnią 480 błędnie podpisaną jako minuty.

LEARN 4: liczba, proporcja i procent

W małej tabeli trzy z pięciu znanych wyników oznaczają powodzenie. Liczba powodzeń wynosi 3, proporcja $3/5 = 0,6$, a odsetek 60%. Każdy zapis jest poprawny, lecz odpowiada innemu sposobowi prezentacji tej samej informacji.

$$\hat{\pi} = \frac{k}{n}, \quad \text{odsetek} = 100\% \cdot \frac{k}{n}.$$

Daszek nad π oznacza oszacowanie proporcji na podstawie próby. Litera k jest tutaj liczbą powodzeń, a n liczbą ważnych wyników zadania. Symbol π w statystyce nie zawsze oznacza stałą geometryczną: znaczenie odczytujemy z definicji.

Poniższa tabela pokazuje kilka miar obok siebie. Dla każdej podaj jednostkę i mianownik, zanim ułożysz zdanie. Wynik 0,6 nie oznacza 0,6 osoby, a wynik 60 nie oznacza sześćdziesięciu powodzeń.

```
podsumowanie <- pokaz_tabele(opis_mini, "Czas i powodzenie zadania")
print(podsumowanie)
```

Czas i powodzenie zadania

miara	wartosc
Średni czas [min]	8.0
Mediana czasu [min]	8.0
Znane wyniki zadania	5.0
Liczba powodzeń	3.0
Proporcja powodzeń	0.6
Odsetek powodzeń [%]	60.0

Gdyby nieznaną szóstą wynik okazał się niepowodzeniem, odsetek wszystkich sześciu wyniósłby 50%. Gdyby był powodzeniem, wyniósłby około 66,7%. Dane nie pozwalają wybrać jednej z tych wersji. Ten prosty zakres pokazuje, jak brak informacji może zmieniać odpowiedź nawet bez zaawansowanego testu.

Wynik 60% na podstawie pięciu pomiarów nie oznacza, że dokładnie 60% wszystkich użytkowników biblioteki zawsze wykona zadanie poprawnie. Na razie opisujemy małą próbę dydaktyczną. Uogólnienie wymaga projektu badania i analizy niepewności, które pojawiają się w dalszej części kursu.

Średnia i mediana odpowiadają na różne pytania

W tabeli widzisz także medianę. Uporządkowane ważne czasy wynoszą 5, 6, 8, 9 i 12 minut. Mediana jest środkową wartością: 8 minut. Średnia również wynosi tu 8 minut, ale jest wynikiem dzielenia sumy przez pięć, nie wyboru środkowego pomiaru.

Gdyby najdłuższy czas zmienił się z 12 na 22 minuty, średnia wzrosłaby do 10 minut, a mediana pozostałaby równa 8. Dlatego w krótkim opisie zawsze nazywamy miarę. „Przeciętny czas” bez doprecyzowania może oznaczać dwa różne podsumowania.


Przykładowa interpretacja tabeli: „W sześciu rekordach odnotowano pięć czasów; ich średnia i mediana wyniosły po 8 minut. Sukces wystąpił w trzech spośród pięciu znanych wyników, czyli w 60%. Dla jednej osoby nie znamy ani czasu, ani poprawności. Jest to opis tej małej próby syntetycznej, nie wszystkich użytkowników biblioteki”.

LEARN 5: wykres trzeba odczytać, a nie tylko obejrzeć

Wykres punktowy pokazuje pięć zmierzonych czasów. Oś pozioma zawiera identyfikatory, więc nie jest osią czasu ani skalą rosnącej kompetencji. Przerywana linia przedstawia średnią; nie jest wynikiem każdej osoby.

Odczytaj najkrótszy i najdłuższy zarejestrowany czas. Następnie wskaż, której osoby brakuje na wykresie i dlaczego. Brak punktu u04 nie oznacza punktu leżącego na wysokości zero.

```
czasy_osob <- pokaz_wykres(wykres_mini)
print(czasy_osob)
```



Odrębny przykład syntetyczny; linia: średnia. Brak u04 nie jest zerem.

W opisie możesz napisać: „Pięć zarejestrowanych czasów mieściło się między 5 a 12 minutami, a średnia wyniosła 8 minut”. Nie dopisuj, że u03 miała najniższą kompetencję, bo położenie punktu samo nie uzasadnia takiej diagnozy. Potrzebne byłyby inne zadania, kryteria poprawności i szerszy pomiar.

Średnia może nie być wartością żadnej konkretnej osoby. W tym przykładzie jest nią przypadkowo 8 minut, ale przy czasach 5 i 6 minut średnia wyniosłaby 5,5 minuty. Statystyka opisuje zbiór; nie tworzy „przeciętnego respondenta” ze wszystkimi przeciętnymi cechami.

Na wykresie nie widzimy przyczyn długiego czasu. Być może osoba sprawdzała kilka wydań, korzystała z wolnego łącza albo inaczej zrozumiiała polecenie. Dobre zdanie opisowe nazywa widoczny wzorec. Wyjaśnienie mechanizmu wymaga kolejnych danych.

Jak z wyniku powstaje zdanie

Dobre zdanie powinno pozwalać drugiej osobie odnaleźć liczbę i sprawdzić jej znaczenie. Zapis „wyszło 8” tego nie umożliwia. Zapis „średnia czasu w pięciu ważnych pomiarach małej tabeli wyniosła 8 minut” podaje miarę, dane, liczebność i jednostkę.

Wersja robocza	Co jest niejasne?	Wersja z uzasadnieniem
„Badani mieli wynik 60”	Liczba osób czy procent?	„Trzy z pięciu znanych wyników były powodzeniami: 60%”
„u04 wyszukiwała 0 minut”	Brak zamieniono w pomiar	„Dla u04 nie zarejestrowano czasu”
„Doświadczeni są wolniejsi”	Uogólnienie z małej demonstracji	„W tej tabeli trzeba osobno porównać grupy i ich liczebności”
„W tabeli jest sześć osób, więc N=6”	Mianownik zależy od zmiennej	„Sześć rekordów, pięć ważnych czasów”
„Wykres udowadnia brak kompetencji”	Zmieniono konstrukt	„Wykres pokazuje zróżnicowanie czasu konkretnego zadania”

Poprawa interpretacji często wymaga zwężenia zdania, a nie dodawania kolejnych liczb. Jeżeli badaliśmy czas jednego zadania, piszemy o czasie tego zadania. Jeżeli mierzyliśmy ocenę użyteczności, nie zastępujemy jej kompetencją tylko dlatego, że ta nazwa brzmi szerzej.

W tym ćwiczeniu nie wyznaczamy wartości p ani przedziału ufności. Nie są potrzebne do rozpoznania wiersza i poprawnego opisanie małej tabeli. Przygotowujemy język, który później pozwoli odróżnić estymatę, statystykę testową i niepewność.

Łączymy wykres z obserwacją

Najkrótszy czas ma osoba u06: 5 minut, lecz niepowodzenie. Osoba u01 pracowała 6 minut i odniosła sukces. Poprawny opis brzmi: „Krótszy czas nie oznaczał tu automatycznie poprawnego wykonania: u06 zakończyła próbę szybciej od u01, ale tylko u01 znalazła właściwy dokument”. Nie piszemy, że krótszy czas spowodował błąd.

Analogicznie odczytujemy deklarację. Gdy ktoś wybiera 5 na skali pewności, a obserwowane zadanie kończy się niepowodzeniem, obie wartości mogą być poprawnie zapisane. Deklaracja dotyczy oceny własnej, obserwacja — wyniku konkretnej próby. Takiego rekordu nie usuwamy jako „sprzecznego”. W CHALLENGE zastosujesz to rozróżnienie do portalu studenckiego.

CHALLENGE — samodzielny opis portalu

Zastąp znaczniki odpowiedzi w pięciu zadaniach własnym tekstem. Pisz pod wynikiem, poza blokiem R; nie wpisuj interpretacji jako komentarza w kodzie. Nie musisz odtwarzać dodatkowego dziennika ani projektu badawczego.

CHALLENGE 1: Portal studenta: opis rekordu

W nowym scenariuszu osiem hipotetycznych osób szuka terminu składania wniosku w portalu studenckim. Po zadaniu deklarują pewność, że potrafią korzystać z portalu, na skali 1–5. Obserwator osobno zapisuje czas i to, czy odnaleziono poprawny termin.

Blok pokazuje cały mały zbiór oraz rekord p06. To nowe dane: nie przepisuj liczb z części LEARN. Rozróżnij rok studiów, deklarację i obserwację.

```
obserwacje_portalu <- odczyt_portalu(numer = 6)
print(obserwacje_portalu)
```

Portal studencki — osiem osób

id	rok	czas_min	sukces	pewnosc
p01	pierwszy	4	1	4
p02	pierwszy	7	1	5
p03	kolejny	11	0	4
p04	pierwszy	NA	NA	3
p05	kolejny	6	1	2
p06	kolejny	14	0	5
p07	pierwszy	9	1	4
p08	kolejny	5	1	3

Rekord wybranej osoby

pole	wartosc
id	p06
rok	kolejny
czas_min	14
sukces	0
pewnosc	5

Napisz krótki akapit: opisz p06 z podaniem wszystkich trzech wyników: czasu, sukcesu i pewności. Wyjaśnij, czego ich zestawienie nie pozwala stwierdzić o ogólnych kompetencjach tej osoby.

[UZUPELNIJ_S01]

CHALLENGE 2: Skąd pochodzi wynik?

Przygotowany kod wybiera czas osoby z trzeciego wiersza na dwa sposoby. Następnie liczy rekordy i ważne czasy. W raporcie każda liczba powinna mieć jednoznaczny przedmiot.

Tabela pokazuje polecenie i jego rezultat. Odczytaj nazwę obiektu, kolumnę oraz wiersz. Nie trzeba pisać nowej funkcji ani kopiować kodu do odpowiedzi.

```
adresy <- tabela_adresow()
print(adresy)
```

Polecenia wskazujące źródło wyniku

wyrażenie	wynik
portal\$czas_min[3]	11
portal[3, "czas_min"]	11
nrow(portal)	8
sum(!is.na(portal\$czas_min))	7

Napisz krótki akapit: wyjaśnij dwa adresy czasu tej samej osoby i rozbieżność dwóch liczebności. Dodaj, gdzie zapisujesz trwały kod, gdzie pojawia się jego wynik, a gdzie wpisujesz interpretację.

[UZUPELNIJ_S02]

CHALLENGE 3: Czy brak można zastąpić zerem?

Osoba przygotowująca raport proponuje wpisać zero tam, gdzie nie ma czasu. Twierdzi, że dzięki temu „nie stracimy żadnego uczestnika”. Twoim zadaniem jest ocena tej decyzji na podstawie jej skutku i znaczenia pomiaru.

Gotowa tabela pokazuje obie wersje średniej. Odczytaj sumę czasów i mianowniki. Sprawdź, czy powiększenie mianownika dostarczyło nowego pomiaru.

```
warianty <- pokaz_tabele(blad_portalu, "Dwie reguły potraktowania braku")
print(warianty)
```

Dwie reguły potraktowania braku

wariant	N	suma_czasu	srednia
Brak pozostaje brakiem	7	56	8
Brak zastąpiony zerem	8	56	7

Napisz krótki akapit: podaj obie średnie i ich N. Wybierz właściwy opis obecnych danych, uzasadnij go oraz wskaż jedną informację, której należałoby szukać w protokole osoby p04.

[UZUPELNIJ_S03]

CHALLENGE 4: Krótka informacja dla opiekuna portalu

Opiekun potrzebuje dwóch informacji: ile trwało poszukiwanie i jak często znaleziono poprawny termin. Nie potrzebuje listy poleceń R. Oczekuje opisu próby, w którym braki nie znikają z narracji.

Tabela zawiera gotowe podsumowanie. Wybierz liczby odnoszące się do pytania i sprawdź ich jednostki. To opis obserwacji, bez testu i bez uogólnienia na wszystkich studentów.

```
podsumowanie <- pokaz_tabele(opis_portalu, "Opis portalu studenckiego")
print(podsumowanie)
```

Opis portalu studenckiego

wskaznik	wartosc
Wiersze	8.000
Ważny czas	7.000
Brak czasu	1.000
Średnia czasu [min]	8.000
Mediana czasu [min]	7.000
Ważny sukces	7.000
Sukcesy	5.000
Sukces [% ważnych]	71.429

Napisz krótki akapit: podaj N, średnią i medianę czasu, liczbę sukcesów oraz odsetek ze wskazanym mianownikiem. Zakończ jednym ograniczeniem wynikającym z małej syntetycznej próby.


[UZUPELNIJ_S04]

CHALLENGE 5: Deklaracja nie jest obserwacją

Na wykresie pewność zestawiono z czasem, a kształt punktu oznacza sukces. Wysoka pewność nie musi oznaczać poprawnego wyniku. Długi czas nie wskazuje jednoznacznie przyczyny trudności.

Uruchom blok i porównaj co najmniej dwie osoby w tabeli z CHALLENGE 1. Wykres pomaga zobaczyć wzorzec, ale nie mierzy całej kompetencji. Nie obliczamy na C01 korelacji ani jej istotności.

```
deklaracja_i_czas <- pokaz_wykres(wykres_portalu)
print(deklaracja_i_czas)
```



Napisz krótki akapit: wykorzystaj dwa konkretne rekordy do porównania deklaracji i obserwacji. Popraw zdanie „osoby pewne swoich umiejętności zawsze szybciej znajdują właściwą informację” i zaproponuj jeden dodatkowy pomiar do przyszłego badania.

[UZUPELNIJ_S05]

Zapis i oddanie

Sprawdź pięć własnych akapitów w CHALLENGE: nazwę miary, liczbę, jednostkę i mianownik. Zapisz ten Rmd w edytorze. Nie przepisyjesz tekstu do drugiego pliku i nie uruchamiasz osobnego renderowania.

W konsoli wykonaj jedno polecenie. Funkcja oddania tworzy aktualny PDF, sprawdza kompletność i wysyła go razem z Rmd oraz `analiza.R` do Twojego prywatnego repozytorium z dostępem prowadzącego.

```
oddaj_zadanie("Z01")
```

Odczytaj potwierdzenie odbioru i SHA identyfikujące wysłaną wersję. Błąd nie oznacza oddania. Po poprawce zapisz plik i ponownie wywołaj tę samą funkcję; wcześniejsze potwierdzenie nie obejmuje nowych zmian. Zdalny odbiór nie jest jeszcze oceną pracy.

Po potwierdzonym oddaniu wykonaj w konsoli `wyloguj_github()`. Na komputerze współdzielonym wyloguj również przeglądarkę i zamknij RStudio bez zachowywania `.RData`. Przy braku sieci zachowaj źródła przed czyszczeniem komputera i poproś prowadzącego o ustalenie sposobu dostarczenia pracy.

Co jest oceniane

Kryterium	Dowód w Twojej pracy	Punkty
Z01.1	Gotowy skrypt wykonany od początku, wynik z właściwego projektu	3
Z01.2	Poprawnie wskazana wartość, jej miejsce, znaczenie, jednostka i N	3
Z01.3	Własne wyjaśnienie roli konsoli, skryptu i źródła wyniku	2

Kryterium	Dowód w Twojej pracy	Punkty
Z01.4	Własne repozytorium i ID oraz potwierdzony status wysyłki i SHA	2

Nie otrzymujesz dodatkowych punktów za napisanie własnej funkcji lub zastosowanie testu, którego jeszcze nie omawialiśmy. Oceniane są odczyt i wyjaśnienie. Osobna rubryka Z01 rozwija poziomy wykonania tych kryteriów.

Rozwinięcia do powtórki — poza rdzeniem spotkania

Poniższe przykłady rozwijają ten sam sposób odczytu. Nie wymagają dodatkowych odpowiedzi ani oddania kolejnego pliku. Wróć do wybranego fragmentu, jeżeli chcesz sprawdzić znaczenie podglądu danych, jednostek lub komunikatu R.

Podgląd pełnego badania S02

Wspólny zbiór S02 ma więcej rekordów i kolumn, ale obowiązują te same pytania. Najpierw sprawdzamy rozmiar danych przed przygotowaniem i po zastosowaniu reguł. Zmiana liczby wierszy nie oznacza automatycznie, że usunięto „złych respondentów”.

Poniższa tabela pochodzi z przygotowanego skryptu. Odczytaj nazwę każdego pola razem z wartością. Reguły usuwania identycznych duplikatów i oznaczania nieprawidłowych wartości omówimy dokładnie w C02.

```
rozmiar <- pokaz_tabele(wynik_glowny, "Rozmiar pełnego zbioru")
print(rozmiar)
```

Rozmiar pełnego zbioru

N_surowe	N_po	kolumny
150	148	17

Liczba kolumn może wzrosnąć po utworzeniu zmiennych pochodnych, np. indeksu albo liczby ważnych pozycji. Nie oznacza to zebrania nowych odpowiedzi. Nowa kolumna może być jedynie podsumowaniem informacji już obecnej w sześciu innych kolumnach.

Teraz oglądamy sześć pierwszych rekordów pełnego badania. Jest to podgląd struktury, a nie cała próba i nie losowa podpróba do uogólnień. Przeczytaj jeden rekord z czasem i wynikiem zadania; nie dopisuj oceny osoby, której nie ma w danych.

```
rekordy <- podglad_badiana()
print(rekordy)
```

Sześć pierwszych rekordów S02


ID	Grupa	Czas [min]	Powodzenie
o001	nowi	12.1	0
o002	nowi	10.4	1
o003	doświadczeni	5.8	1
o004	doświadczeni	16.1	1
o005	doświadczeni	28.0	1
o006	doświadczeni	6.3	0

Podgląd ma sześć wierszy, lecz pełna tabela może mieć ich znacznie więcej. Częsty błąd polega na uznaniu liczby widocznych rekordów za N analizy. Polecenie `head()` ogranicza wydruk, nie usuwa pozostałych danych z obiektu.

Kolejny wykres pokazuje pierwsze dwadzieścia rekordów. Oś pozioma oznacza pozycję w podglądzie, nie numer kolejnego dnia badania. Szukamy różnic w czasie i potencjalnych braków, ale nie interpretujemy tej kolejności jako trendu czasowego.

```
czasy_podgladu <- pokaz_wykres(wykres_glowny)
print(czasy_podgladu)
```

Pierwsze rekordy zadania



Przed zapisaniem zdania o całej próbie wróć do tabeli podsumowującej pełny zbiór. Wykres fragmentu może pomóc zrozumieć format danych, ale nie daje prawa do stwierdzenia, jaka część całej próby działała szybko. Trzeba odróżniać demonstrację sposobu odczytu od analizy pełnego pytania.

Słownik jest częścią pełnych danych

Nazwa `powodzenie` brzmi intuicyjnie, ale musimy wiedzieć, czy ocenia je obserwator, czy deklaruje uczestnik. Nazwa `czas_wyszukiwania` nie mówi sama, czy chodzi o minuty czy sekundy. Słownik nadaje tym kolumnom znaczenie potrzebne do interpretacji.

Poniższa tabela zestawia wybrane pola pełnego przykładu S02. Odczytaj osobno skalę statystyczną i opis pomiaru. W kolejnych zajęciach rozbudujemy tę kontrolę o zakresy dopuszczalne oraz kody braków.

```
sloownik <- sloownik_pelnego_badania()
print(sloownik)
```

Znaczenie zmiennych

kolumna	znaczenie
id_odpowiedzi	Identyfikator rekordu osoby
grupa	Nowi lub doświadczeni użytkownicy
czas_wyszukiwania	Obserwowany czas w minutach
powodzenie	Wynik zadania: 0 = nie, 1 = tak
pozycja_1	Deklaracja: szybko znajduję pole wyszukiwania
czestosc_korzystania	Deklarowana częstość korzystania: 1–5

Skale pomiaru

kolumna	skala
id_odpowiedzi	identyfikator
grupa	nominalna
czas_wyszukiwania	ilorazowa
powodzenie	nominalna
pozycja_1	porządkowa
czestosc_korzystania	porządkowa

Identyfikator służy odnajdywaniu i łączeniu rekordów. Grupa porównania jest kategorią. Czas ma jednostkę i naturalne zero. Pojedyncza odpowiedź 1–5 jest uporządkowana, ale równość odległości między sąsiednimi kategoriami wymagałaby dodatkowego uzasadnienia.

Pełny scenariusz S02 zawiera sześć pozycji dotyczących użyteczności katalogu i radzenia sobie z nim. Będziemy z nich tworzyć dydaktyczny indeks deklarowanej użyteczności. Nie jest to zwalidowany test całej kompetencji informacyjnej. W C04 sprawdzisz, które fragmenty pozycji dotyczą użytkownika, a które systemu.

Wartość pozycji ankiety wytwarza uczestnik wybierający odpowiedź, natomiast czas i poprawność zadania pochodzą z obserwacji wykonania. Zapis liczbowy obu informacji nie usuwa tej różnicy. Bez definicji pomiaru dwie podobne kolumny mogłyby zostać błędnie uznane za dwa testy kompetencji.

Trzy dodatkowe przykłady odczytu

Przypadek A: ten sam wynik, dwa mianowniki

W ankiecie odpowiedziało dziesięć osób. Sześć wybrało „tak”, dwie „nie”, a dwie pominęły pytanie. Jaki odsetek ważnych odpowiedzi stanowi „tak”? Zatrzymaj się przed czytaniem rozwiązania i nazwij mianownik.

Wśród ośmiu ważnych odpowiedzi jest sześć odpowiedzi „tak”, czyli 75%. Zdanie „60% wszystkich dziesięciu respondentów zaznaczyło tak” także jest rachunkowo poprawne, ale ma inny mianownik i powinno ujawnić dwa braki. Nie wolno używać tych wersji zamiennie bez zmiany opisu.

Przypadek B: jednostka przesądza o znaczeniu

Tabela zawiera wartość 120 w kolumnie czasu. Jedna osoba zapisuje „dwie minuty”, druga „dwie godziny”. Bez słownika nie umiemy rozstrzygnąć, która ma rację. Jeśli jednostką są sekundy, poprawna jest pierwsza interpretacja; jeśli minuty, druga.

Dlatego przed przeliczeniem jednostki sprawdzamy źródło, a po przeliczeniu zmieniamy podpis. Nie należy poprawiać „dziwnej” wartości przez odgadywanie, jaka liczba wyglądałaby bardziej realistycznie. To będzie jeden z tematów czyszczenia danych.

Przypadek C: deklaracja i wykonanie

Osoba wybiera odpowiedź 5 na stwierdzenie „łatwo znajduję potrzebny dokument”, a obserwowane zadanie kończy się niepowodzeniem. Czy wiersz trzeba usunąć jako sprzeczny? Nie. Deklaracja i wykonanie odnoszą się do różnych informacji i mogą się rozchodzić.

Taki rekord może być szczególnie interesujący dla pytania o samoocenę. Nie pozwala jednak sam rozstrzygnąć, czy osoba przeszacowuje umiejętności: zadanie mogło być nietypowe, polecenie niejednoznaczne, a pojedynczy wynik przypadkowy. W C08 wrócimy do związku obu rodzajów pomiaru na poziomie całej próby.

Powrót po zajęciach: czytanie komunikatów bez zgadywania

Komunikat o błędzie zwykle wskazuje, czego program nie mógł wykonać. Nie jest oceną Twojego rozumienia statystyki. Najpierw sprawdź ostatnie uruchomione polecenie, nazwę obiektu i projekt. Nie zmieniaj wielu rzeczy naraz, bo wtedy trudno stwierdzić, co pomogło.

Objaw	Co może oznaczać?	Pierwszy krok
object ... not found	Obiekt jeszcze nie powstał albo nazwa ma literówkę	Uruchom blok przygotowania i porównaj nazwę
cannot open file	Nie znaleziono pliku pod daną ścieżką	Sprawdź projekt i istnienie pliku
Średnia wynosi NA	W obliczeniu pozostał brak	Sprawdź braki i regułę ich obsługi
Wynik różni się od PDF	Inne dane, parametry lub stary dokument	Porównaj wariant i uruchom analizę od początku
W konsoli pojawia się +	Polecenie nie zostało domknięte	Przerwij Esc i sprawdź nawias/cudzysłów
Wysyłka nie ma potwierdzenia	Praca może być tylko lokalna	Sprawdź status i zachowaj pliki

Średnia NA nie oznacza, że prawdziwa średnia jest nieznana w sensie teorii estymacji. Oznacza, że konkretne polecenie nie zwróciło liczbowego wyniku przy danym sposobie traktowania braków. Z kolei liczbowy wynik nie gwarantuje poprawności interpretacji. Program może poprawnie policzyć średnią niewłaściwie zakodowanej kolumny.

Zestawienie poniżej pomaga wrócić do składni potrzebnej do odczytu. Potraktuj je jak słownik poleceń, a nie listę funkcji do wyuczenia na pamięć. Wyjaśnij słowami dwa wybrane wiersze, odwołując się do małej tabeli.

```
polecenia <- slownik_odczytu()
print(polecenia)
```

Polecenie i jego sens

polecenie	sens
czasy[3]	Trzecia wartość wektora
mini[3, "czas_min"]	Czas z trzeciego wiersza tabeli
mini\$czas_min	Cała kolumna czasu
nrow(mini)	Liczba wierszy, także z brakami
sum(is.na(czasy))	Liczba braków czasu
mean(czasy, na.rm = TRUE)	Średnia wyłącznie zmierzonych czasów

Instalacja na własnym komputerze

Na własnym komputerze instalacja jest osobnym krokiem wykonywanym przed pracą, a nie częścią analizy statystycznej. W sali nie powtarzasz jej na każdych zajęciach. Po instalacji nadal trzeba otworzyć własny projekt i używać jego danych.

Poniższe polecenia pobierają pakiet kursu z repozytorium GitHub. Wymagają połączenia z siecią, ale późniejszy odczyt lokalnych PDF i HTML nie wymaga stałego dostępu do internetu. W przypadku zalecanej wersji rocznika stosuj instrukcję instalacyjną kursu.

```
install.packages("remotes")
remotes::install_github(
  "MarekDejaUJ/projektowanie-badan-ZI",
  dependencies = NA, upgrade = "never"
)
```

PDF Twojej pracy powstaje z uzupełnionego Rmd. Środowisko sali musi zawierać przygotowane przez informatyka zależności renderowania; nie instalujesz samodzielnie LaTeX w trakcie ćwiczeń. Na własnym komputerze sprawdź render przed zajęciami według instrukcji środowiska. Brak gotowego środowiska wymaga rozwiązania technicznego, a nie zamiany pisemnego zadania w odpowiedź „w myślach”.

Samokontrola przed następnym spotkaniem

Od liczby w raporcie do osoby w tabeli

Po kilku dniach inna osoba czyta Twoją odpowiedź i pyta: „Skąd wiadomo, że te osiem minut dotyczy właśnie tego zadania?”. Nie wystarczy wskazać, że liczba pojawiła się w konsoli. Potrzebny jest łańcuch od pytania, przez kolumnę i regułę obliczenia, do zapisanej tabeli wyniku.

W małej demonstracji potrafisz przejść ten łańcuch w obie strony. Pytanie dotyczy średniego zarejestrowanego czasu. Kolumna `czas_min` zawiera sześć miejsc, w tym jeden brak. Wektor ważnych wartości obejmuje 6, 8, 12, 9 i 5 minut. Suma wynosi 40, mianownik 5, wynik 8 minut. W raporcie nazwa miary powinna wskazywać właśnie tę operację.

W większym zbiorze nie sprawdzamy ręcznie każdej sumy, ale zachowujemy tę samą strukturę dowodu. Słownik objaśnia kolumnę, skrypt zapisuje regułę, a tabela podaje wynik i liczebność. Gdy któryś element jest nieznany, zdanie może wyglądać poprawnie i nadal nie być sprawdzalne.

Element zdania	Gdzie go sprawdzisz?	Przykład pytania kontrolnego
„czas wykonania”	Słownik i protokół	Czy to czas do zakończenia, czy do ostatniego kliknięcia?
„średni”	Reguła podsumowania	Czy wynik pochodzi ze średniej, a nie mediany?
„w pięciu pomiarach”	Licznik ważnych wartości	Czy brak został pominięty wyłącznie w tej analizie?
„osiem minut”	Tabela wyniku i jednostka	Czy nie przepisano sekund pod etykietą minut?
„w tej próbie”	Definicja zbioru	Czy zdanie nie rozszerza wyniku na wszystkich użytkowników?

Każda liczba w raporcie powinna mieć wskazane źródło, jednostkę i zakres analizy. Zdanie niepoparte tabelą lub słownikiem wymaga doprecyzowania albo usunięcia. Ta zasada pozwala odróżnić odczyt danych od dopowiedzianego wyjaśnienia.

Dwie tabele z takim samym procentem

Wyobraź sobie dwa odrębne badania próbne. W pierwszym sukces odniosły cztery z pięciu osób, w drugim czterdzieści z pięćdziesięciu. W obu proporcja wynosi 0,8, czyli 80%. To ten sam odsetek, ale nie ten sam zasób informacji.

Na C01 nie obliczamy jeszcze przedziału ufności. Możemy jednak zauważyć prostą własność: zmiana wyniku jednej osoby w pierwszej próbie przesunęła odsetek o 20 punktów procentowych, a w drugiej o 2 punkty procentowe. Pokazuje to, dlaczego N jest częścią wyniku, mimo że nie zmienia definicji proporcji.

Nie należy z tego wyciągać wniosku, że większa próba zawsze opisuje właściwą populację. Pięćdziesiąt osób zrekrutowanych wyłącznie na szkoleniu bibliotecznym może różnić się od pozostałych użytkowników. Liczba osób i sposób ich doboru odpowiadają na dwa odrębne pytania. W03 połączy tę intuicję z formalnym językiem niepewności.

Punkty procentowe a procentowa zmiana

Jeżeli odsetek powodzeń wzrasta z 50% do 60%, różnica wynosi 10 punktów procentowych. Względem początkowych 50% jest to wzrost o $10/50 = 20\%$. Oba rachunki mogą opisywać to samo porównanie, ale nie są tym samym sformułowaniem.

W raporcie o usłudze zdanie „skuteczność zwiększyła się o 10%” jest bez dodatkowego określenia niejasne. Czy chodzi o dziesięć punktów procentowych, czy o zmianę względną? Przy początkowym odsetku 50% wzrost względny o 10% prowadzi do 55%, a nie do 60%.

W kursie najpierw podajemy oba odsetki i ich mianowniki, a dopiero potem wybraną miarę porównania.

Nie potrzebujesz nowego testu, aby poprawnie odczytać ten język. Potrzebujesz wiedzieć, która liczba jest podstawą dzielenia.

Krótką próba redakcyjna

Popraw zdanie: „Komputer pokazał 0,8, więc osiemdziesięciu studentów umie wyszukiwać”. Pierwszy problem to zamiana proporcji w liczbę osób. Drugi to rozszerzenie wyniku pojedynczego zadania na całą umiejętność. Trzeci to pominięcie liczebności i statusu danych.

Możliwa poprawa dla pierwszego z powyższych przykładów brzmi: „W odrębnej próbie dydaktycznej cztery z pięciu osób wykonały zadanie poprawnie, co stanowi 80% znanych wyników”. Zdanie nie rozstrzyga poziomu ich ogólnych kompetencji. Jeśli w badaniu były braki, trzeba dodatkowo wskazać ich liczbę.

Porównaj tę poprawę z własną odpowiedzią Z01. Sprawdź, czy nie ma w niej podobnego przejścia od wartości technicznej do zbyt szerokiej diagnozy. Na pierwszych zajęciach właśnie takie rozpoznanie jest ważniejsze niż uruchomienie większej liczby funkcji.

Wyjaśnij pięć zdań: „jeden wiersz to jedna osoba”, „liczba wierszy nie zawsze jest mianownikiem”, „NA nie jest zerem”, „nazwa kolumny nie jest definicją konstruktów” oraz „wynik na ekranie powinien mieć zapisane źródło”. Do każdego podaj przykład z dzisiejszego materiału.

Jeżeli rozróżniasz te sytuacje, jesteś przygotowany do C02. Tam surowy eksport będzie zawierał duplikaty, kody braków i wartości wymagające sprawdzenia. Zamiast pytać tylko „jak naprawić plik?”, będziemy pytać „jak dana decyzja zmienia informację o badanych osobach?”.

Kontekst badawczy

Łączenie ankiety z obserwacją działania nawiązuje do podejścia opisanego przez Hargittai (2002). Nasza mała tabela i S02 pozostają niezależnymi przykładami syntetycznymi. Pozytywna ocena usługi, deklarowana umiejętność i poprawne wykonanie zadania mają odrębne znaczenia; ich relacja będzie pytaniem kolejnych zajęć.