

C02 — Surowy eksport: braki, duplikaty i jawne czyszczenie

Zarządzanie informacją — ćwiczenie i zadanie Z02 — 2026/27

ID: [UZUPELNIJ_ID]

2026/27

Spis treści

Początek pracy na ćwiczeniu C02	2
Dlaczego dwie osoby otrzymały różne średnie	2
Surowy plik i dokumenty, które go objaśniają	3
LEARN 1: plik CSV jest tekstem z umową	3
Separator kolumn a znak dziesiętny	4
Klasa R i skala pomiaru	5
LEARN 2: duplikat i konflikt identyfikatora	5
LEARN 3: kod braku 99	6
Wartość niemożliwa i wartość nietypowa	7
Wykres pudełkowy i granica wąsa	8
Skutek usunięcia prawidłowego długiego czasu	9
LEARN 4: rachunek liczebności	10
Pary zmiennych mają własne N	10
LEARN 5: dziennik decyzji, który można przeczytać	11
CHALLENGE — samodzielny audyt cyfrowego archiwum	12
Scenariusz cyfrowego archiwum	12
CHALLENGE 1: Audyt importu	12
CHALLENGE 2: Powtórzenie i konflikt	13
CHALLENGE 3: Zero, 99, 121 i NA	14
CHALLENGE 4: Wynik z długą próbą i bez niej	14
CHALLENGE 5: Notatka o danych gotowych do analizy	15
Zapis i oddanie	16
Co jest oceniane	16
Rozwinięcia do powtórki — poza rdzeniem spotkania	17
Dziennik pełnego zbioru S02	17
Histogram czasu po przygotowaniu	18
CSV i arkusz przekazują tę samą informację	19
Od logu zdarzeń do wyniku osoby	20
Szeroko, długo i w innej jednostce	21
Brak danych a przebieg badania	24

Dodatkowe przykłady z rozwiązaniem	24
Braki w dwóch grupach	25
Dwa rodzaje zdania o jakości danych	26

Początek pracy na ćwiczeniu C02

Otwórz RStudio. Pakiet kursu `badaniaZI` jest zainstalowany na komputerach w sali. Cztery polecenia z następnego bloku wpisujesz w konsoli RStudio, czyli w dolnym panelu ze znakiem `>`; w miejsce `TWOJE_ID` wpisz swoje ID, a w miejsce adresu — adres prywatnego repozytorium otrzymany na początku kursu. Dokument PDF zawiera cztery polecenia jako tekst instrukcji.

```
library(badaniaZI)
ID <- "TWOJE_ID"
zaloguj_github()
rozpocznij_zajecia(
  "C02", id_studenta = ID,
  repo_url = "ADRES_TWOJEGO_PRYWATNEGO_REPOZYTORIUM"
)
```

Dokończ logowanie na stronie GitHub otwartej w przeglądarce. Hasło i drugi składnik podajesz wyłącznie na stronie GitHub. Sprawdź w komunikacie potwierdzony login i ID odtworzonej pracy. ID wpisujesz raz w sesji; pliki pracy zachowują je także po zamknięciu RStudio.

Funkcja `rozpocznij_zajecia()` otwiera własny plik `zadanie.Rmd` i zapamiętuje katalog pracy. Pracuj w otwartym pliku `zadanie.Rmd` do końca zajęć; plik `.Rproj` pozostaje zamknięty, bo jego otwarcie uruchamia nową sesję R, która wymaga ponownego logowania. Najpierw uruchom blok `przygotowanie`, a potem kolejne części `LEARN` i `CHALLENGE`. Przy problemie poproś prowadzącego o pomoc; plik pracy i własne ID pozostają bez zmian.

Plik ćwiczenia łączy tekst z blokami kodu R (chunkami), które uruchamiasz zieloną strzałką w prawym górnym rogu bloku albo skrótem `Ctrl+Shift+Enter`. Pierwszy chunk, `przygotowanie`, wczytuje gotowy skrypt `analiza.R`. Skrypt tworzy trzy zbiory: mały eksport demonstracyjny badania katalogu (nagłówek i siedem wierszy opisujących osoby `u01–u06`), eksport badania cyfrowego archiwum (nagłówek i siedem wierszy opisujących osoby `a01–a06`) oraz zbiór `S02` po przygotowaniu (148 osób). Skrypt zawiera też funkcje wyświetlające tabele i wykresy i działa bez zmian.

Zbiór `S02` przygotowuje funkcja pakietu `przygotuj_ankiete()`. Funkcja stosuje trzy reguły: usuwa identyczne duplikaty rekordów, zamienia kod 99 w pozycjach ankiety na `NA` i oznacza jako `NA` czasy spoza zakresu 0–120 minut. Plik surowy pozostaje bez zmian, a wszystkie porównania działają na kopiach w pamięci R. Każdy chunk zapisuje wynik funkcji w obiekcie, a `print()` wyświetla obiekt w dokumencie, tak jak na ćwiczeniu C01.

Dlaczego dwie osoby otrzymały różne średnie

Zespół biblioteki przekazał tę samą ankietę dwóm analitykom. Pierwsza osoba potraktowała 99 jako odpowiedź na skali oceny, druga rozpoznała w 99 kod braku. Pierwsza usunęła każdy wiersz z pustym polem, druga zachowała wiersze do analiz, w których miały potrzebne informacje. Z jednego pliku powstały różne liczebności i różne podsumowania.

Część różnic wynika z różnych pytań: analiza czasu wymaga ważnego czasu, a analiza indeksu — pięciu ważnych pozycji ankiety. Różnica staje się problemem, gdy decyzja pozostaje ukryta albo pozbawiona uzasadnienia. Ćwiczenie C02 uczy czytać czyszczenie danych jako serię decyzji o znaczeniu danych.

Ćwiczenie C01 wprowadziło rekord, zmienną, brak i mianownik. Ćwiczenie C02 stosuje te pojęcia do surowego eksportu. Reguły czyszczenia wynikają ze słownika, projektu i procesu pomiaru, a ustala się je przed obliczeniem wyników. Wynik obliczeń pozostaje poza uzasadnieniem reguły.

Przeznacz około 5 minut na odtworzenie pracy, 30 minut na pięć bloków `LEARN`, 50 minut na pięć zadań

CHALLENGE i 5 minut na zapis oraz oddanie. LEARN to część z gotowymi przykładami i wzorcową interpretacją; CHALLENGE to pięć odpowiedzi, które piszesz samodzielnie pod wynikami. Gdy odczyt wyniku sprawia trudność, pytasz prowadzącego.

Dane projektu indywidualnego poznasz na ćwiczeniu C09 (Warsztat projektu). Na C02 pracujesz na gotowym eksporcie, słowniku i procedurze przygotowania, a Twoim zadaniem jest opis skutków procedury. Rozwinięcia po CHALLENGE służą powtórce i pozostają poza oceną.

Surowy plik i dokumenty, które go objaśniają

W LEARN pracujemy na małym eksporcie badania katalogu: siedem rekordów opisuje sześć osób. CHALLENGE dotyczy odrębnego badania cyfrowego archiwum. Pełny zbiór S02 wraca w rozwinięciu po CHALLENGE. Wszystkie dane są syntetyczne i opisujemy je jako dane dydaktyczne; znaczenie przygotowanych sytuacji odczytujemy ze słownika.

Surowy plik jest punktem odniesienia. Pozostaje bez zmian, a reguły zapisuje skrypt. Zachowany plik i skrypt pozwalają odtworzyć wynik, porównać dwie uzasadnione decyzje i sprawdzić N podane w raporcie. Ręczna zmiana komórek w arkuszu bez dziennika usuwa możliwość kontroli wyniku.

Dokument lub obiekt	Co pozwala ustalić?	Co wymaga drugiego źródła?
Surowy CSV	Wartości przekazane do analizy	Przyczyny wartości: protokół obserwacji
Słownik	Jednostki, kody, zakresy i znaczenie pól	Prawdziwość wartości: kontrola zapisu
Protokół obserwacji	Początek, koniec i warunki zadania	Sposób eksportu: skrypt eksportu
Skrypt przygotowania	Zastosowane przekształcenia	Sens badawczy reguły: projekt badania
Dziennik zmian	Liczbę rekordów lub komórek objętych regułą	Mechanizm powstawania braków: projekt i protokół
Tabela analityczna	Dane, z których obliczono wynik	Stan przed przekształceniem: surowy plik

Kontrola składniowa sprawdza zapis, a kontrola merytoryczna — znaczenie. Program sprawdza, czy czas jest liczbą nieujemną. Znaczenie wartości 8 — minuty aktywnego szukania, czas całej sesji albo czas do rezygnacji — podaje projekt badania.

LEARN 1: plik CSV jest tekstem z umową

CSV przechowuje tabelę jako tekst. Umowa pliku obejmuje separator kolumn, znak dziesiętny, zapis braków i kodowanie znaków. Każdy program odczytuje plik `.csv` według własnych ustawień, więc polecenie importu podaje separator, znak dziesiętny i kodowanie jawnie.

Eksport `eksport_demo` ma nagłówek i siedem wierszy. Kolumny rozdziela średnik, liczby dziesiętne zapisano z przecinkiem, a puste pole oznacza brak. Odczytaj najpierw nagłówek, a następnie pojedynczy rekord; dwa sąsiednie średniki oznaczają puste pole.

```
eksport <- tekst_eksportu(eksport_demo)
print(eksport)
```

```
id;grupa;czas_min;ocena;powodzenie
u01;nowi;6,5;4;1
u02;nowi;8,0;99;0
u02;nowi;8,0;99;0
u03;doświadczeni;4,5;5;1
u04;doświadczeni;;3;
```

```
u05;nowi;-2,0;2;0
u06;doświadczeni;35,0;4;1
```

Wiersz u02 występuje dwa razy z identycznymi polami. Pole `ocena` u02 zawiera 99, czyli kod braku według słownika demonstracji. Wiersz u04 ma puste pola czasu i powodzenia. Wiersz u05 ma czas -2 minuty, a u06 — długi czas 35 minut, mieszczący się w zakresie 0–120 minut przyjętym dla danych kursu.

Duplikat, kod 99, ujemny czas i długi czas wymagają czterech różnych reakcji. Identyczny duplikat usuwa się jako nadmiarowy rekord. Kod braku zmienia znaczenie komórki. Ujemny czas wymaga sprawdzenia w źródle albo oznaczenia jako brak. Długi czas w zakresie pozostaje obserwacją do chwili, gdy protokół dostarczy dowodu błędu.

Funkcja `import_demo()` ma podaną właściwą umowę: średnik jako separator i przecinek jako znak dziesiętny. Tabela „Poprawny import” ma pięć kolumn i siedem rekordów, a czasy są liczbami, choć tekst źródłowy zawiera przecinki.

```
dane_importu <- pokaz_tabele(surowe_demo, "Poprawny import")
print(dane_importu)
```

Poprawny import

id	grupa	czas_min	ocena	powodzenie
u01	nowi	6,5	4	1
u02	nowi	8,0	99	0
u02	nowi	8,0	99	0
u03	doświadczeni	4,5	5	1
u04	doświadczeni	NA	3	NA
u05	nowi	-2,0	2	0
u06	doświadczeni	35,0	4	1

Siedem rekordów to liczba wierszy tabeli. Liczbę osób ustala kontrola identyfikatorów i duplikatów: w demonstracji siedem rekordów opisuje sześć osób.

Separator kolumn a znak dziesiętny

Właściwy separator kolumn z niewłaściwym znakiem dziesiętnym daje tabelę o poprawnym wyglądzie, w której czas pozostaje tekstem. Błąd znaku dziesiętnego trudniej rozpoznać niż sklejenie wszystkich pól w jedną kolumnę. Kontrola importu obejmuje więc klasę każdej kolumny.

Blok `import-bledny-typ` odczytuje eksport z kropką jako oczekiwanym znakiem dziesiętnym. Błędny import powstaje jako osobny obiekt. Tabela „Typ zapisu i liczba braków” podaje klasę `character` kolumny `czas_min`: program odczytał czasy jako tekst.

```
bledny_import <- kontrola_typow(import_demo(dziesiętny = "."))
print(bledny_import)
```

Typ zapisu i liczba braków

kolumna	klasa_R	braki
id	character	0
grupa	character	0
czas_min	character	1
ocena	integer	0
powodzenie	integer	1

Błędny separator kolumn daje jedną długą kolumnę albo różną liczbę pól w wierszach. Błędne kodowanie znaków uszkadza nazwy kategorii, np. „doświadczeni”. Błędny znak dziesiętny zmienia liczby w tekst. Każdy z trzech problemów rozpoznaje osobna kontrola.

W poprawnym imporcie tabela „Typ zapisu i liczba braków” podaje: `id` i `grupa` mają klasę `character` i 0 braków; `czas_min` ma klasę `numeric` i 1 brak (u04); `ocena` ma klasę `integer` i 0 braków; `powodzenie` ma klasę `integer` i 1 brak (u04). Program traktuje kod 99 jako liczbę, więc kolumna `ocena` ma 0 braków.

```
poprawny_import <- kontrola_typow(surowe_demo)
print(poprawny_import)
```

Typ zapisu i liczba braków

kolumna	klasa_R	braki
id	character	0
grupa	character	0
czas_min	numeric	1
ocena	integer	0
powodzenie	integer	1

Klasa R i skala pomiaru

Klasa R opisuje zapis techniczny, a skala pomiaru — znaczenie wartości. Program zapisuje ocenę jako liczbę całkowitą, a słownik określa ją jako pozycję porządkową z odpowiedziami 1–5. Kod 99 ma klasę `integer` i leży poza skalą 1–5. Uznanie wartości za pomiar wymaga zgodności z klasą i ze słownikiem.

Identyfikator „0012” zachowuje zera wiodące, gdy są częścią klucza; zamiana na liczbę 12 uniemożliwia połączenie z inną tabelą. Numer karty bibliotecznej jest etykietą nominalną zapisaną cyframi.

Klasa `factor` przechowuje kategorie jako poziomy o kolejnych numerach. Numer poziomu wyniku z kolejności etykiet, a wartość skali podaje słownik; mechaniczna konwersja kategorii na liczby tworzy więc inną zmienną. Gotowy skrypt kursu wykonuje konwersję, a Twoim zadaniem jest odczyt sensu wyniku.

Kolumna	Pytanie o zapis	Pytanie o pomiar
ID	Czy zachowano tekst i zera wiodące?	Czy ID jednoznacznie wskazuje jednostkę?
Grupa	Czy zapis etykiet jest spójny?	Na jakiej podstawie przypisano doświadczenie?
Czas	Czy R rozpoznaje liczby?	Od jakiego do jakiego zdarzenia mierzono czas?
Ocena	Czy 99 oznaczono jako brak?	Co znaczy każda kategoria odpowiedzi?
Powodzenie	Czy kolumna zawiera wyłącznie 0, 1 i NA?	Kto oceniał poprawność i według jakiego kryterium?

Etykiety „nowi” i „nowi ” (ze spacją na końcu) R traktuje jako dwie kategorie, bo końcowa spacja jest częścią tekstu. Usunięcie nadmiarowych spacji jest uzasadnione, gdy dokumentacja potwierdza, że obie etykiety oznaczają tę samą kategorię. Łączenie etykiet obejmuje wyłącznie zapisy tej samej kategorii.

LEARN 2: duplikat i konflikt identyfikatora

Identyczny duplikat powtarza cały rekord. W demonstracji u02 ma dwa wiersze z tymi samymi danymi. Eksport zawiera jeden pomiar na osobę, więc dodatkowa kopia powtarza tę samą obserwację i podwaja jej wagę w średniej i odsetku.

Tabela „Po usunięciu identycznej kopii” ma sześć wierszy i sześć różnych identyfikatorów. Kod 99 u02 i ujemny czas u05 pozostają w tabeli do zastosowania kolejnych reguł: jedna reguła rozwiązuje jeden rodzaj problemu.

```
unikalne <- pokaz_tabele(unikalne_demo, "Po usunięciu identycznej kopii")
print(unikalne)
```

Po usunięciu identycznej kopii

id	grupa	czas_min	ocena	powodzenie
u01	nowi	6,5	4	1
u02	nowi	8,0	99	0
u03	doświadczeni	4,5	5	1
u04	doświadczeni	NA	3	NA
u05	nowi	-2,0	2	0
u06	doświadczeni	35,0	4	1

Wartości pomiarów pozostały takie same. Dziennik zapisuje liczbę usuniętych rekordów: 1.

Konflikt identyfikatora oznacza ten sam identyfikator z różnymi wartościami. Tabela „Ten sam identyfikator, różne wyniki” jest osobnym przypadkiem diagnostycznym: dwa wiersze u02 z czasem 8 i 18 minut oraz powodzeniem 0 i 1.

```
konflikt <- pokaz_tabele(konflikt_demo, "Ten sam identyfikator, różne wyniki")
print(konflikt)
```

Ten sam identyfikator, różne wyniki

id	czas_min	powodzenie
u02	8	0
u02	18	1

Dwie wersje mogą pochodzić z poprawionego pomiaru, dwóch zadań tej samej osoby albo błędu przypisania ID. Wybór wersji wymaga źródła: protokołu, numeru zadania lub informacji o wersji. Funkcja `przygotuj_ankiety()` zatrzymuje analizę przy konflikcie i wskazuje identyfikator do wyjaśnienia.

Gdy osoba wykonała dwa zadania, oba rekordy są poprawne. Wiersz oznacza wtedy parę osoba–zadanie, a analiza wymaga agregacji do jednej wartości na osobę albo modelu pomiarów zależnych. Usunięcie powtórzonego ID usunęłoby wtedy część badania.

LEARN 3: kod braku 99

Słownik demonstracji określa odpowiedzi od 1 do 5 oraz kod 99 oznaczający brak. Zamiana 99 na NA rozpoznaje brak odpowiedzi. Imputacja, czyli uzupełnienie brakującego wyniku wartością oszacowaną, jest osobną metodą.

Tabela „Wpływ kodu 99 na rachunek średniej” porównuje średnią surowych liczb ze średnią ważnych odpowiedzi. Pięć ważnych ocen po usunięciu duplikatu to 4, 5, 3, 2 i 4, o sumie 18. Oznaczmy przez W zbiór osób z ważną odpowiedzią, przez n liczbę ważnych odpowiedzi, a przez m liczbę kodów 99:

$$\bar{x}_{99} = \frac{\sum_{i \in W} x_i + 99m}{n + m} = \frac{18 + 99}{5 + 1} = 19,5, \quad \bar{x} = \frac{\sum_{i \in W} x_i}{n} = \frac{18}{5} = 3,6.$$

Średnia $\bar{x}_{99}$ wlicza kod jako odpowiedź i leży poza skalą 1–5, a średnia $\bar{x}$ opisuje pięć ważnych odpowiedzi. Wynik spoza zakresu skali sygnalizuje błąd w przygotowaniu danych.

```
kody <- pokaz_tabele(skutek_kodu, "Wpływ kodu 99 na rachunek średniej")
print(kody)
```

Wpływ kodu 99 na rachunek średniej

wariant	N	srednia
Kod 99 błędnie traktowany jak odpowiedź	6	19,5
Wyłącznie ważne odpowiedzi 1–5	5	3,6

Kod 99 wpływa także na rozrzut wyników, histogram, korelację i indeks. Błąd na etapie przygotowania przenosi się do wszystkich dalszych analiz, dlatego kontrola wejścia poprzedza każdą analizę.

Kod 99 oznacza brak w pozycjach ankiety; w kolumnie czasu 99 minut jest pomiarem mieszczącym się w zakresie 0–120 minut. Regułę stosuje się do wskazanych pól i wskazanego znaczenia. Zamiana każdej wartości 99 w całym pliku byłaby inną, nieuzasadnioną operacją.

Zapis odpowiedzi	Znaczenie w projekcie	Postępowanie
0 w powodzeniu	Zadanie zakończone powodzeniem	Zachowaj jako wynik
0 w czasie	Pomiar na dolnej granicy zakresu	Odczytaj w kontekście zadania
99 w pozycji oceny	Kod braku według słownika	Zamień na NA w tej pozycji
Puste pole	Brak zapisu	Zachowaj brak i wyjaśnij jego pochodzenie
„Nie dotyczy”	Pytanie bez zastosowania dla osoby	Zachowaj odrębne znaczenie w protokole
„Nie wiem”	Odpowiedź o stanie wiedzy	Postępuj według definicji pytania

Odpowiedź „Nie wiem” opisuje stan wiedzy i tworzy osobną kategorię, ważną np. w pytaniu o znajomość procedury. Analiza skali od zdecydowanej niezgody do zgody obejmuje odpowiedzi 1–5, a sposób analizy kategorii „Nie wiem” wynika z celu pytania.

Wartość niemożliwa i wartość nietypowa

Czas –2 minuty leży poza zakresem pomiaru czasu wykonania zadania. Powstaje np. przez zamianę znaczników początku i końca albo literówkę. Poprawka wymaga zapisu źródłowego i wpisu w dzienniku; bez zapisu źródłowego wartość oznaczamy jako brak.

W danych dydaktycznych obowiązuje jawna reguła: czasy poza 0–120 minut oznaczamy jako brak. Zakres 0–120 minut jest regułą zbioru kursowego; w rzeczywistym projekcie zakres wynika z protokołu, limitu czasu i sposobu rejestracji.

Tabela „Zmiany komórek przy zachowaniu osób” zestawia komórki przed regułami i po nich. Zmieniły się dwie komórki: ocena u02 z 99 na NA i czas u05 z –2 na NA. Reguły zmieniają komórki, a rekordy zostają: u02 zachowuje czas 8 minut i wynik 0, a u05 — ocenę 2 i wynik 0.

```
zmiany <- pokaz_tabele(roznice_komorek, "Zmiany komórek przy zachowaniu osób")
print(zmiany)
```

Zmiany komórek przy zachowaniu osób


id	czas_przed	czas_po	ocena_przed	ocena_po
u01	6,5	6,5	4	4
u02	8,0	8,0	99	NA
u03	4,5	4,5	5	5
u04	NA	NA	3	3
u05	-2,0	NA	2	2
u06	35,0	35,0	4	4

Czas 35 minut pozostaje w tabeli. Jest znacznie dłuższy od pozostałych i mieści się w przyjętym zakresie. Nietypowość jest powodem do sprawdzenia kontekstu. Długie próby bywają dla instytucji najważniejszą

informacją o barierze usługi.

Wykres „Długi czas pozostaje obserwacją” ma na osi poziomej osoby, a na osi pionowej czas w minutach. Zawiera cztery ważne czasy po przygotowaniu: u01 6,5; u02 8,0; u03 4,5; u06 35,0 minuty. Osoba u04 ma puste pole, a czas u05 oznaczono jako brak. Decyzja o błędzie wymaga dowodu z protokołu.

```
czasy_osob <- pokaz_wykres(wykres_decyzji)
print(czasy_osob)
```



kład syntetyczny. Cztery ważne czasy; u04 ma puste pole, a czas u05 (–2 min) oznaczono jako brak.

Rysunek 1: Długi czas pozostaje obserwacją. Oś pozioma: osoby u01, u02, u03 i u06; oś pionowa: czas w minutach od 0 do 40. Punkty z podpisami: 6,5; 8,0; 4,5 i 35,0 minuty; punkt u06 leży wyraźnie wyżej od trzech pozostałych.

Wykres pudełkowy i granica wąsa

Wykres pudełkowy streszcza rozkład pięcioma liczbami. Kwartyle dzielą uporządkowane wartości na cztery części: pierwszy kwartył Q_1 oddziela najniższą ćwiartkę, mediana — połowę, trzeci kwartył Q_3 — najwyższą ćwiartkę. Pudełko obejmuje wartości od Q_1 do Q_3 , a kreska w pudełku oznacza medianę. Rozstęp międzykwartyłowy $IQR = Q_3 - Q_1$ jest długością pudełka. Wąsy sięgają do najbardziej skrajnych obserwacji leżących w odległości co najwyżej $1,5 IQR$ od pudełka.


Dla czterech ważnych czasów 4,5; 6,5; 8 i 35 minut R oblicza kwartyle przez interpolację między sąsiednimi wartościami uporządkowanymi: $Q_1 = 6,0$, mediana 7,25, $Q_3 = 14,75$ minuty. Górna granica wąsa wynosi

$$Q_3 + 1,5 IQR = 14,75 + 1,5 \cdot (14,75 - 6,0) = 14,75 + 13,125 \approx 27,9 \text{ minuty.}$$

Przedział od 14,75 do 27,9 minuty jest pusty, więc górny wąs ma zerową długość i kończy się na prawej krawędzi pudełka. Czas 35 minut leży poza granicą wąsa i pozostaje prawidłową obserwacją: granica wąsa jest konwencją graficzną, a rozpoznanie błędu wymaga protokołu.

```
pudelko <- pokaz_wykres(wykres_pudelka)
print(pudelko)
```

Cztery ważne czasy na wykresie pudełkowym



Rysunek 2: Cztery ważne czasy na wykresie pudełkowym. Oś pozioma: czas w minutach. Pudełko obejmuje czasy od 6,0 do 14,75 minuty, kreska mediany leży przy 7,25 minuty; kropkowana linia oznacza granicę $Q3 + 1,5 IQR = 27,9$ minuty, a punkt 35 minut leży na prawo od granicy.

Automatyczne usuwanie punktów spoza wąsów zmienia badane zjawisko: opis obejmuje wtedy wyłącznie osoby, którym poszło podobnie do większości. Czas wyszukiwania ma zwykle rozkład z długim prawym ogonem, więc punkty poza wąsem są w nim oczekiwane; ćwiczenie C03 (Portret próby) opisuje taki rozkład miarami.

Skutek usunięcia prawidłowego długiego czasu

Analiza wrażliwości porównuje wyniki przy nazwanej alternatywie ustalonej przed porównaniem liczb. Gdy alternatywa zmienia analizowaną populację albo definicję wyniku, opis podaje tę zmianę przed liczbami.

Tabela „Konsekwencja wykluczenia prawidłowego pomiaru” opisuje konsekwencję usunięcia czasu 35 minut: średnia spada z 13,5 do 6,33 minuty, mediana z 7,25 do 6,5 minuty, a N z 4 do 3.

```
warianty <- porownanie_wrazliwosci(wrazliwosc_czasu)
print(warianty)
```

Konsekwencja wykluczenia prawidłowego pomiaru

Wariant	N	Średnia [min]	Mediana [min]
Wszystkie ważne pomiary	4	13,500	7,25
Po usunięciu poprawnego czasu 35 min	3	6,333	6,50

Średnia zmienia się silnie, bo czas 35 minut stanowi 35 z 54 minut łącznego nakładu. Mediana zależy od kolejności wartości i zmienia się o 0,75 minuty. Ćwiczenie C03 rozwija różnicę między średnią a medianą. Na C02 najważniejsze jest pytanie o opisywany zbiór: wszystkie osoby z ważnym czasem albo osoby po wykluczeniu najdłuższej próby.

Czas 35 minut może obejmować udokumentowaną przerwę techniczną. Analiza aktywnego czasu wymaga wtedy zmierzonej długości przerwy; przypuszczenie o przerwie pozostaje przypuszczeniem.

W rzeczywistym projekcie warto zaplanować rejestrację przerw, pomocy bibliotekarza i przerywania zadania. Takie pola oddzielają trudność wyszukiwania od technicznego zakłócenia. Brak pól o przerwach jest ograniczeniem pomiaru, zapisywanym w raporcie.

Przykładowy opis porównania: „Cztery ważne czasy dają średnią 13,5 minuty. Po wyłączeniu prawidłowego pomiaru 35 minut zostałyby trzy osoby ze średnią 6,33 minuty. Niższa średnia wynika z pominięcia jednej długiej próby. Bez dowodu błędu zachowuję ten pomiar w opisie”.

LEARN 4: rachunek liczebności

Dziennik pozwala odtworzyć zmiany wierszy i zmiany poszczególnych zmiennych. Liczba osób i liczba ważnych wartości to dwie różne wielkości: zamiana 99 na brak zmniejsza N oceny o 1, a liczba rekordów pozostaje równa 6.

$$N_{\text{po}} = N_{\text{surowe}} - N_{\text{duplikatów}}, \quad n_X = N_{\text{po}} - m_X.$$

Pierwszy wzór liczy wiersze: $7 - 1 = 6$. Drugi liczy ważne wartości zmiennej X : m_X to liczba braków X po zastosowaniu reguł, a n_X liczba ważnych wartości. Dla czasu $n_{\text{czas}} = 6 - 2 = 4$ (braki u04 i u05), dla oceny $n_{\text{ocena}} = 6 - 1 = 5$ (brak u02), dla powodzenia $n_{\text{wynik}} = 6 - 1 = 5$ (brak u04). Liczba osób i liczba zmienionych komórek to dwie osobne wielkości dziennika.

Symbol	Odczyt	Znaczenie w demonstracji
N_{surowe}	liczba surowych rekordów	Siedem wierszy eksportu
$N_{\text{duplikatów}}$	liczba nadmiarowych kopii	Jeden identyczny wiersz
N_{po}	liczba rekordów po deduplikacji	Sześć osób
m_X	liczba braków zmiennej X	Dla czasu 2, dla oceny 1
n_X	liczba ważnych wartości X	Mianownik opisu zmiennej
n_{XY}	liczba kompletnych par X i Y	Podstawa analizy związku

Tabela „Rekordy oraz niebrakujące wartości na kolejnych etapach” podaje dla trzech etapów liczby rekordów, czasów, ocen i wyników. Etap „surowe”: 7 rekordów, 6 czasów, 7 ocen, 6 wyników. Etap „unikalne”: 6, 5, 6, 5. Etap „oczyszczone”: 6, 4, 5, 5. Pierwsza zmiana dotyczy powtórzonej osoby, druga — znaczenia wybranych komórek.

```
liczebnosci <- pokaz_etapy(etapy_demo)
print(liczebnosci)
```

Rekordy oraz niebrakujące wartości na kolejnych etapach

Etap	Rekordy	Czas	Ocena	Powodzenie
surowe	7	6	7	6
unikalne	6	5	6	5
oczyszczone	6	4	5	5

Przed rekodacją kolumna oceny ma siedem niepustych wartości, bo 99 jest niepustą liczbą. Słownik ujawnia jeden nieznaną wynik. Liczba NA po imporcie obejmuje puste pola; braki zapisane kodem 99 ujawnia słownik.

Osoba u05 ma brak czasu, powodzenie 0 i ocenę 2. Usunięcie całego rekordu u05 odebrałoby analizie powodzenia i oceny dwie ważne wartości.

Pary zmiennych mają własne N

Opis czasu wymaga ważnego czasu. Analiza związku czasu i oceny wymaga obu wartości tej samej osoby w jednym wierszu. Liczbę kompletnych par zapisuje wzór

$$n_{XY} = \sum_{i=1}^{N_{\text{po}}} \mathbf{1}(x_i \text{ ważne} \wedge y_i \text{ ważne}),$$

w którym $\mathbf{1}(\cdot)$ jest funkcją wskaźnikową: przyjmuje 1, gdy warunek w nawiasie jest spełniony, i 0 w pozostałych przypadkach. Symbol $\wedge$ czytamy „i”. Suma jedynek liczy osoby z ważnym czasem x_i i ważną oceną y_i .

Tabela „Czas i ocena tej samej osoby” oznacza kompletne pary kolumną `kompletna_para`. Wartość `TRUE` mają `u01`, `u03` i `u06`, więc $n_{XY} = 3$. Tabela ustala dane, z których ćwiczenie C08 (Samoocena a wykonanie) liczy korelację.

```
pary <- pokaz_tabele(pary_demo, "Czas i ocena tej samej osoby")
print(pary)
```

Czas i ocena tej samej osoby

id	czas	ocena	kompletna_para
u01	6,5	4	TRUE
u02	8,0	NA	FALSE
u03	4,5	5	TRUE
u04	NA	3	FALSE
u05	NA	2	FALSE
u06	35,0	4	TRUE

Usunięcie braków osobno z każdej kolumny przesuwają pozycje w wektorach. Funkcja obliczyłaby wtedy związek między wartościami różnych osób, choć działałaby bez komunikatu błędu. Warunek kompletności dotyczy wiersza pary.

Przykładowy odczyt: „Po przygotowaniu pozostaje sześć osób, cztery ważne czasy i pięć ważnych ocen. Do wspólnej analizy czasu i oceny wchodzi trzy kompletne pary: `u01`, `u03` i `u06`. Osoba `u02` ma czas 8 minut i brak oceny, osoba `u05` ma ocenę 2 i brak czasu; obie osoby wnoszą informację do opisów pojedynczych zmiennych”.

LEARN 5: dziennik decyzji, który można przeczytać

Zapis „oczyszczono bazę, usuwając błędy” pomija regułę, podstawę i zakres zmiany. Dobry zapis podaje regułę, podstawę, zakres zmiany i konsekwencję dla wyniku.

Reguła	Podstawa	Co liczymy?	Co zapisujemy we wniosku?
Identyczny rekord występuje ponownie	Jeden pomiar na osobę, kopia eksportu	Nadmiarowe wiersze	Liczbę usuniętych kopii
Pozycja ma kod 99	Słownik pozycji 1–5	Komórki z kodem	Zmniejszenie N
Czas leży poza 0–120 minut	Reguła danych kursowych	Komórki czasu	Ważnych odpowiedzi
To samo ID ma różne wyniki	Konflikt klucza	Identyfikatory do wyjaśnienia	Zachowanie pozostałych pól osoby
Czas jest długi i mieści się w zakresie	Protokół bez informacji o błędzie	Obserwacje do sprawdzenia	Wstrzymanie analizy do rozstrzygnięcia
			Zachowanie ich jako obserwacji

Opis małej demonstracji brzmi: „Siedem rekordów obejmowało jedną identyczną kopię, więc po deduplikacji pozostało sześć osób. Kod 99 w ocenie oznaczono jako brak. Ujemny czas uznano za niedopuszczalny pomiar i oznaczono jako brak, zachowując pozostałe odpowiedzi osoby `u05`”.

Uzupełnienie opisu brzmi: „Dostępne są cztery ważne czasy, pięć ocen i pięć wyników powodzenia. Do analizy związku czasu i oceny wchodzi trzy kompletne pary. Przyczyna braku `u04` i źródło ujemnego czasu `u05` pozostają nieznane”. Opis dotyczy demonstracji; archiwum w CHALLENGE ma własne liczby.

Kody 99 i niedopuszczalne czasy liczy się jako komórki; mogą dotyczyć tych samych rekordów, a reguły braków zachowują wszystkie wiersze. Dlatego tabela dziennika podaje nazwę działania razem z liczbą.

Chunk `notatka-demo` wyświetla dwie tabele: „Etapy przygotowania” (liczby jak w tabeli etapów) i „Dane do krótkiej notatki” z dziewięcioma miarami: 6 osób, 4 ważne czasy, średnia 13,5 i mediana 7,25 minuty,

5 ważnych ocen, 5 ważnych wyników, 3 powodzenia, czyli 60% ważnych wyników, oraz 3 pary czasu i oceny. Każde zdanie przykładowej notatki odsyła do jednej komórki. W CHALLENGE 5 sporządzisz analogiczną notatkę dla eksportu archiwum.

```
notatka <- podsumowanie_przygotowania(czyste_demo, etapy_demo)
print(notatka)
```

Etapy przygotowania

Etap	Rekordy	Czas	Ocena	Powodzenie
surowe	7	6	7	6
unikalne	6	5	6	5
oczyszczone	6	4	5	5

Dane do krótkiej notatki

miara	wartosc
Osoby po przygotowaniu	6,00
Ważne czasy	4,00
Średnia czasu [min]	13,50
Mediana czasu [min]	7,25
Ważne oceny	5,00
Ważne wyniki zadania	5,00
Powodzenia	3,00
Powodzenia [% ważnych wyników]	60,00
Pary czasu i oceny	3,00

CHALLENGE — samodzielny audyt cyfrowego archiwum

W pięciu zadaniach zastąp znaczniki odpowiedzi własnymi krótkimi akapitami. Pisz pod wynikami, poza blokami R. Surowe dane pozostają bez zmian.

Scenariusz cyfrowego archiwum

Instytucja sprawdza, czy opis kolekcji ułatwia znalezienie wskazanego obiektu. Eksport zawiera identyfikator, grupę doświadczenia, czas w minutach, ocenę zrozumiałości opisu 1–5 i sukces 0/1. Kod 99 oznacza brak oceny, a puste pole — brak danej wartości. Czas od 0 do 120 minut jest dopuszczalny.

Protokół archiwum podaje dwie dodatkowe informacje. Zero minut oznacza zarejestrowane natychmiastowe zakończenie zadania bez sukcesu. Czas 35 minut jest potwierdzonym pomiarem. Surowy eksport pozostaje bez zmian, a wszystkie reguły są udokumentowane.

CHALLENGE 1: Audyt importu

Analiza zaczyna się od kontroli importu: odczyt 7,5 minuty jako tekstu albo rozdzielenie liczby na dwa pola zmienia każdy dalszy wynik.

Blok wyświetla trzy elementy: tabelę „Import archiwum”, tabelę „Typy kolumn” z klasą R i liczbą braków każdej kolumny oraz surowy tekst eksportu. Odczytaj nazwy kolumn, liczbę kolumn i klasę czasu. Odpowiedź podaje dowody z wydruku.

```
import_archiwum <- kontrola_importu_archiwum()
print(import_archiwum)
```

Import archiwum

id	grupa	czas_min	ocena	powodzenie
a01	nowi	0,0	3	0
a02	nowi	7,5	4	1
a03	doświadczeni	12,0	99	1
a03	doświadczeni	12,0	99	1
a04	nowi	NA	2	NA
a05	doświadczeni	121,0	5	0
a06	doświadczeni	35,0	4	1

Typy kolumn

kolumna	klasa_R	braki
id	character	0
grupa	character	0
czas_min	numeric	1
ocena	integer	0
powodzenie	integer	1

```
id;grupa;czas_min;ocena;powodzenie
a01;nowi;0,0;3;0
a02;nowi;7,5;4;1
a03;doświadczeni;12,0;99;1
a03;doświadczeni;12,0;99;1
a04;nowi;;2;
a05;doświadczeni;121,0;5;0
a06;doświadczeni;35,0;4;1
```

Napisz krótki akapit: podaj liczbę rekordów i kolumn, separator pól, znak dziesiętny oraz typ czasu. Wyjaśnij, jak ustalić liczbę różnych osób na podstawie liczby rekordów.

[UZUPELNIJ_S01]

CHALLENGE 2: Powtórzenie i konflikt

W surowym eksporcie a03 występuje dwa razy z identycznymi polami. Dodatkowa tabela przedstawia inną sytuację: ten sam identyfikator z różnymi wynikami. Rozróżnienie obu sytuacji poprzedza decyzję o usunięciu informacji.

Blok wyświetla tabelę „Etapy przygotowania” z liczbą rekordów i ważnych wartości na trzech etapach oraz tabelę „Odrębny przykład konfliktu”. Tabela konfliktu jest osobną ilustracją, poza analizowanym zbiorem.

```
powtorzenia <- kontrola_powtorzen_archiwum()
print(powtorzenia)
```

Etapy przygotowania

Etap	Rekordy	Czas	Ocena	Powodzenie
surowe	7	6	7	6
bez_duplikatu	6	5	6	5
po_regulach	6	4	5	5

Odrębny przykład konfliktu

id	czas_min	powodzenie
a03	12	1
a03	18	0

Napisz krótki akapit: uzasadnij usunięcie identycznego powtórzenia, podaj N przed i po oraz wyjaśnij,

jakiej innej decyzji wymaga konflikt. Wskaż źródło informacji, które pozwala rozstrzygnąć konflikt.

[UZUPELNIJ_S02]

CHALLENGE 3: Zero, 99, 121 i NA

W archiwum występują cztery sytuacje: obserwowane zero, kod braku oceny, czas poza zakresem i puste pole. Każda ma własne znaczenie i własną regułę.

Blok wyświetla tabelę „Po zastosowaniu reguł” i tabelę „Kompletność par czasu i oceny”. Zestaw pierwszą z tabelą „Import archiwum” z CHALLENGE 1 i wskaż pola zmienione oraz zachowane.

```
reguly <- kontrola_regul_archiwum()
print(reguly)
```

Po zastosowaniu reguł

id	grupa	czas_min	ocena	powodzenie
a01	nowi	0,0	3	0
a02	nowi	7,5	4	1
a03	doświadczeni	12,0	NA	1
a04	nowi	NA	2	NA
a05	doświadczeni	NA	5	0
a06	doświadczeni	35,0	4	1

Kompletność par czasu i oceny

id	czas	ocena	para
a01	0,0	3	TRUE
a02	7,5	4	TRUE
a03	12,0	NA	FALSE
a04	NA	2	FALSE
a05	NA	5	FALSE
a06	35,0	4	TRUE

Napisz krótki akapit: opisz obsługę wartości 0, 99, 121 i pustej komórki. Podaj N ważnych czasów oraz kompletnych par czasu i oceny. Oddziel brak pomiaru od porażki zadania.

[UZUPELNIJ_S03]

CHALLENGE 4: Wynik z długą próbą i bez niej

Osoba redagująca raport proponuje usunąć 35 minut, ponieważ „reszta użytkowników szukała krócej”. Instytucję interesuje także koszt trudnych, długich poszukiwań. Decyzję o obserwacji uzasadnia dowód o pomiarze.


Blok wyświetla tabelę „Z prawidłowym długim czasem i bez niego” z N i średnią dla dwóch wariantów oraz wykres „Zero, długi czas i brak: trzy różne zapisy”. Przy odczycie uwzględnij obserwowane zero. Średnia opisuje jawnie określony zbiór.

```
dlugi_czas <- wrazliwosc_archiwum()
print(dlugi_czas)
```

Z prawidłowym długim czasem i bez niego

Wariant	N	Średnia [min]
Wszystkie ważne czasy	4	13,625
Bez prawidłowych 35 minut	3	6,500

Zero, długi czas i brak: trzy różne zapisy



regulach; a04 ma puste pole, a05 ma czas 121 min spoza zakresu, więc obie osoby mają brak czasu.

Rysunek 3: Zero, długi czas i brak: trzy różne zapisy. Oś pozioma: osoby a01, a02, a03 i a06; oś pionowa: czas w minutach. Punkty leżą przy 0; 7,5; 12 i 35 minutach. Osoby a04 (puste pole) i a05 (121 minut poza zakresem) mają brak czasu i nie mają punktu.

Napisz krótki akapit: podaj obie średnie i N, wyjaśnij zmianę oraz oceń propozycję usunięcia 35 minut. Zakończ zdaniem o informacji spoza wykresu, której wymaga ocena poprawności czasu 35 minut.

[UZUPELNIJ_S04]

CHALLENGE 5: Notatka o danych gotowych do analizy

Badacz przekazuje przygotowany zbiór osobie opisującej wyniki. Osoba opisująca potrzebuje krótkiej notatki z regułami i mianownikami; dokumentację tworzy notatka, a nazwa pliku „czyste” pozostaje etykietą.

Blok wyświetla tabelę „Etapy przygotowania” i tabelę „Dane do krótkiej notatki” z dziewięcioma mianami. Wybierz liczby opisujące wykonane działania. Notatka opisuje reguły i liczebności; reprezentatywność wymaga opisu doboru próby.

```
notatka <- podsumowanie_przygotowania(archiwum_czyste, archiwum_etapy)
print(notatka)
```

Etapy przygotowania

Etap	Rekordy	Czas	Ocena	Powodzenie
surowe	7	6	7	6
bez_duplikatu	6	5	6	5
po_regulach	6	4	5	5

Dane do krótkiej notatki

miara	wartosc
Osoby po przygotowaniu	6,000
Ważne czasy	4,000
Średnia czasu [min]	13,625
Mediana czasu [min]	9,750
Ważne oceny	5,000
Ważne wyniki zadania	5,000
Powodzenia	3,000
Powodzenia [% ważnych wyników]	60,000
Pary czasu i oceny	3,000

Napisz krótki akapit: przedstaw N surowe i końcowe, duplikat, dwie reguły braków, N ważnego czasu i sukcesu oraz jedno ograniczenie. Wyjaśnij, po co zachowuje się surowy plik i skrypt, który można wykonać ponownie.

[UZUPELNIJ_S05]

Zapis i oddanie

Porównaj pięć własnych odpowiedzi z wydrukami. Sprawdź, czy odpowiedzi odróżniają liczbę zmienionych komórek od liczby osób i brak od zarejestrowanego zera. Zapisz plik `zadanie.Rmd` w edytorze (Ctrl+S); funkcja oddania tworzy PDF z zapisanego pliku.

W konsoli wykonaj jedno polecenie. Funkcja oddania tworzy aktualny PDF, sprawdza kompletność i wysyła go razem z Rmd oraz `analiza.R` do Twojego prywatnego repozytorium z dostępem prowadzącego.

```
oddaj_zadanie("Z02")
```

Oddanie potwierdza komunikat z identyfikatorem SHA wysłanej wersji. Po komunikacie błędu popraw wskazany problem, zapisz plik i ponownie wywołaj `oddaj_zadanie("Z02")`; nowe potwierdzenie obejmuje nowe zmiany. Ocenę prowadzący zapisuje osobno w repozytorium.

Po potwierdzonym oddaniu wykonaj w konsoli `wyloguj_github()`. Na komputerze współdzielonym wyloguj również przeglądarkę i zamknij RStudio, wybierając „Don't Save” przy pytaniu o przestrzeń roboczą `.RData`. Przy braku sieci zachowaj źródła przed czyszczeniem komputera i poproś prowadzącego o ustalenie sposobu dostarczenia pracy.

Co jest oceniane

Kryterium	Dowód w Twojej pracy	Odpowiedzi	Punkty
Z02.1 Odczyt importu i struktury surowego eksportu	Liczba wierszy i kolumn, separator pól, znak dziesiętny, typ czasu; rekord eksportu odróżniony od osoby	S01	2
Z02.2 Uzasadnienie reguł duplikatów, kodów i długiego czasu	Identyczne powtórzenie a03 i konflikt ID; obsługa 0, 99, 121 i pustego pola; wynik z czasem 35 minut i bez niego	S02, S03, S04	4
Z02.3 Bilans osób i dostępnych pomiarów	N surowe, N po usunięciu powtórzeń, ważne N czasu i wyniku, kompletne pary; wiersz odróżniony od komórki i brak od niepowodzenia	S02, S03, S05	2
Z02.4 Zgodność opisu z dziennikiem i odtworzenie analizy	Informacja spoza wykresu o czasie 35 minut; reguły, wynik i ograniczenie; powód zachowania surowego źródła	S04, S05	2

Rubryka ocenia rozumienie reguł i dowodów. Skrypt wykonuje zadanie poprawnie także wtedy, gdy opis jest błędny, np. „usunięto pięć osób” przy zmianie pięciu komórek, dlatego oceniany jest opis. Poziomy

wykonania opisuje rubryka Z02: na stronie kursu w dokumencie `rubryki/Z02.html`, a w konsoli R po poleceniu `rubryka("Z02")`.

Rozwinięcia do powtórki — poza rdzeniem spotkania

Rozwinięcia stosują decyzje z LEARN do pełnego zbioru S02, arkusza i logu zdarzeń. Rozwinięcia służą powtórce i pozostają poza oceną.

Dziennik pełnego zbioru S02

Reguły S02 są te same co w demonstracji, a liczebności pochodzą z większej tabeli. Tabela „Reguły w pełnym zbiorze S02” podaje pięć wierszy: 150 rekordów przed czyszczeniem, 2 usunięte identyczne duplikaty, 4 kody 99 zamienione na NA, 2 czasy spoza 0–120 minut zamienione na NA i 148 rekordów po czyszczeniu. Nazwij jednostkę każdej liczby: rekordy albo komórki.

```
dziennik <- dziennik_s02()
print(dziennik)
```

Reguły w pełnym zbiorze S02


Reguła lub stan	Liczba
N przed czyszczeniem	150
Usunięte identyczne duplikaty	2
Kod 99 zamieniony na NA	4
Czas poza 0–120 minut zamieniony na NA	2
N po czyszczeniu	148

Dziennik opisuje działania na rekordach i komórkach. Identyczny duplikat powstaje zwykle w eksporcie, kod 99 zapisuje odmowę albo pominięcie odpowiedzi, a niedopuszczalny czas — np. błąd urządzenia. Język raportu nazywa każdą z trzech sytuacji osobno.

Wykres „Od surowego eksportu do ważnych czasów S02” przedstawia cztery liczby: 150 rekordów surowego eksportu, 148 rekordów po usunięciu duplikatów, 144 rekordy z zapisanym czasem i 142 czasy w zakresie 0–120 minut. Liczba rekordów zmienia się wyłącznie na pierwszym kroku; dwa kolejne kroki dotyczą komórek czasu.

```
przeplyw <- pokaz_wykres(wykres_przeplywu)
print(przeplyw)
```

Od surowego eksportu do ważnych czasów S02



Rysunek 4: Od surowego eksportu do ważnych czasów S02. Cztery poziome słupki od góry: 150 rekordów surowego eksportu, 148 rekordów po usunięciu duplikatów (98,7% z 150), 144 rekordy z zapisanym czasem (96,0%) i 142 czasy w zakresie 0–120 minut (94,7%).

Liczba wierszy po przygotowaniu równa się różnicy surowego N i liczby duplikatów: $150 - 2 = 148$. Braki liczy się dla każdej zmiennej osobno, bo jedna osoba może mieć kilka braków. Tabela „Niepuste wartości przed regułami i ważne po regułach” podaje: czas 146 i 142, pozycja 2 — 150 i 144, powodzenie 150 i 148.

```
liczebnosci_s02 <- bilans_s02()
print(liczebnosci_s02)
```

Rekordy S02

Rekordy surowe	Rekordy po przygotowaniu	Braki czasu
150	148	6

Niepuste wartości przed regułami i ważne po regułach

Zmienna	Niepuste przed regułami	Ważne po regułach
czas_wyszukiwania	146	142
pozycja_2	150	144
powodzenie	150	148

Kolumna „Niepuste przed regułami” obejmuje kody 99, niedopuszczalne czasy i wartości z duplikatów. Dla pozycji 2 różnica $150 - 144 = 6$ składa się z 2 wartości w duplikatach i 4 kodów 99. Dla czasu różnica $146 - 142 = 4$ składa się z 2 wartości w duplikatach i 2 czasów spoza zakresu.

Histogram czasu po przygotowaniu

Histogram dzieli oś wartości na przedziały równej szerokości i nad każdym przedziałem rysuje słupek o wysokości równej liczbie osób z wartością w przedziale. Wykres „Czas S02 po zastosowaniu reguł” ma przedziały po 2,5 minuty, zamknięte z prawej strony: przedział $(5; 7,5]$ obejmuje czasy większe od 5 i mniejsze lub równe 7,5 minuty. Suma wysokości wszystkich słupków równa się liczbie ważnych czasów, $N = 142$.

```
rozklad <- pokaz_wykres(wykres_glowny)
print(rozklad)
```

Czas S02 po zastosowaniu reguł

N = 142; szerokość przedziału 2,5 min



Rysunek 5: Czas S02 po zastosowaniu reguł: histogram 142 ważnych czasów z przedziałami po 2,5 minuty. Oś pozioma: czas wyszukiwania w minutach; oś pionowa: liczba osób. Najwyższy słupek, 38 osób, stoi nad przedziałem od 5 do 7,5 minuty; słupki obniżają się w prawo, a pojedyncze osoby mają czasy do 33,8 minuty.

Histogram przedstawia rozkład z długim prawym ogonem: 20 osób ma czas do 5 minut, 66 osób od 5 do 10 minut, 35 osób od 10 do 15 minut, 10 osób od 15 do 20 minut, a 11 osób powyżej 20 minut. Mediana wynosi 8,25 minuty. Mechanizm powstawania sześciu braków czasu wymaga informacji spoza rozkładu, np. protokołu zadania.

Długi czas jest informacją o trudności zadania. Protokół przerywający wszystkie próby po dziesięciu minutach ograniczyłby opis do prób zakończonych przed limitem; ograniczenie wynikające z limitu zapisuje się obok wyniku.

CSV i arkusz przekazują tę samą informację

Arkusz ułatwia oglądanie danych i przechowuje formatowanie, formuły, scalone komórki i kilka tabel obok siebie. Analiza wymaga jednoznacznej prostokątnej tabeli: jeden wiersz nagłówek z nazwami kolumn, a pod nim wartości tej samej jednostki obserwacji.

Pakiet kursu zawiera surowy CSV zbioru S02 oraz mały arkusz do nauki importu. Arkusz jest wycinkiem danych, a porównanie dotyczy znaczenia i zapisu odpowiadających sobie kolumn.

Odczyt korzysta z plików zapisanych w zainstalowanym pakiecie. Tabela „Lokalne pliki dwóch formatów” podaje wymiary: CSV ma 150 wierszy i 15 kolumn, arkusz ćwiczeniowy — 12 wierszy i te same 15 kolumn.

```
pliki <- porownanie_formatow()
print(pliki)
```

Lokalne pliki dwóch formatów

zrodlo	wiersze	kolumny
CSV	150	15
Arkusz ćwiczeniowy	12	15

Komunikat o pakiecie `readxl` dotyczy środowiska i zgłasza brakujące narzędzie; w sali środowisko przy-

gotowuje informatyk. Zadanie Z02 i pozostałe przykłady korzystają z CSV.

Tabela „Wybrane kolumny arkusza” zawiera identyfikator, grupę, czas i powodzenie sześciu pierwszych wierszy arkusza. Odczytaj identyfikator, etykietę grupy i jednostkę czasu. Format liczby w arkuszu dotyczy wyświetlania; wartość w analizie pozostaje ta sama.

```
arkusz <- podglad_arkusza()
print(arkusz)
```

Wybrane kolumny arkusza

ID	Grupa	Czas [min]	Powodzenie
o001	nowi	12,1	0
o002	nowi	10,4	1
o003	doświadczeni	5,8	1
o004	doświadczeni	16,1	1
o005	doświadczeni	28,0	1
o006	doświadczeni	6,3	0

Jednostkę zapisuje się w słowniku lub nagłówku opisowym, a wartość jako liczbę: zapis „8 min” w komórce zmienia kolumnę liczbową w tekstową. Niepowodzenie i wykluczenie zapisuje się w osobnej kolumnie, bo eksport do CSV usuwa kolory komórek.

Most do pracy z arkuszem. Otwórz plik ćwiczeniowy tylko do odczytu, wskaż jeden rekord i porównaj go z tabelą „Wybrane kolumny arkusza”. Sprawdź, czy puste pole pozostało puste oraz czy „doświadczeni” zachowuje polskie znaki. Arkusz służy kontroli zgodności odczytu, a wszystkie zmiany danych wykonuje skrypt.

Od logu zdarzeń do wyniku osoby

Log katalogu ma zwykle po jednym wierszu dla każdego kliknięcia, a ankieta — po jednym wierszu dla osoby. Połączenie obu tabel wymaga ustalenia poziomu danych, bo w przeciwnym razie odpowiedzi ankietowe powielają się tyle razy, ile osoba ma zdarzeń.

Tabela „Pięć zdarzeń, dwie osoby” jest osobnym przykładem dwóch sesji. Pięć wierszy logu opisuje dwie osoby: u01 ma trzy zdarzenia (start w minucie 0, filtr w minucie 1, koniec w minucie 6,5), a u02 dwa zdarzenia (start w minucie 0, koniec w minucie 8).

```
zdarzenia <- pokaz_tabele(log_demo, "Pięć zdarzeń, dwie osoby")
print(zdarzenia)
```


Pięć zdarzeń, dwie osoby

id	minuta	zdarzenie
u01	0,0	start
u01	1,0	filtr
u01	6,5	koniec
u02	0,0	start
u02	8,0	koniec

Wykres „Dwie sesje w logu zdarzeń” umieszcza każdą osobę w osobnym wierszu. Odcinek biegnie od pierwszego do ostatniego zdarzenia, punkty z podpisami oznaczają zdarzenia, a liczba przy końcu odcinka podaje długość sesji.

```
sesje_wykres <- pokaz_wykres(wykres_logu)
print(sesje_wykres)
```

Dwie sesje w logu zdarzeń



Rysunek 6: Dwie sesje w logu zdarzeń. Oś pozioma: minuta sesji. Wiersz u01: zdarzenia start (0), filtr (1) i koniec (6,5), odcinek o długości 6,5 minuty. Wiersz u02: zdarzenia start (0) i koniec (8), odcinek o długości 8 minut.

Czas sesji y_i osoby i jest różnicą znaczników czasu ostatniego i pierwszego zdarzenia:

$$y_i = c_{i,\text{koniec}} - c_{i,\text{start}} : \quad y_{u01} = 6,5 - 0 = 6,5, \quad y_{u02} = 8 - 0 = 8 \text{ minut},$$

gdzie c oznacza znacznik czasu zdarzenia w minutach od początku sesji. Indeks i oznacza osobę lub sesję zgodnie z definicją. Reguła ma sens, bo log zapisuje start i koniec jawnie; w rzeczywistych logach ostatnie kliknięcie bywa wcześniejsze od zakończenia pracy, a długa przerwa oznacza nieaktywność. Definicja sesji poprzedza obliczenie. Gdy osoba ma kilka sesji, grupowanie wyłącznie według ID osoby łączy odrębne wizyty w jeden bardzo długi czas.

Tabela „Czas od początku do końca sesji” podaje jedną wartość na osobę: u01 6,5 i u02 8 minut. Agregacja zmienia poziom danych z kliknięcia na osobę.

```
sesje <- pokaz_tabele(agregat_demo, "Czas od początku do końca sesji")
print(sesje)
```

Czas od początku do końca sesji

id	czas_min
u01	6,5
u02	8,0

Połączenie ankiety z logiem wymaga kontroli klucza: jedno ID ankiety odpowiada jednemu uzgodnionemu wynikowi zadania. Po połączeniu kontroluje się N i liczbę dopasowanych rekordów. Wzrost tabeli ze 150 do 620 wierszy po dopisaniu kliknięć zmienia jednostkę wiersza, a liczba osób pozostaje 150.

Szeroko, długo i w innej jednostce

Sześć pozycji ankiety zapisanych w sześciu kolumnach jednej osoby tworzy układ szeroki. W układzie długim każda osoba ma sześć wierszy z nazwą pozycji i odpowiedzią. Oba układy przechowują tę samą informację i wymagają innego liczenia wierszy.

Przekształcenie 150 osób z sześcioma pozycjami do układu długiego daje 900 wierszy, a liczba osób pozostaje 150. Statystyka pojedynczej pozycji zachowuje mianownik osób z odpowiedzią na tę pozycję.

Transpozycja, czyli zamiana wierszy z kolumnami, zmienia układ prezentacji, np. pojedynczego rekordu na ćwiczeniu C01. Struktura danych i projekt pozostają przy transpozycji takie same.

Przeliczenie jednostki zmienia zapis wartości: 8 minut to 480 sekund. Dziennik podaje wzór przeliczenia i nową jednostkę. Skalowanie do przedziału 0–1 i standaryzacja zmieniają sposób wyrażenia wartości; wymagają uzasadnienia w pytaniu badawczym.

Operacja	Co się zmienia?	Co należy zachować?
Usunięcie identycznego duplikatu	Liczba rekordów	Jedna kopia informacji o osobie
Rekodacja 99 na NA	Znaczenie wskazanej komórki	Jawna informacja o braku
Minuty na sekundy	Jednostka i wartość liczbową	Ten sam czas zdarzenia
Szeroko na długo	Układ tabeli i liczba wierszy	Identyfikator osoby oraz pozycji
Agregacja logu	Poziom obserwacji	Reguła wyznaczenia wyniku sesji
Standaryzacja	Skala wyrażenia wartości	Parametry odniesienia i interpretacja

Sortowanie, rangi i skalowanie na czterech czasach

Przykład dotyczy czterech osób a, b, c i d spoza danych zadania Z02, z czasami 2, 4, 4 i 8 minut. Pięć reprezentacji opisują wzory:

$$x_i^{(s)} = 60 x_i, \quad x_i^* = \frac{x_i - \min x}{\max x - \min x}, \quad z_i = \frac{x_i - \bar{x}}{s}, \quad s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}, \quad \log_2 x_i.$$

Symbol	Nazwa	Rachunek dla czterech czasów
x_i	czas osoby i w minutach	2, 4, 4, 8
$x_i^{(s)}$	ten sam czas w sekundach	120, 240, 240, 480
$\min x, \max x$	najmniejszy i największy czas	2 i 8 minut
x_i^*	wartość po skalowaniu min-max	$(4 - 2)/(8 - 2) = 1/3 \approx 0,333$ dla 4 minut
$\bar{x}$	średnia	$18/4 = 4,5$ minuty
s	odchylenie standardowe (SD): typowa odległość od średniej	$\sqrt{19/3} \approx 2,52$ minuty
z_i	wynik standaryzowany	$(8 - 4,5)/2,52 \approx 1,39$ dla 8 minut
$\log_2 x_i$	logarytm o podstawie 2	1, 2, 2, 3

Tabela „Cztery osoby: ta sama informacja, różne przekształcenia” zestawia w jednym wierszu tę samą obserwację we wszystkich reprezentacjach.

```
przeliczenia <- przyklad_transformacji()
print(przeliczenia)
```


Cztery osoby: ta sama informacja, różne przekształcenia

ID	minuty	sekundy	ranga	min_max	z	log2
a	2	120	1,0	0,000	-0,993	1
b	4	240	2,5	0,333	-0,199	2
c	4	240	2,5	0,333	-0,199	2
d	8	480	4,0	1,000	1,391	3

Wykres „Cztery czasy w pięciu skalach” ma pięć poziomych osi, po jednej na reprezentację: wartość w minutach, rangę, min-max, standaryzację z i $\log_2$. Punkty mają podpisy osób.

```
skale <- pokaz_wykres(wykres_transformacji)
print(skale)
```

Cztery czasy w pięciu skalach



Rysunek 7: Cztery czasy w pięciu skalach. Pięć poziomych osi od góry: minuty (2, 4, 4, 8), rangi (1; 2,5; 2,5; 4), min-max (0; 0,333; 0,333; 1), standaryzacja z (−0,99; −0,20; −0,20; 1,39) i log2 (1, 2, 2, 3). Osoby b i c mają ten sam punkt na każdej osi, a kolejność a, b i c, d jest wszędzie ta sama.

Kolejność czterech osób jest na każdej osi ta sama, a odległości się zmieniają. Sortowanie porządkuje całe rekordy według czasu i zachowuje identyfikator oraz pozostałe dane osoby; posortowanie samej kolumny w arkuszu przypisuje czasy innym osobom. Ranga nadaje pozycję w porządku: czasy 4 i 4 minuty zajmują miejsca drugie i trzecie, więc obie mają średnią rangę 2,5. Ranga zachowuje kolejność; odległość w minutach pozostaje w kolumnie czasu.

Skalowanie min-max, nazywane też normalizacją do zakresu 0–1, przypisuje 0 najkrótszemu i 1 najdłuższemu czasowi w zestawie. Dopisanie czasu 20 minut zmienia wartości min-max wszystkich pozostałych osób, więc porównanie grup wymaga wspólnych parametrów $\min x$ i $\max x$.

Standaryzacja wyraża odległość od średniej w jednostkach SD: $z = 1,39$ oznacza czas o 1,39 SD dłuższy od średniej. Min-max i standaryzacja zachowują kształt rozkładu. Przy identycznych wartościach mianownik obu reguł wynosi zero, więc obie reguły wymagają co najmniej dwóch różnych wartości.

Logarytm o podstawie 2 odpowiada na pytanie: do jakiej potęgi trzeba podnieść 2, aby otrzymać daną liczbę? $\log_2 8 = 3$, a $\log_2 4 = 2$. Różnica jednego na skali log2 oznacza podwojenie czasu: odstęp 2→4

minuty równa się odstępowi 4→8 minut. Równe odstępów logarytmów odpowiadają równym stosunkom czasów. Logarytm istnieje dla liczb dodatnich, a wybór transformacji wynika z pytania i trafia do reguł analizy.

Brak danych a przebieg badania

Brak techniczny, odmowa odpowiedzi i niewykonane zadanie mają różne źródła. W pliku wszystkie trzy mogą wystąpić jako NA, a protokół rozróżnia je osobnymi kodami, gdy zebrano taką informację. Przyczynę braku podaje protokół.

Gdy braki czasu występują częściej przy problemach z interfejsem, analiza samych zmierzonych czasów przedstawia usługę korzystniejszą od rzeczywistości. Gdy osoby niezadowolone rzadziej kończą ankietę, średnia deklarowanej użyteczności dotyczy bardziej zadowolonej części użytkowników. Mechanizm braków ocenia się na podstawie procesu zbierania danych.

Raport podaje liczbę braków każdej analizowanej zmiennej i ich rozkład między grupami. Tabela braków w grupach wskazuje wzorzec dostępności danych; zależność braków od nieobserwowanych wartości pozostaje założeniem.

Podstawienie średniej za brak zmniejsza zróżnicowanie i zniekształca związek między zmiennymi. Brak pozostaje brakiem do czasu przyjęcia jawnej, uzasadnionej metody analizy.

Dodatkowe przykłady z rozwiązaniem

Próba A: pozorne zwiększenie próby

Ankietę wypełniło 120 osób. Po połączeniu z logiem tabela ma 800 wierszy. Autor raportu pisze „N = 800 użytkowników”. Co sprawdzić przed poprawieniem liczby?

Najpierw sprawdzamy poziom rekordu po połączeniu: osoba, sesja albo zdarzenie. Gdy jeden uczestnik ma wiele kliknięć, 800 jest liczbą zdarzeń. Liczbę użytkowników wyznaczają identyfikatory osób i reguła włączenia. Analiza wspólna obejmuje ankiety z dopasowanym logiem, więc jej N wymaga kontroli dopasowania i bywa mniejsze od 120.

Próba B: braki a granice odsetka

Wynik zadania zarejestrowano dla 80 ze 100 osób. Wśród znanych wyników było 60 powodzeń. Czy sukces odniosło 60% czy 75% uczestników?

Wśród 80 znanych wyników odsetek powodzeń wynosi $60/80 = 75\%$, a 60% to odsetek zapisanych powodzeń wśród wszystkich stu osób. Pełny odsetek $\pi_{\text{pełne}}$ w stu próbach leży między dwoma skrajnymi wariantami braków:

$$\frac{k}{N} \leq \pi_{\text{pełne}} \leq \frac{k+m}{N} : \quad \frac{60}{100} = 60\% \leq \pi_{\text{pełne}} \leq \frac{80}{100} = 80\%,$$

gdzie $k = 60$ to liczba powodzeń, $m = 20$ liczba braków, a $N = 100$ liczba osób. Dolna granica odpowiada niepowodzeniu wszystkich osób z brakiem, górna — ich powodzeniu. Raport nazywa mianownik i liczbę braków.

Próba C: odrzucenie najdłuższych wyszukiwań

Autor usuwa wszystkie czasy powyżej mediany i stwierdza, że system działa szybko. Reguła z definicji usuwa dłuższą połowę obserwacji. Średnia po usunięciu połowy obserwacji opisuje szybszą połowę próby.

Protokół wykazujący, że określone znaczniki czasu zapisano w sekundach, uzasadnia korektę jednostki. Korekta opiera się na dowodzie o pomiarze.

Próba D: niezgodne słowniki

Jeden plik koduje powodzenie jako 1, drugi jako 2. Po połączeniu kolumna zawiera wartości 0, 1 i 2. Kod 2 wymaga odwzorowania na wspólną definicję wyniku.

Odwzorowanie kodów zapisuje się jawnie w skrypcie. Wspólna etykieta wymaga też wspólnego kryterium sukcesu: odnalezienie rekordu i poprawna ocena wiarygodności publikacji to dwa różne kryteria.

Braki w dwóch grupach

Porównanie nowych i doświadczonych użytkowników wymaga sprawdzenia, czy pomiar czasu pomijano podobnie w obu grupach. Niewielka ogólna liczba braków może skupiać się w grupie kluczowej dla pytania. Odsetek braków zmiennej w grupie g zapisuje wzór

$$b_g = \frac{m_g}{N_g} \cdot 100\% : \quad b_{\text{doświadczeni}} = \frac{4}{74} \cdot 100\% \approx 5,4\%, \quad b_{\text{nowi}} = \frac{2}{74} \cdot 100\% \approx 2,7\%,$$

gdzie m_g to liczba braków czasu w grupie g , a N_g liczba osób w grupie. Mianownikiem odsetka braków w grupie jest liczba osób w grupie: 74 doświadczonych i 74 nowych.


Chunk **braki-w-grupach** wyświetla tabelę „Mianownik odsetka braków to liczba osób w danej grupie” i wykres „Braki trzech zmiennych w dwóch grupach S02”. Tabela podaje dla doświadczonych 74 osoby, 70 ważnych czasów i 4 braki (5,4%), a dla nowych 74 osoby, 72 ważne czasy i 2 braki (2,7%).

```
braki <- braki_w_grupach()
print(braki)
```

Mianownik odsetka braków to liczba osób w danej grupie

Grupa	Osoby	Ważne czasy	Braki	Braki [%]
doświadczeni	74	70	4	5,4
nowi	74	72	2	2,7

Braki trzech zmiennych w dwóch grupach S02



Rysunek 8: Braki trzech zmiennych w dwóch grupach S02. Dwa panele, doświadczeni i nowi; w każdym poziome słupki odsetka braków dla czasu wyszukiwania, pozycji 2 i powodzenia. Doświadczeni: czas 4/74 (5,4%), pozycja 2 2/74 (2,7%), powodzenie 0/74 (0,0%). Nowi: czas 2/74 (2,7%), pozycja 2 2/74 (2,7%), powodzenie 0/74 (0,0%).

Tabela i wykres opisują dostępność pomiarów; wartości brakujących czasów pozostają nieznane. Podobne odsetki braków są zgodne z sytuacją, w której w jednej grupie zabrakło najkrótszych prób, a w drugiej najdłuższych.

Odrębny przykład: zaproszono po 50 osób z dwóch grup, a czas zapisano dla 30 nowych i 45 doświadczonych. Średnie obliczone z zapisanych czasów dotyczą dwóch podzbiorów o różnej kompletności: 60% i 90%. Interpretacja różnicy średnich jako różnicy doświadczenia wymaga ustalenia przyczyny brakujących pomiarów.

Dwa rodzaje zdania o jakości danych

Zdanie „dane są poprawne, bo funkcja wykonała się bez błędu” obejmuje więcej, niż potwierdza kontrola. Wykonanie funkcji bez błędu potwierdza warunki techniczne; opis jednostki, rezygnacje uczestników i rozumienie pytań wymagają kontroli merytorycznej.

Lepsza wersja rozdziela sprawdzony fakt i pozostałą niewiedzę: „Po zastosowaniu reguł zbiór zawiera wyłącznie unikalne rekordy, a ważne odpowiedzi pozycji mieszczą się w zakresie 1–5. Związek przyczyn braków czasu z trudnością zadania pozostaje nieznany”. Pierwsze zdanie odsyła do danych, drugie do ograniczenia projektu.

Rozróżnienie przydaje się w analizach instytucjonalnych. Kompletne logi opisują zachowanie w systemie, a potrzeby użytkowników wymagają osobnego pomiaru; poprawnie zakodowana ankieta wymaga jeszcze trafnych pytań. Kontrola danych i kontrola pomiaru uzupełniają się.

Ćwiczenie C03 (Portret próby: czas wyszukiwania, skuteczność i zróżnicowanie) opisuje rozkład czasu i skuteczność zadania średnią, medianą i histogramem obliczonymi dla jawnie określonych danych. Wynik C02 ustala, o czym zachowaniu i jakim pomiarze mówią dalsze analizy.

Przed C03 odpowiedz bez komputera: od czego zależy N czasu w porównaniu z liczbą osób; jak postępujemy z ujemnym czasem, a jak z długim czasem w zakresie; ile osób opisuje układ długi sześciu pozycji

dla 150 osób; które informacje osoby zostają przy brakującej ocenie. Każdą odpowiedź połącz z jednym konkretnym rekordem lub regułą.