

C02 — Surowy eksport: decyzje, które zmieniają wynik

Zarządzanie informacją — ćwiczenie i zadanie Z02 — 2026/27

ID: [UZUPELNIJ_ID]

2026/27

Spis treści

Początek pracy na tych zajęciach	2
Dlaczego dwie osoby otrzymały różne średnie	2
Zanim cokolwiek zmienimy	2
LEARN 1: plik CSV jest tekstem z umową	3
Separator kolumn a znak dziesiętny	4
Typ statystyczny nie wynika z klasy R	5
LEARN 2: duplikat nie jest tym samym co konflikt	5
LEARN 3: kod braku 99 nie jest wysoką oceną	6
Wartość niemożliwa i wartość nietypowa	7
Skutek usunięcia prawidłowego długiego czasu	8
LEARN 4: rachunek liczebności	9
Pary zmiennych mają własne N	9
LEARN 5: dziennik decyzji, który można przeczytać	10
CHALLENGE — samodzielny audyt cyfrowego archiwum	11
Scenariusz cyfrowego archiwum	11
CHALLENGE 1: Audyt importu	11
CHALLENGE 2: Powtórzenie i konflikt	12
CHALLENGE 3: Zero, 99, 121 i NA	13
CHALLENGE 4: Czy usunięcie długiej próby poprawia badanie?	13
CHALLENGE 5: Notatka o danych gotowych do analizy	14
Zapis i oddanie	15
Kryteria oceny	15
Rozwinięcia do powtórki — poza rdzeniem spotkania	15
Dziennik pełnego zbioru S02	15
CSV i arkusz mają przekazywać tę samą informację	17
Od logu zdarzeń do wyniku osoby	18
Szeroko, długo i w innej jednostce	19
Co brak danych może mówić o badaniu	20
Dodatkowe przykłady z rozwiązaniami	20
Czy braki występują tak samo w obu grupach	21

Dwa rodzaje zdania o jakości danych 21

Początek pracy na tych zajęciach

Otwórz RStudio. Pakiet kursu jest już zainstalowany w sali; nie instalujesz go ponownie. W konsoli poniżej edytora wpisz swoje ID i adres prywatnego repozytorium otrzymany w kursie, a następnie wykonaj polecenia. Ten blok jest instrukcją do konsoli, nie chunkiem uruchamianym przy tworzeniu PDF.

```
library(badaniaZI)
ID <- "TWOJE_ID"
zaloguj_github()
rozpocznij_zajecia(
  "C02", id_studenta = ID,
  repo_url = "ADRES_TWOJEGO_PRYWATNEGO_REPOZYTORIUM"
)
```

Dokończ logowanie na stronie GitHub otwartej w przeglądarce. Hasło i drugi składnik podajesz wyłącznie tam, nie w konsoli R. Sprawdź potwierdzony login i ID odtworzonej pracy. ID wpisujesz raz w tej sesji; pliki pracy mają je zachować także po zamknięciu RStudio.

Polecenie otwiera własny `zadanie.Rmd` i zapamiętuje katalog pracy. Nie przełączaj teraz projektu przez `.Rproj`, bo nowa sesja R utraci logowanie. Pracuj w otwartym `Rmd`, nie w źródłach pakietu. Uruchom pierwszy chunk przygotowania, potem wykonuj `LEARN` i `CHALLENGE`. Przy problemie poproś prowadzącego o pomoc; nie usuwaj pracy ani nie wpisuj cudzego ID.

Pierwszy blok ładuje gotowe funkcje z `analiza.R` oraz przygotowuje wspólny zbiór `S02`. Osobny mały eksport pozwoli prześledzić każdą zmianę komórki. Nie edytuj pliku surowego; wszystkie porównania wykonujemy na przygotowanych kopiach w pamięci.

Dlaczego dwie osoby otrzymały różne średnie

Po pierwszym spotkaniu zespół biblioteki przekazał tę samą ankietę dwóm analitykom. Jedna osoba potraktowała 99 jako odpowiedź na skali oceny. Druga rozpoznała w 99 kod braku. Ktoś usunął wszystkie wiersze z jakimkolwiek pustym polem, ktoś inny zachował je do analiz, w których miały potrzebne informacje. Z tego samego pliku powstały różne liczebności i różne podsumowania.

Nie wszystkie różnice są błędami rachunkowymi. Część wynika z innych pytań: analiza czasu potrzebuje czasu, a analiza indeksu wymaga odpowiedniej liczby pozycji. Problem pojawia się wtedy, gdy decyzja jest ukryta albo nie ma uzasadnienia. Dzisiejsze ćwiczenie uczy czytać czyszczenie jako serię decyzji o znaczeniu danych.

W `C01` odróżniliśmy rekord, zmienną i brak. Teraz sprawdzimy, jak te pojęcia działają w surowym eksporcie. Nie uczymy się „poprawiania danych aż wynik będzie ładny”. Reguły mają wynikać ze słownika, projektu i procesu pomiaru. Wynik testu statystycznego nie jest powodem do usunięcia osoby.

Przeznacz około 5 minut na odtworzenie pracy, 30 minut na pięć bloków `LEARN`, 50 minut na pięć `CHALLENGE` i 5 minut na zapis oraz oddanie. W tym jednym `Rmd` uruchamiasz gotowe analizy, w `LEARN` odczytujesz wzorcowe interpretacje, a w `CHALLENGE` piszesz własne krótkie akapity pod wynikami. Pracujesz samodzielnie; w razie trudności pytasz prowadzącego.

Nie zakładamy wcześniejszego czyszczenia danych projektu zaliczeniowego: poznasz go na `C09`. Dzisiaj masz gotowy eksport, słownik i procedurę. Twoim zadaniem jest rozumieć oraz opisać jej skutki. Rozwinięcia po `CHALLENGE` służą powtórcie i nie wymagają dodatkowych odpowiedzi.

Zanim cokolwiek zmienimy

W `LEARN` pracujemy na małym eksporcie badania katalogu: siedem rekordów opisuje sześć osób. `CHALLENGE` dotyczy osobnego badania cyfrowego archiwum. Pełny przykład `S02` pojawia się dopiero w rozwinięciu. Wszystkie dane są syntetyczne: nie opisujemy ich tak, jakby zostały zebrane od rzeczywistych użytkowników. Znaczenie przygotowanych sytuacji odczytujemy ze słownika.

Surowy plik jest punktem odniesienia. Zostawiamy go bez zmian, a reguły zapisujemy w skrypcie. Dzięki temu można odtworzyć wynik, porównać dwie uzasadnione decyzje i sprawdzić, czy w raporcie podano prawidłowe N. Ręczne usunięcie kilku komórek w arkuszu bez dziennika pozbawia nas tej możliwości.

Dokument lub obiekt	Co pozwala ustalić?	Czego sam nie mówi?
Surowy CSV	Jakie wartości przekazano do analizy	Dlaczego wartości są takie, a nie inne
Słownik	Jednostki, kody, zakresy i znaczenie pól	Czy każda wartość jest prawdziwa
Protokół obserwacji	Początek, koniec i warunki zadania	Jak wszystkie rekordy zostały wyeksportowane
Skrypt przygotowania	Jakie przekształcenia zastosowano	Czy badawczy sens reguły jest właściwy
Dziennik zmian	Ile rekordów lub komórek objęła reguła	Czy brak danych jest losowy
Tabela analityczna	Z czego obliczono wynik	Jak wyglądały dane przed przekształceniem

Zwróć uwagę na różnicę między kontrolą składniową a merytoryczną. Program może sprawdzić, czy czas jest liczbą nieujemną. Nie dowie się jednak z samej wartości 8, czy zapisano minuty aktywnego szukania, czas całej sesji czy czas do rezygnacji. Te definicje muszą pochodzić z projektu.

LEARN 1: plik CSV jest tekstem z umową

CSV przechowuje tabelę jako tekst. Umowa dotyczy separatora kolumn, znaku dziesiętnego, zapisu braków oraz kodowania znaków. Rozszerzenie `.csv` nie gwarantuje, że wszystkie programy odczytają te elementy tak samo.

Poniższy eksport używa średnika między kolumnami i przecinka w liczbach dziesiętnych. Puste pole oznacza brak. Odczytaj najpierw nagłówek, a następnie pojedynczy rekord; trzy kolejne średniki nie są trzema zerami.

```
eksport <- tekst_eksportu(eksport_demo)
print(eksport)
```

```
id;grupa;czas_min;ocena;powodzenie
u01;nowi;6,5;4;1
u02;nowi;8,0;99;0
u02;nowi;8,0;99;0
u03;doświadczeni;4,5;5;1
u04;doświadczeni;;3;
u05;nowi;-2,0;2;0
u06;doświadczeni;35,0;4;1
```

Wiersz u02 występuje dwa razy. W obu kopiach wszystkie pola są identyczne. Pozycja `ocena` zawiera 99, którego słownik demonstracji nie uznaje za ocenę: jest kodem braku. Wiersz u05 ma ujemny czas, a u06 długi, lecz mieszczący się w dopuszczalnym zakresie czas 35 minut.

Te cztery sytuacje wymagają różnych reakcji. Identyczny duplikat usuwa dodatkowy rekord. Kod braku zmienia znaczenie komórki. Ujemny czas wymaga sprawdzenia lub oznaczenia nieprawidłowego pomiaru. Długi, dopuszczalny czas pozostaje obserwacją, dopóki nie mamy dowodu błędu.

Funkcja importu ma już podaną właściwą umowę. Uruchom ją i sprawdź pięć kolumn oraz siedem rekordów. Wartości czasu powinny być liczbami, mimo że w źródłowym tekście użyto przecinka.

```
dane_importu <- pokaz_tabele(surowe_demo, "Poprawny import")
print(dane_importu)
```

Poprawny import

id	grupa	czas_min	ocena	powodzenie
u01	nowi	6.5	4	1
u02	nowi	8.0	99	0
u02	nowi	8.0	99	0
u03	doświadczeni	4.5	5	1
u04	doświadczeni	NA	3	NA
u05	nowi	-2.0	2	0
u06	doświadczeni	35.0	4	1

Siedem rekordów nie oznacza jeszcze siedmiu różnych osób. Liczba wierszy jest własnością aktualnej tabeli. Ustalenie liczby jednostek analizy wymaga kontroli identyfikatorów i duplikatów.

Separator kolumn a znak dziesiętny

Jeżeli wybierzemy właściwy separator kolumn, ale niewłaściwy znak dziesiętny, tabela może wyglądać przekonująco, a czas pozostanie tekstem. Jest to trudniejszy do zauważenia błąd niż całkowite sklejenie wszystkich pól w jedną kolumnę. Nie wystarcza więc stwierdzenie, że „plik się otworzył”.

Poniżej celowo odczytujemy przecinki dziesiętne przy oczekiwaniu kropki. Nie zmieniamy oryginalnego obiektu. Porównaj klasę czasu z poprzednim importem, a nie tylko wygląd wartości na ekranie.

```
bledny_import <- kontrola_typow(import_demo(dziesietny = "."))
print(bledny_import)
```

Typ zapisu i liczba braków

kolumna	klasa_R	braki
id	character	0
grupa	character	0
czas_min	character	1
ocena	integer	0
powodzenie	integer	1

Błędny separator kolumn może dać jedną długą kolumnę albo różną liczbę pól w wierszach. Błędne kodowanie może uszkodzić nazwy kategorii, np. „doświadczeni”. Błędny znak dziesiętny może zmienić liczby w tekst. Każdy problem rozpoznajemy inną kontrolą.

W naszym poprawnym imporcie czas i ocena są numeryczne, a ID i grupa tekstowe. Poniższa tabela pokazuje również braki. Pamiętaj, że kod 99 nie jest jeszcze rozpoznawany przez program jako brak, więc nie zwiększa tej liczby.

```
poprawny_import <- kontrola_typow(surowe_demo)
print(poprawny_import)
```

Typ zapisu i liczba braków

kolumna	klasa_R	braki
id	character	0
grupa	character	0
czas_min	numeric	1
ocena	integer	0
powodzenie	integer	1

Typ statystyczny nie wynika z klasy R

Program widzi ocenę jako liczbę całkowitą. Badacz widzi pozycję porządkową z odpowiedziami 1–5. Kod 99 nadal jest liczbą całkowitą, lecz nie jest dopuszczalną realizacją tej skali. Poprawny typ techniczny nie wystarczy do uznania wartości za poprawny pomiar.

Identyfikator „0012” powinien zachować zera wiodące, jeśli są częścią klucza. Zamiana go na liczbę 12 może uniemożliwić połączenie z inną tabelą. Numer karty bibliotecznej nie staje się zmienną ilościową tylko dlatego, że składa się z cyfr.

W przypadku **factor** program przechowuje kategorie z poziomami. Wewnętrzny numer poziomu nie musi być wartością skali. Dlatego mechaniczna konwersja kategorii na liczby może stworzyć inną zmienną niż zamierzona. Gotowy skrypt kursu upraszcza tę pracę, ale Twoim zadaniem jest rozpoznać, jaki sens ma wynik.

Kolumna	Pytanie o zapis	Pytanie o pomiar
ID	Czy zachowano tekst i zera wiodące?	Czy ID jednoznacznie wskazuje jednostkę?
Grupa	Czy zapis etykiet jest spójny?	Na jakiej podstawie przypisano doświadczenie?
Czas	Czy R rozpoznaje liczby?	Od jakiego do jakiego zdarzenia mierzono czas?
Ocena	Czy 99 oznaczono jako brak?	Co znaczy każda kategoria odpowiedzi?
Powodzenie	Czy występują tylko 0/1/NA?	Kto oceniał poprawność i według jakiego kryterium?

Etykiety „nowi” i „nowi ” mogą pojawić się jako dwie różne kategorie. Końcowa spacja jest częścią tekstu, choć trudno ją zauważyć. Usunięcie nadmiarowych spacji jest uzasadnione, gdy dokumentujemy, że etykiety miały oznaczać tę samą kategorię. Nie wolno w ten sposób łączyć rzeczywiście odmiennych odpowiedzi.

LEARN 2: duplikat nie jest tym samym co konflikt

Identyczny duplikat powtarza cały rekord. W demonstracji u02 ma drugi raz dokładnie te same dane. Jeżeli wiemy, że eksport dotyczy jednego pomiaru na osobę, dodatkowa kopia nie wnosi nowej obserwacji. Zostawienie jej nadałoby tej osobie większą wagę w średniej i odsetku.

Poniżej oglądamy tabelę po usunięciu identycznego powtórzenia. Zwróć uwagę, że kod 99 i ujemny czas nadal są obecne. Jedna reguła rozwiązuje jeden rodzaj problemu; nie udajemy, że usunięcie duplikatu automatycznie oczyściło cały zbiór.

```
unikalne <- pokaz_tabele(unikalne_demo, "Po usunięciu identycznej kopii")
print(unikalne)
```

Po usunięciu identycznej kopii

id	grupa	czas_min	ocena	powodzenie
u01	nowi	6.5	4	1
u02	nowi	8.0	99	0
u03	doświadczeni	4.5	5	1
u04	doświadczeni	NA	3	NA
u05	nowi	-2.0	2	0
u06	doświadczeni	35.0	4	1

Teraz mamy sześć wierszy i sześć różnych identyfikatorów. Nie zmieniła się wartość żadnego pomiaru;

usunęliśmy nadmiarową kopię. W dzienniku zapisujemy liczbę usuniętych rekordów, a nie liczbę komórek objętych kopiowaniem.

Konflikt wygląda inaczej: ten sam identyfikator ma różne wartości. Poniższa mała tabela jest osobnym przypadkiem diagnostycznym. Nie wybieraj automatycznie pierwszego lub ostatniego wiersza.

```
konflikt <- pokaz_tabele(konflikt_demo, "Ten sam identyfikator, różne wyniki")
print(konflikt)
```

Ten sam identyfikator, różne wyniki

id	czas_min	powodzenie
u02	8	0
u02	18	1

Wersje mogą pochodzić z poprawionego pomiaru, dwóch zadań tej samej osoby albo błędu przypisania ID. Żeby podjąć decyzję, potrzeba protokołu, numeru zadania lub informacji o wersji. Wspólna funkcja kursowa zatrzymuje analizę przy konfliktujących odpowiedziach tego samego ID. To uczciwsze niż ciche usunięcie informacji.

Jeżeli osoba wykonała dwa zadania, oba rekordy mogą być poprawne. Wtedy zmienia się jednostka tabeli: wiersz to osoba–zadanie, a nie sama osoba. Trzeba zaplanować agregację albo analizę zależnych pomiarów. Proste usunięcie powtórzonego ID zgubiłoby część badania.

LEARN 3: kod braku 99 nie jest wysoką oceną

Słownik demonstracji określa odpowiedzi od 1 do 5 oraz kod 99 oznaczający brak. Zamiana 99 na NA nie jest imputacją, czyli uzupełnieniem brakującego wyniku. Jest poprawnym rozpoznaniem, że wyniku nie znamy.

W tabeli poniżej porównujemy średnią surowych liczb ze średnią ważnych odpowiedzi. Nie jest to dowód, że średnia pojedynczej pozycji jest zawsze najlepszym opisem; używamy rachunku, aby zobaczyć skutek błędnego kodu. Wynik poza zakresem 1–5 powinien od razu wywołać kontrolę.

```
kody <- pokaz_tabele(skutek_kodu, "Wpływ kodu 99 na rachunek średniej")
print(kody)
```

Wpływ kodu 99 na rachunek średniej

wariant	N	średnia
Kod 99 błędnie traktowany jak odpowiedź	6	19.5
Wyłącznie ważne odpowiedzi 1–5	5	3.6

Kod 99 wpływałby nie tylko na średnią, ale także na odchylenie standardowe, histogram, korelację i wynik indeksu. Błąd na etapie przygotowania może więc przenieść się przez wszystkie późniejsze analizy. Większa liczba testów nie naprawi nieprawidłowej definicji wejścia.

Nie każda liczba 99 w dowolnej kolumnie jest brakiem. Wiek 99 lat albo 99 minut może być rzeczywistym pomiarem, jeśli mieści się w definicji zmiennej. Regułę stosujemy do wskazanych pól i wskazanego znaczenia. Globalne zastąpienie każdej wartości 99 w całym pliku byłoby inną, nieuzasadnioną operacją.

Zapis odpowiedzi	Znaczenie możliwe w projekcie	Postępowanie
0 w powodzeniu	Zadanie nie zakończyło się sukcesem	Zachowaj jako wynik
0 w czasie	Pomiar na dolnej granicy; wymaga kontekstu	Nie myl automatycznie z brakiem
99 w pozycji oceny	Kod braku według słownika	Zamień na NA w tej pozycji
Puste pole	Brak zapisu	Zachowaj brak i wyjaśnij jego pochodzenie

Zapis odpowiedzi	Znaczenie możliwe w projekcie	Postępowanie
„Nie dotyczy”	Pytanie nie ma zastosowania	Zachowaj odrębne znaczenie w protokole
„Nie wiem”	Odpowiedź o stanie wiedzy lub brak oceny	Postępuj według definicji pytania

„Nie wiem” może być ważną kategorią w pytaniu o znajomość procedury, lecz nie stanowi punktu na skali od zdecydowanej niezgody do zgody. Decyzję o analizie trzeba podjąć na podstawie celu pytania. Nie dopisujemy takiej odpowiedzi jako środka skali wyłącznie po to, aby uniknąć NA.

Wartość niemożliwa i wartość nietypowa

Czas -2 minuty nie może oznaczać dodatnio mierzonego czasu wykonania zadania. Może powstać przez zamianę znaczników początku i końca albo literówkę. Jeśli mamy zapis źródłowy pozwalający naprawić błąd, dokumentujemy poprawkę. Jeśli go nie mamy, nie zgadujemy „zapewne chodziło o 2”.

W danych dydaktycznych obowiązuje jawna reguła: czasy poza 0–120 minut oznaczamy jako brak. To kontrakt przygotowanego zbioru, a nie uniwersalne prawo badań wyszukiwania. W rzeczywistym projekcie zakres wynikałby z protokołu, limitu czasu i sposobu rejestracji.

Poniżej widać komórki przed i po dwóch regułach: kodzie braku oraz dopuszczalnym czasie. Wskaż, które osoby zachowują inne ważne odpowiedzi mimo utraty jednej wartości. Nie usunęliśmy całych rekordów tylko dlatego, że jedna kolumna wymagała oznaczenia braku.

```
zmiany <- pokaz_tabele(roznice_komorek, "Zmiany komórek, nie usuwanie osób")
print(zmiany)
```


Zmiany komórek, nie usuwanie osób

id	czas_przed	czas_po	ocena_przed	ocena_po
u01	6.5	6.5	4	4
u02	8.0	8.0	99	NA
u03	4.5	4.5	5	5
u04	NA	NA	3	3
u05	-2.0	NA	2	2
u06	35.0	35.0	4	4

Czas 35 minut pozostaje w tabeli. Jest dużo dłuższy od pozostałych, ale mieści się w przyjętym zakresie. Nietypowość jest powodem do sprawdzenia kontekstu, a nie wystarczającym uzasadnieniem usunięcia. Dla instytucji właśnie takie długie próby mogą oznaczać istotną barierę usługi.

Wykres pokazuje tylko ważne czasy po przygotowaniu. Odczytaj położenie u06 i zastanów się, jak jej usunięcie zmieniałoby obraz korzystania z katalogu. Nie rozstrzygaj, że punkt jest błędem, tylko dlatego, że utrudnia opisanie całej próby jednym zdaniem.

```
czasy_osob <- pokaz_wykres(wykres_decyzji)
print(czasy_osob)
```



Przykład syntetyczny. 35 minut mieści się w zadanej regule 0–120.

Automatyczne odcinanie wartości poza pudełkiem wykresu myli konwencję graficzną z rozpoznaniem błędu. W C03 zobaczymy, że punkty poza wąsami mogą być prawidłowymi obserwacjami ze skośnego rozkładu czasu. Usunięcie takich przypadków zmienia badane zjawisko: zaczynamy opisywać tylko osoby, którym poszło podobnie do większości.

Skutek usunięcia prawidłowego długiego czasu

Analiza wrażliwości sprawdza, jak wynik zmienia się pod wpływem jasno nazwanej alternatywy. Nie służy wybieraniu wersji, która daje najbardziej oczekiwany wniosek. Jeśli alternatywa zmienia populację analizowaną albo definicję wyniku, trzeba to powiedzieć przed porównaniem liczb.

W małym przykładzie długi czas 35 minut jest dopuszczalną obserwacją. Poniższe porównanie pokazuje konsekwencję jej usunięcia, ale nie uzasadnia takiej decyzji. Przeczytaj średnią i medianę w obu wierszach, pamiętając o zmianie N.

```
warianty <- porownanie_wrazliwosci(wrazliwosc_czasu)
print(warianty)
```

Konsekwencja wykluczenia prawidłowego pomiaru

Wariant	N	Średnia [min]	Mediana [min]
Wszystkie ważne pomiary	4	13.500	7.25
Po usunięciu poprawnego czasu 35 min	3	6.333	6.50

Zmiana średniej jest wyraźna, ponieważ długi czas wnosi dużą część łącznego nakładu. Mediana reaguje inaczej, bo opiera się na kolejności. Na C03 rozwiniemy tę różnicę. Tutaj ważniejsze jest pytanie, którą historię opowiada wybrany zbiór: wszystkich osób z ważnym czasem czy osób po wykluczeniu najdłuższej próby.

Jeżeli 35 minut wynikało z udokumentowanej przerwy technicznej, można zdefiniować analizę aktywnego czasu po odjęciu przerwy. Trzeba jednak znać jej długość. Nie zastępujemy czasu dowolną mniejszą liczbą i nie usuwamy osoby na podstawie przypuszczenia, że „zapewne rozmawiała przez telefon”.

W rzeczywistym projekcie warto zaplanować rejestrację przerw, pomocy bibliotekarza i przerywania zadania. Takie informacje mogą pozwolić oddzielić trudność wyszukiwania od technicznego zakłócenia. Brak tych pól w aktualnym zbiorze jest ograniczeniem pomiaru, a nie zaproszeniem do ich odtworzenia z wyobraźni.

Przykładowy opis porównania: „Cztery ważne czasy dają średnią 13,5 minuty. Po wyłączeniu prawidłowego pomiaru 35 minut zostałyby trzy osoby ze średnią około 6,33 minuty. Niższa średnia nie świadczy o poprawie katalogu: wynika z pominięcia jednej długiej próby. Bez dowodu błędu zachowuję ten pomiar w opisie”.

LEARN 4: rachunek liczebności

Dziennik powinien pozwalać odtworzyć, co stało się z wierszami i z poszczególnymi zmiennymi. Liczba osób oraz liczba ważnych wartości są różnymi wielkościami. Zmiana 99 na brak może zmniejszyć N oceny, ale nie zmienia liczby rekordów.

$$N_{\text{po}} = N_{\text{surowe}} - N_{\text{duplikatów}}, \quad n_X = N_{\text{po}} - m_X.$$

W pierwszym wzorze liczymy wiersze. W drugim m_X oznacza liczbę braków zmiennej X po zastosowaniu reguł, a n_X liczbę jej ważnych wartości. Nie odejmujemy liczby zmienionych komórek od liczby osób bez ustalenia, co reprezentuje każda z liczb.

Symbol	Odczyt	Znaczenie w demonstracji
N_{surowe}	liczba surowych rekordów	Siedem wierszy eksportu
$N_{\text{duplikatów}}$	liczba nadmiarowych kopii	Jeden identyczny wiersz
N_{po}	liczba rekordów po deduplikacji	Sześć osób
m_X	liczba braków zmiennej X	Zależy od wybranej kolumny
n_X	liczba ważnych wartości X	Mianownik jej opisu
n_{XY}	liczba kompletnych par X i Y	Podstawa analizy związku

Tabela etapów sprawdza oba rodzaje liczebności. Odczytaj zmianę między etapem „surowe” a „unikalne”, następnie między „unikalne” a „oczyszczone”. Pierwsza dotyczy powtórzonej osoby, druga znaczenia wybranych komórek.

```
liczebnosci <- pokaz_etapy(etapy_demo)
print(liczebnosci)
```

Rekordy oraz niebrakujące wartości na kolejnych etapach

Etap	Rekordy	Czas	Ocena	Powodzenie
surowe	7	6	7	6
unikalne	6	5	6	5
oczyszczone	6	4	5	5

Przed rekodacją kolumna oceny może mieć pozornie kompletne dane: 99 jest przecież niepustą liczbą. Dopiero odczyt słownika ujawnia, że jeden wynik był nieznanym. Dlatego liczba NA po imporcie nie zawsze odpowiada rzeczywistej liczbie braków pomiaru.

W naszym przykładzie nowy brak czasu u05 nie oznacza, że nie znamy wyniku jej zadania. Nadal mamy powodzenie 0 oraz ocenę 2. Globalne usunięcie u05 pozbawiłoby analizę kategorii ważnej informacji.

Pary zmiennych mają własne N

Do opisu czasu potrzebujemy ważnego czasu. Do sprawdzenia związku czasu i oceny potrzebujemy obu wartości dla tej samej osoby. Nie można połączyć czasu jednej osoby z oceną innej tylko dlatego, że oba wektory po pominięciu braków mają podobną długość.

Poniższa tabela oznacza kompletne pary. Odczytaj, które identyfikatory wchodzi do przyszłej analizy związku. Nie wykonujemy jeszcze korelacji; sprawdzamy, z jakich danych mogłaby zostać obliczona.

```
pary <- pokaz_tabele(pary_demo, "Czas i ocena tej samej osoby")
print(pary)
```

Czas i ocena tej samej osoby

id	czas	ocena	kompletna_para
u01	6.5	4	TRUE
u02	8.0	NA	FALSE
u03	4.5	5	TRUE
u04	NA	3	FALSE
u05	NA	2	FALSE
u06	35.0	4	TRUE

Jeżeli usuniemy braki oddzielnie z każdej kolumny, pozycje w wektorach mogą się przesunąć. Wtedy pozornie poprawne działanie funkcji obliczy związek między nieodpowiadającymi sobie osobami. Warunek kompletności dotyczy wiersza pary, a nie oddzielnych list liczb.

Wzór logiczny można zapisać jako $I_i = 1$, gdy osoba i ma ważne X i ważne Y , oraz $I_i = 0$ w przeciwnym razie. Wtedy $n_{XY} = \sum_i I_i$. Symbol I_i jest wskaźnikiem spełnienia warunku, a nie nową skalą kompetencji. Suma jedynek liczy osoby spełniające oba warunki.

Przykładowy odczyt: „Po przygotowaniu pozostaje sześć osób, cztery ważne czasy i pięć ważnych ocen. Do wspólnej analizy czasu oraz oceny mamy trzy kompletne pary: u01, u03 i u06. U02 ma czas, ale nie ma ważnej oceny; u05 ma ocenę, ale nie ma ważnego czasu. Osoby te mogą nadal wносить informację do opisów pojedynczych zmiennych”.

LEARN 5: dziennik decyzji, który można przeczytać

Słaby zapis brzmi: „oczyszczono bazę, usuwając błędy”. Nie pozwala ustalić, kto i dlaczego pozostał w analizie. Dobry zapis rozdziela regułę, podstawę, zakres zmiany i konsekwencję dla wyniku.

Reguła	Podstawa	Co liczymy?	Co zapisujemy we wniosku?
Identyczny rekord występuje ponownie	Jeden pomiar na osobę, kopia eksportu	Nadmiarowe wiersze	Ile kopii usunięto
Pozycja ma kod 99	Słownik pozycji 1–5	Komórki z kodem	Że zmalało N ważnych odpowiedzi
Czas jest poza 0–120	Kontrakt danych kursowych	Pomiar czasu	Że pozostałe pola osoby zachowano
To samo ID ma różne wyniki	Konflikt klucza	Identyfikatory do wyjaśnienia	Że analiza wymaga rozstrzygnięcia
Czas jest długi, ale dopuszczalny	Brak dowodu błędu	Obserwacje do sprawdzenia	Że nie usunięto ich z powodu nietypowości

Opis dla małej demonstracji może brzmieć: „Siedem rekordów obejmowało jedną identyczną kopię, więc po deduplikacji pozostało sześć osób. Kod 99 w ocenie oznaczono jako brak. Ujemny czas uznano za niedopuszczalny pomiar i również oznaczono jako brak, zachowując pozostałe odpowiedzi tej osoby”.

Uzupełnienie wzorcowego opisu brzmi: „Dostępne są cztery ważne czasy, pięć ocen i pięć wyników powodzenia. Do analizy związku czasu i oceny pozostają trzy kompletne pary. Reguły nie wyjaśniają przyczyny pierwotnego braku u04 ani źródła ujemnego czasu u05”. To interpretacja małej demonstracji, nie gotowa odpowiedź do cyfrowego archiwum.

Nie sumuj liczby kodów 99 i liczby niedopuszczalnych czasów jako liczby „usuniętych osób”. Komórki mogą dotyczyć tych samych rekordów, a reguły nie muszą usuwać żadnego wiersza. Właśnie dlatego w tabeli dziennika nazwa działania jest równie ważna jak liczba.

Gotowy wynik poniżej zbiera bilans rekordów i ważnych wartości. Sprawdź, jak każde zdanie przykładowej notatki odsyła do konkretnej komórki. W CHALLENGE sporządzisz analogiczną notatkę dla nowego eksportu, zachowując jego reguły i liczebności.

```
notatka <- podsumowanie_przygotowania(czyste_demo, etapy_demo)
print(notatka)
```

Etapy przygotowania

Etap	Rekordy	Czas	Ocena	Powodzenie
surowe	7	6	7	6
unikalne	6	5	6	5
oczyszczone	6	4	5	5

Dane do krótkiej notatki

miara	wartosc
Osoby po przygotowaniu	6.00
Ważne czasy	4.00
Średnia czasu [min]	13.50
Mediana czasu [min]	7.25
Ważne oceny	5.00
Ważne wyniki zadania	5.00
Powodzenia	3.00
Powodzenia [% ważnych wyników]	60.00
Pary czasu i oceny	3.00

CHALLENGE — samodzielny audyt cyfrowego archiwum

Pięć pól odpowiedzi uzupełniasz własnymi krótkimi akapitami. Pisz pod wynikami poza blokami R, zastępując znaczniki odpowiedzi. Nie zmieniaj surowych danych, aby dopasować je do własnego opisu.

Scenariusz cyfrowego archiwum

Instytucja sprawdza, czy opis kolekcji ułatwia znalezienie wskazanego obiektu. W eksporcie zapisano grupę doświadczenia, czas, ocenę zrozumiałości 1–5 i sukces 0/1. Kod 99 oznacza brak oceny; puste pole oznacza brak danej wartości. Czas 0–120 jest dopuszczalny, ale zero wymaga odczytania w kontekście zadania.

W przykładzie 0 minut oznacza rzeczywiście zarejestrowane natychmiastowe zakończenie bez sukcesu, nie brak pomiaru. Długi czas 35 minut jest potwierdzonym pomiarem. Surowego eksportu nie zmieniamy, a wszystkie reguły dokumentujemy.

CHALLENGE 1: Audyt importu

Najpierw trzeba sprawdzić, czy eksport został poprawnie rozdzielony na kolumny. Odczyt 7,5 minuty jako tekstu albo rozdzielenie go na dwa pola zmieniłoby dalszą analizę. Nie zaczynamy od średniej.

Blok pokazuje surowe dane i ich strukturę. Przeczytaj nazwy, liczbę kolumn i typ czasu. W odpowiedzi podaj dowody z wydruku, a nie samo „import jest poprawny”.

```
import_archiwum <- kontrola_importu_archiwum()
print(import_archiwum)
```

Import archiwum

id	grupa	czas_min	ocena	powodzenie
a01	nowi	0.0	3	0
a02	nowi	7.5	4	1
a03	doświadczeni	12.0	99	1
a03	doświadczeni	12.0	99	1
a04	nowi	NA	2	NA
a05	doświadczeni	121.0	5	0
a06	doświadczeni	35.0	4	1

Typy kolumn

kolumna	klasa_R	braki
id	character	0
grupa	character	0
czas_min	numeric	1
ocena	integer	0
powodzenie	integer	1

```
id;grupa;czas_min;ocena;powodzenie
a01;nowi;0,0;3;0
a02;nowi;7,5;4;1
a03;doświadczeni;12,0;99;1
a03;doświadczeni;12,0;99;1
a04;nowi;;2;
a05;doświadczeni;121,0;5;0
a06;doświadczeni;35,0;4;1
```

Napisz krótki akapit: podaj liczbę rekordów i kolumn, regułę separatora i dziesiętną oraz typ czasu. Wyjaśnij, dlaczego liczba rekordów nie musi jeszcze oznaczać liczby różnych osób.

[UZUPELNIJ_S01]

CHALLENGE 2: Powtórzenie i konflikt

W surowym eksporcie a03 występuje dwa razy identycznie. Dodatkowa tabela pokazuje inną możliwą sytuację: to samo ID, ale odmienne wyniki. Musisz odróżnić te problemy, zanim zdecydujesz o utracie informacji.

Uruchom blok i porównaj surowy etap z etapem bez duplikatu. Następnie przeczytaj konflikt. Ta druga tabela jest osobną ilustracją i nie została automatycznie dołączona do analizowanego zbioru.

```
powtorzenia <- kontrola_powtorzen_archiwum()
print(powtorzenia)
```

Etapy przygotowania

Etap	Rekordy	Czas	Ocena	Powodzenie
surowe	7	6	7	6
bez_duplikatu	6	5	6	5
po_regulach	6	4	5	5

Odrębny przykład konfliktu

id	czas_min	powodzenie
a03	12	1
a03	18	0

Napisz krótki akapit: uzasadnij usunięcie identycznego powtórzenia, podaj N przed i po oraz wyjaśnij, dlaczego konflikt wymaga innej decyzji. Wskaż, jakie źródło informacji pomogłoby go rozstrzygnąć.

[UZUPELNIJ_S02]

CHALLENGE 3: Zero, 99, 121 i NA

W archiwum występują cztery różne sytuacje: obserwowane zero, kod braku oceny, czas poza zakresem i puste pole. Każda ma własne znaczenie. Usunięcie wszystkich czterech osób z całej analizy byłoby nieuzasadnionym uproszczeniem.

Poniższa tabela pokazuje wynik zastosowania reguł. Zestaw ją z tabelą surową z CHALLENGE 1. Wskaż dokładnie, które pola zostały zmienione, a które zachowano.

```
reguly <- kontrola_regul_archiwum()
print(reguly)
```

Po zastosowaniu reguł

id	grupa	czas_min	ocena	powodzenie
a01	nowi	0.0	3	0
a02	nowi	7.5	4	1
a03	doświadczeni	12.0	NA	1
a04	nowi	NA	2	NA
a05	doświadczeni	NA	5	0
a06	doświadczeni	35.0	4	1

Kompletność par czasu i oceny

id	czas	ocena	para
a01	0.0	3	TRUE
a02	7.5	4	TRUE
a03	12.0	NA	FALSE
a04	NA	2	FALSE
a05	NA	5	FALSE
a06	35.0	4	TRUE

Napisz krótki akapit: opisz obsługę wartości 0, 99, 121 i pustej komórki. Podaj N ważnych czasów oraz kompletnych par czasu i oceny. Nie utożsamiaj braku pomiaru z porażką zadania.

[UZUPELNIJ_S03]

CHALLENGE 4: Czy usunięcie długiej próby poprawia badanie?

Osoba redagująca raport chce usunąć 35 minut, ponieważ „reszta użytkowników szukała krócej”. Instytucję interesuje jednak także koszt trudnych, długich poszukiwań. Prawidłowa decyzja nie wynika z samego wpływu obserwacji na średnią.


Chunk porównuje dwa zakresy danych i pokazuje czasy osób. Przy odczycie zachowaj również obserwowane zero. Średnia ma opisywać jawnie określony zbiór, nie wybrany estetycznie fragment.

```
dlugi_czas <- wrazliwosc_archiwum()
print(dlugi_czas)
```

Z prawidłowym długim czasem i bez niego

Wariant	N	Średnia [min]
Wszystkie ważne czasy	4	13.625
Bez prawidłowych 35 minut	3	6.500

Zero, długi czas i brak nie są tym samym



Napisz krótki akapit: podaj obie średnie i N, wyjaśnij zmianę oraz oceń propozycję usunięcia 35 minut. Zakończ zdaniem o tym, czego sam wykres nie rozstrzyga.

[UZUPELNIJ_S04]

CHALLENGE 5: Notatka o danych gotowych do analizy

Badacz przekazuje przygotowany zbiór osobie opisującej wyniki. Potrzebna jest krótka notatka, która pozwoli zrozumieć reguły i mianowniki. Sam plik o nazwie „czyste” nie jest dokumentacją.

Poniższy blok zestawia etapy z podsumowaniem. Wybierz właściwe liczby do opisu tego, co zrobiono. Nie pisz, że dane są reprezentatywne lub bezbłędne tylko dlatego, że skrypt wykonał się poprawnie.

```
notatka <- podsumowanie_przygotowania(archiwum_czyste, archiwum_etapy)
print(notatka)
```

Etapy przygotowania

Etap	Rekordy	Czas	Ocena	Powodzenie
surowe	7	6	7	6
bez_duplikatu	6	5	6	5
po_regulach	6	4	5	5

Dane do krótkiej notatki

miara	wartosc
Osoby po przygotowaniu	6.000
Ważne czasy	4.000
Średnia czasu [min]	13.625
Mediana czasu [min]	9.750
Ważne oceny	5.000
Ważne wyniki zadania	5.000
Powodzenia	3.000
Powodzenia [% ważnych wyników]	60.000
Pary czasu i oceny	3.000

Napisz krótki akapit: przedstaw N surowe i końcowe, duplikat, dwie reguły braków, N ważnego czasu i sukcesu oraz jedno ograniczenie. Wyjaśnij, dlaczego trzeba zachować surowy plik i ponownie wykonywalny

helper.

[UZUPELNIJ_S05]

Zapis i oddanie

Porównaj pięć własnych odpowiedzi z wydrukami. Odróżnij liczbę zmienionych komórek od liczby osób, a brak od prawdziwego zera. Zapisz ten Rmd; nie przepisuj notatki do osobnego pliku Markdown.

W konsoli wykonaj jedno polecenie. Funkcja oddania tworzy PDF z zapisanej pracy, sprawdza kompletność i wysyła dokument wraz z Rmd i `analiza.R` do Twojego prywatnego repozytorium z dostępem prowadzącego.

```
oddaj_zadanie("Z02")
```

Odczytaj potwierdzenie odbioru i SHA wysłanej wersji. Jeżeli pojawi się błąd, popraw wskazany problem, zapisz plik i wywołaj ponownie tę samą funkcję. Nie musisz oddzielnie uruchamiać renderowania, kontroli i statusu.

Po potwierdzonym oddaniu wykonaj w konsoli `wyloguj_github()`. Na komputerze współdzielonym wyloguj również przeglądarkę i zamknij RStudio bez zachowywania `.RData`. Przy braku sieci zachowaj źródła przed czyszczeniem komputera i poproś prowadzącego o pomoc.

Kryteria oceny

Kryterium	Co ma być widoczne?	Punkty
Z02.1	Poprawny odczyt importu, separatora, znaków, rozmiaru i struktury	2
Z02.2	Wyjaśnienie gotowych reguł dla typów, kodów i duplikatów	4
Z02.3	Właściwe N przed/po oraz odróżnienie braku od zera	2
Z02.4	Zgodność zapisanej tabeli z dziennikiem i odtworzenie od surowych danych	2

Rubryka ocenia rozumienie reguł i dowodów. Skrypt może prawidłowo wykonać zadanie, podczas gdy opis pozostaje błędny, np. „usunięto pięć osób” przy zmianie pięciu komórek. Sprawdź oba poziomy osobno.

Rozwinięcia do powtórki — poza rdzeniem spotkania

Poniższe materiały pokazują te same decyzje w większym zbiorze, arkuszu i logu zdarzeń. Nie dodają kolejnych obowiązkowych zadań ani osobnego oddania. Służą powrotowi do konkretnej wątpliwości o źródle danych, jednostce lub mianowniku.

Dziennik pełnego zbioru S02

Wracamy do S02. Reguły są analogiczne, ale liczebności pochodzą z większej tabeli. Najpierw odczytaj dziennik i nazwij jednostkę każdej pozycji: wiersze, kody odpowiedzi lub pomiary czasu.

```
dziennik <- pokaz_tabele(przygotowane$dziennik, "Reguły w pełnym zbiorze S02")
print(dziennik)
```

Reguły w pełnym zbiorze S02

regula	liczba
N przed czyszczeniem	150
Usunięte identyczne duplikaty	2
Kod 99 zamieniony na NA	4
Czas poza 0–120 minut zamieniony na NA	2
N po czyszczeniu	148

Dziennik nie jest listą rzeczy, które „były złe u respondentów”. Opisuje działania na rekordach. Identyfikacyjny duplikat może powstać w eksporcie, kod 99 może prawidłowo reprezentować odmowę odpowiedzi, a niedopuszczalny czas może wynikać z błędu urządzenia. Język raportu powinien rozróżniać te sytuacje.

Sprawdź, czy liczba wierszy po przygotowaniu odpowiada różnicy między surowym N a duplikatami. Następnie osobno przeczytaj ważne wartości wybranych zmiennych. Nie sumuj braków między kolumnami jako liczby osób, bo jedna osoba może mieć kilka braków.

```
liczebnosci_s02 <- bilans_s02()
print(liczebnosci_s02)
```

Rekordy S02

N_surowe	N_analityczne	braki_czasu
150	148	6


Niepuste wartości przed regułami i ważne po regułach

zmienna	N_przed	N_po
czas_wyszukiwania	146	142
pozycja_2	150	144
powodzenie	150	148

Zwróć uwagę na określenie **N_przed** w drugiej tabeli: oznacza liczbę niepustych wartości przed przygotowaniem. Może obejmować liczbowy kod 99 lub niedopuszczalny czas. Nie należy bez kontroli nazwać go liczbą poprawnych pomiarów. Znaczenie technicznego licznika wymaga komentarza.

Histogram po przygotowaniu pokazuje rozkład zapisanych czasów spełniających reguły. Odczytaj zakres, skupienie i ewentualny długi ogon. Sam kształt rozkładu nie pozwala stwierdzić, czy wszystkie braki powstały losowo.

```
rozklad <- pokaz_wykres(wykres_glowny)
print(rozklad)
```



Dłuższy czas może być ważną informacją o trudności zadania. Jeśli w przyszłym badaniu protokół przerwałby wszystkie próby po dziesięciu minutach, na podstawie samych zarejestrowanych zakończeń nie opiszemy pełnej zmienności czasu potrzebnego do sukcesu. Ograniczenie powinno być zapisane obok wyniku, nie ukryte w skrypcie.

CSV i arkusz mają przekazywać tę samą informację

Arkusz jest wygodny do oglądania danych, lecz może przechowywać formatowanie, formuły, scalone komórki i kilka tabel obok siebie. Analiza potrzebuje jednoznacznej prostokątnej tabeli. W jednym wierszu nagłówka powinny znajdować się nazwy kolumn, a niżej wartości tej samej jednostki obserwacji.

Wspólny pakiet zawiera surowy CSV oraz mały arkusz do nauki importu. Arkusz jest przykładem wycinka, więc nie zakładamy, że ma tyle samo wierszy co pełny CSV. Sprawdzamy znaczenie i zapis odpowiadających sobie kolumn.

Odczyt poniżej korzysta z plików dostępnych lokalnie w zainstalowanym pakiecie. Nie pobiera danych z internetu i nie instaluje dodatków. Pierwszy wynik dotyczy pełnego CSV, drugi arkusza ćwiczeniowego.

```
pliki <- porownanie_formatow()
print(pliki)
```

Lokalne pliki dwóch formatów

zrodlo	wiersze	kolumny
CSV	150	15
Arkusz ćwiczeniowy	12	15

Jeżeli odczyt XLSX zgłosi brak pakietu `readxl`, jest to brak przygotowanego narzędzia, a nie błąd statystyczny. W sali środowisko przygotowuje informatyk. Pozostałe przykłady oraz Z02 opierają się na CSV i nie wymagają ręcznego przepisywania arkusza.

Teraz oglądamy wybrane kolumny arkusza. Odczytaj identyfikator, etykietę grupy i jednostkę czasu. Format liczby widoczny w arkuszu nie powinien zmieniać jej wartości w analizie.

```
arkusz <- podglad_arkusza()
print(arkusz)
```

Wybrane kolumny arkusza

ID	Grupa	Czas [min]	Powodzenie
o001	nowi	12.1	0
o002	nowi	10.4	1
o003	doświadczeni	5.8	1
o004	doświadczeni	16.1	1
o005	doświadczeni	28.0	1
o006	doświadczeni	6.3	0

W arkuszu nie zapisuj jednostki w każdej komórce jako „8 min”, jeśli kolumna ma być numeryczna. Jednostkę umieść w słowniku lub nagłówku opisowym, a wartość pozostaw liczbą. Nie korzystaj z koloru komórki jako jedyne go zapisu niepowodzenia lub wykluczenia; po eksporcie do CSV kolor zniknie.

Most do pracy z arkuszem. Otwórz ćwiczeniowy plik tylko do odczytu, wskaż jeden rekord i porównaj go z podglądem w R. Sprawdź, czy puste pole pozostało puste oraz czy „doświadczeni” zachowuje polskie znaki. Nie poprawiaj danych ręcznie w arkuszu — celem jest kontrola zgodności odczytu.

Od logu zdarzeń do wyniku osoby

Plik z katalogu może zawierać po jednym wierszu dla każdego kliknięcia. Ankieta zwykle zawiera po jednym wierszu dla osoby. Bez ustalenia poziomu danych połączenie tych tabel może wielokrotnie powielić odpowiedzi ankietowe.

Poniższy log jest osobnym przykładem dwóch sesji. U01 ma trzy zdarzenia, u02 dwa. Odczytaj, dlaczego pięć wierszy nie oznacza pięciu uczestników.

```
zdarzenia <- pokaz_tabele(log_demo, "Pięć zdarzeń, dwie osoby")
print(zdarzenia)
```

Pięć zdarzeń, dwie osoby

id	minuta	zdarzenie
u01	0.0	start
u01	1.0	filtr
u01	6.5	koniec
u02	0.0	start
u02	8.0	koniec

W tej demonstracji czas sesji jest różnicą ostatniego i pierwszego znacznika. Reguła ma sens, ponieważ jawnie zapisano start i koniec. W rzeczywistych logach ostatnie kliknięcie nie musi być zakończeniem pracy, a długa przerwa może oznaczać nieaktywność. Najpierw trzeba zdefiniować sesję.

Gotowy skrypt agreguje log do jednej wartości na osobę. Odczytaj wynik oraz jego jednostkę. Agregacja zmniejsza liczbę wierszy, ale nie jest usuwaniem respondentów ani naprawą duplikatów.

```
sesje <- pokaz_tabele(agregat_demo, "Czas od początku do końca sesji")
print(sesje)
```

Czas od początku do końca sesji

id	czas_min
u01	6.5
u02	8.0

Wzór ma postać $T_i = t_{i,\text{koniec}} - t_{i,\text{start}}$. Indeks i oznacza osobę lub sesję zgodnie z definicją, a nie pojedyncze kliknięcie. Gdy zapisano kilka sesji tej samej osoby, samo grupowanie według ID osoby może połączyć odrębne wizyty w jeden bardzo długi czas.

Przy łączeniu ankiety z logiem trzeba sprawdzić klucz. Jedno ID ankiety powinno odpowiadać jednemu uzgodnionemu wynikowi zadania. Po połączeniu kontrolujemy N i liczbę dopasowanych rekordów. Wzrost tabeli ze 150 do 620 wierszy nie jest nową próbą, jeśli wynika z dopisania kliknięć.

Szeroko, długo i w innej jednostce

Sześć pozycji ankiety może występować w sześciu kolumnach jednej osoby: to układ szeroki. W układzie długim każda osoba ma sześć wierszy z nazwą pozycji i odpowiedzią. Oba układy przechowują tę samą informację, lecz wymagają innego liczenia wierszy.

Jeżeli 150 osób ma po sześć pozycji, po przekształceniu do pełnego układu długiego może powstać 900 wierszy. Nie przybyło 750 osób. Statystyka dotycząca odpowiedzi na pojedynczą pozycję powinna zachować właściwy mianownik osób z tą odpowiedzią.

Podobnie transpozycja, czyli zamiana wierszy z kolumnami, nie jest uniwersalnym sposobem „poprawienia tabeli”. Może pomóc w prezentacji małego rekordu, jak w C01, ale nie naprawia projektu ani nie nadaje sensu mieszaniu tekstów z liczbami.

Transformacja jednostki to jeszcze inne działanie. Czas 8 minut jest równy 480 sekundom. Dziennik powinien wskazywać wzór przeliczenia i nową jednostkę. Skalowanie do wartości od 0 do 1 albo standaryzacja przez odchylenie standardowe zmieniają sposób wyrażenia wartości i wymagają osobnego uzasadnienia. Nie są obowiązkową częścią czyszczenia.

Operacja	Co się zmienia?	Co należy zachować?
Usunięcie identycznego duplikatu	Liczba rekordów	Jedna kopia informacji o osobie
Rekodacja 99 na NA	Znaczenie wskazanej komórki	Jawna informacja o braku
Minuty na sekundy	Jednostka i wartość liczbową	Ten sam czas zdarzenia
Szeroko na długo	Układ tabeli i liczba wierszy	Identyfikator osoby oraz pozycji
Agregacja logu	Poziom obserwacji	Reguła wyznaczenia wyniku sesji
Standaryzacja	Skala wyrażenia wartości	Parametry odniesienia i interpretacja

Odczyt sortowania, rang i skalowania na czterech czasach

Gotowy przykład dotyczy czterech innych osób z czasami 2, 4, 4 i 8 minut. Funkcja porządkuje kolumny porównania; nie zmienia danych zadania Z02. Odczytaj w jednym wierszu, co oznacza ta sama obserwacja w każdej reprezentacji.

```
przeliczenia <- przyklad_transformacji()
print(przeliczenia)
```

Cztery osoby: ta sama informacja, różne przekształcenia

ID	minuty	sekundy	ranga	min_max	z	log2
a	2	120	1.0	0.000	-0.993	1
b	4	240	2.5	0.333	-0.199	2
c	4	240	2.5	0.333	-0.199	2
d	8	480	4.0	1.000	1.391	3

Sortowanie porządkuje całe rekordy według czasu, zachowując identyfikator i pozostałe dane osoby. Posortowanie samej kolumny w arkuszu mogłoby przypisać czas innej osobie. Ranking nadaje pozycję w tym porządku: dwa czasy po 4 minuty zajmują miejsca drugie i trzecie, więc oba mają średnią rangę 2,5. Ranga nie mówi, o ile minut ktoś był szybszy.

Skalowanie min-max, nazywane też normalizacją do zakresu 0–1, oblicza $(x - \min x) / (\max x - \min x)$. Tutaj dla 4 minut otrzymujemy $(4 - 2) / (8 - 2) = 1/3$. Wynik 1 oznacza najdłuższy czas w tym zestawie, nie pełną kompetencję. Dodanie czasu 20 minut zmieni wartości min-max pozostałych osób. Osobne skalowanie w każdej grupie uniemożliwia prosty odczyt pierwotnej różnicy czasu między grupami; trzeba zachować wspólne parametry odniesienia.

Standaryzacja $z = (x - \bar{x})/s$ wyraża odległość od średniej w jednostkach SD. Dla tych czterech czasów średnia to 4,5, a SD około 2,52 minuty; 8 minut daje $z \approx 1,39$. Ani min-max, ani standaryzacja nie wymuszają rozkładu normalnego. Gdy wszystkie wartości są identyczne, mianownik obu reguł wynosi zero i taka skala nie jest określona.

Logarytm o podstawie 2 odpowiada na pytanie: do jakiej potęgi trzeba podnieść 2, aby otrzymać daną liczbę? Dla czasu wyrażonego w minutach $\log_2(8) = 3$, a $\log_2(4) = 2$. Różnica jednego na tej skali oznacza podwojenie czasu; równe odstępstwa logarytmów odpowiadają stosunkom, nie równym przyrostom minut. Logarytm nie jest zdefiniowany dla zera i liczb ujemnych, więc nie używamy go do ukrycia błędu pomiaru. Wybór transformacji musi wynikać z pytania i być zapisany w regułach analizy.

Co brak danych może mówić o badaniu

Brak techniczny, odmowa odpowiedzi i niewykonane zadanie mają różne źródła. W pliku mogą wszystkie wystąpić jako NA, ale w protokole powinny być rozpoznawane osobno, jeśli zebrano taką informację. Bez niej nie wolno dopowiadać przyczyny na podstawie samej pustej komórki.

Jeżeli braki czasu występują częściej przy problemach z interfejsem, analiza samych zmierzonych czasów może zbyt korzystnie opisywać usługę. Jeśli osoby niezadowolone rzadziej kończą ankietę, średnia deklarowanej użyteczności może dotyczyć bardziej zadowolonej części użytkowników. Żaden test normalności nie odpowie na te pytania.

Na podstawowym poziomie raportujemy liczbę braków dla każdej analizowanej zmiennej i, jeśli ma to sens, ich rozkład między grupami. Taka kontrola może ujawnić problem, lecz nie dowodzi, że pozostałe braki są nieszkodliwe. Zależność braków od nieobserwowanych wyników nie daje się wykluczyć samą tabelą już dostępnych wartości.

W tym kursie nie wprowadzamy rozbudowanych metod imputacji. Rozumiemy jednak, dlaczego proste podstawienie średniej za brak nie tworzy prawdziwej odpowiedzi. Może sztucznie zmniejszyć zróżnicowanie i zniekształcić związki. Brak pozostaje brakiem, dopóki nie przyjęto jawnej, uzasadnionej metody analizy.

Dodatkowe przykłady z rozwiązaniem

Próba A: pozorne zwiększenie próby

Ankietę wypełniło 120 osób. Po połączeniu z logiem zapisano 800 wierszy. Autor raportu pisze „N=800 użytkowników”. Co trzeba sprawdzić przed poprawieniem liczby?

Najpierw sprawdzamy poziom rekordu po połączeniu: osoba, sesja czy zdarzenie. Jeżeli jeden uczestnik ma wiele kliknięć, 800 jest liczbą zdarzeń. Liczba użytkowników wynika z identyfikatorów osób i reguły włączenia, a nie z długości połączonej tabeli. Nie wybieramy mechanicznie 120, jeżeli część ankiet nie ma dopasowanego logu: do analizy wspólnej potrzebujemy dodatkowej kontroli dopasowania.

Próba B: braki dodane do odpowiedzi negatywnych

Wynik zadania zarejestrowano dla 80 z 100 osób. Wśród znanych wyników było 60 powodzeń. Czy sukces odniosło 60% czy 75% uczestników?

Wiemy, że 60% wszystkich stu osób ma zapisane powodzenie, a wśród osiemdziesięciu znanych wyników odsetek wynosi 75%. Nie znamy pełnego odsetka powodzeń w stu próbach. Jeśli wszystkie braki byłyby niepowodzeniami, wyniósłby 60%; jeśli powodzeniami, 80%. Raport powinien nazwać mianownik i ujawnić brak wiedzy, zamiast zamieniać dwadzieścia pustych pól w zera.

Próba C: odrzucenie najdłuższych wyszukiwań

Autor usuwa wszystkie czasy powyżej mediany i stwierdza, że system działa szybko. Reguła z definicji usuwa około połowy dłuższych obserwacji. Tak uzyskana średnia opisuje wyselekcjonowaną część próby, a nie typowe działanie usługi dla wszystkich badanych.

Inna sytuacja zachodzi, gdy protokół wykazuje, że określone znaczniki czasu zapisały się w sekundach zamiast minutach. Wtedy korekta jednostki ma zewnętrzne uzasadnienie. Rozróżnienie opiera się na dowodzie o pomiarze, nie na tym, czy wynik po zmianie wygląda korzystniej.

Próba D: niezgodne słowniki

Jeden plik koduje powodzenie jako 1, drugi jako 2. Po połączeniu pojawiają się wartości 0, 1 i 2. Nie wolno po prostu uznać 2 za „silniejsze powodzenie” ani dodać kolejnej kategorii bez sprawdzenia.

Potrzebne jest jawne odwzorowanie kodów do wspólnej definicji wyniku. Weryfikujemy także, czy oba badania stosowały to samo kryterium sukcesu. Identyczne etykiety po rekodacji nie naprawiają różnicy między odnalezieniem rekordu a poprawną oceną wiarygodności publikacji.

Czy braki występują tak samo w obu grupach

Dotychczas liczyliśmy braki w całej tabeli. Dla porównania nowych i doświadczonych użytkowników ważne jest również, czy pomiar czasu pomijano podobnie w obu grupach. Nawet niewielka ogólna liczba braków może koncentrować się w grupie kluczowej dla pytania.

Gotowy skrypt pokazuje liczebność grupy, ważne czasy oraz liczbę i odsetek braków. Mianownikiem ostatniej kolumny jest liczba osób w danej grupie. Nie używaj całej próby jako mianownika, jeśli porównujesz częstość braków między grupami.

```
braki <- braki_w_grupach()
print(braki)
```

Mianownik odsetka braków to liczba osób w danej grupie

Grupa	Osoby	Ważne czasy	Braki	Braki [%]
doświadczeni	74	70	4	5.4
nowi	74	72	2	2.7

Podobne odsetki braków nie dowodzą, że brakujące czasy miały podobne wartości. Możliwe, że w jednej grupie nie zarejestrowano najkrótszych prób, a w drugiej najdłuższych. Tabela opisuje wzorzec dostępności, lecz nie pokazuje wartości, których nie zmierzono.

Rozważ odrębny przykład: zaproszono po 50 osób z dwóch grup, ale czas zapisano dla 30 nowych i 45 doświadczonych. Średnie obliczone z tych danych dotyczą dwóch różnych podzbiorów o różnym stopniu kompletności. Zanim zinterpretujemy różnicę jako obraz doświadczenia, trzeba ustalić, dlaczego część prób nie ma pomiaru. Większa liczba permutacji późniejszego testu nie uzupełni brakujących obserwacji.

Dwa rodzaje zdania o jakości danych

Zdanie „dane są poprawne, bo funkcja nie zwróciła błędu” jest zbyt szerokie. Brak błędu oznacza, że wejście spełniło sprawdzane warunki techniczne. Może nie wykryć złego opisu jednostki, systematycznej rezygnacji uczestników ani odmiennego rozumienia pytania.

Lepsza wersja rozdziela sprawdzony fakt i pozostałą niewiedzę: „Po zastosowaniu zadanych reguł nie ma identycznych duplikatów, a ważne odpowiedzi pozycji mieszczą się w zakresie 1–5. Nie dysponujemy informacją, czy przyczyny braków czasu wiązały się z trudnością zadania”. Pierwsze zdanie odsyła do danych, drugie do ograniczenia projektu.

Takie rozróżnienie jest przydatne także w analizach instytucjonalnych. Kompletnie logi nie gwarantują pełnej wiedzy o potrzebach użytkowników, a poprawnie zakodowana ankieta nie gwarantuje trafnego pomiaru kompetencji. Kontrola danych i kontrola pomiaru są powiązane, lecz nie zastępują się wzajemnie.

W następnym zestawie opiszemy rozkład czasu oraz skuteczność zadania. Średnia, mediana i histogram będą miały sens tylko dla jasno określonych danych. Dlatego wynik C02 nie jest „technicznym wstępem do prawdziwej statystyki”: ustala, o czym zachowaniu i jakim pomiarze będziemy mówić.

Przed C03 odpowiedz bez komputera: dlaczego N czasu może być mniejsze od liczby osób; dlaczego

ujemny czas i długi czas wymagają innych reakcji; dlaczego sześć pozycji w układzie długim nie zwiększa liczby respondentów; dlaczego brakująca ocena nie usuwa automatycznie obserwowanego powodzenia. Każdą odpowiedź połącz z jednym konkretnym rekordem lub regułą.