

C03 — Opis danych i dwa wykresy

Zarządzanie informacją — część ilościowa — 2026/27

Marek Deja

2026/27

Spis treści

Cel: opisać odpowiedzi, zanim wybierzesz test	1
Przygotowanie danych	1
Miary położenia i rozproszenia	2
Liczebności i odsetki kategorii	2
Dwa wykresy	3
Histogram	3
Wykres pudełkowy	4
Jak napisać krótki opis	5
Z03 — jedna tabela i dwa wykresy własnej ankiety	5
Dalsza lektura — poza zadaniem	6

Cel: opisać odpowiedzi, zanim wybierzesz test

Jak długo użytkownicy szukają informacji i jak zróżnicowane są ich doświadczenia? Opis zaczyna się od jakości danych, liczby ważnych odpowiedzi oraz jednostek. Po zajęciach przygotujesz małą tabelę i dwa czytelne wykresy własnego wariantu. Nie przypisujemy dziś różnic do populacji ani przyczyn instytucjonalnych.

Minuty	Praca
0–10	Logowanie, własny projekt i Z03
10–30	Miary i mianowniki
30–55	Wspólna tabela, histogram i pudełko
55–80	Własny opis Z03
80–90	Kontrola i oddanie

Przygotowanie danych

Rozpocznij zajęcia przez `zaloguj_github()` i `rozpocznij_zajecia("C03", ...)`, jak w C01. Wspólnie pracujemy na syntetycznym przykładzie S02 z pakietu. Na samodzielnym etapie odczytasz surowy CSV swojego projektu; nie zmieniaj go podczas opisu.

Używamy jawnej funkcji czyszczenia poznanych już reguł. Wynik jest listą: `$dane` zawiera tabelę, a `$dziennik` liczby zmian. Odczytaj N po czyszczeniu i liczbę brakujących czasów; te dwie liczby mają inne znaczenie.

```
przygotowane <- badaniaZI::przygotuj_ankiete(badaniaZI::dane_przykladowe())
dane <- przygotowane$dane
przygotowane$dziennik
```

```
##                                reguła liczba
## 1                      N przed czyszczeniem    150
## 2          Usunięte identyczne duplikaty        2
## 3              Kod 99 zamieniony na NA          4
## 4 Czas poza 0--120 minut zamieniony na NA        2
## 5                      N po czyszczeniu    148
```

```
c(n_osob = nrow(dane), braki_czasu = sum(is.na(dane$czas_wyszukiwania)))
```

```
##      n_osob braki_czasu
##      148          6
```

Miary położenia i rozproszenia

Najpierw liczymy podstawowe miary jednej zmiennej. Średnia pokazuje poziom przeciętny, mediana punkt środkowy, a odchylenie standardowe i IQR opisują zmienność. Patrzymy też na minimum i maksimum, bo skrajne wartości mogą wpływać na interpretację średniej.

Średnia jest sumą wartości podzieloną przez liczbę znanych wartości. Mediana dzieli uporządkowane dane na dwie części; dla parzystego N R uśrednia dwie środkowe liczby. SD opisuje rozproszenie w minutach, a IQR różnicę trzeciego i pierwszego kwartyla. Wariancja ma jednostkę „minuty do kwadratu”, dlatego do opisu dla odbiorcy częściej wybieramy SD.

Liczba osób w tabeli nie jest zawsze liczbą ważnych czasów. `na.rm=TRUE` pomija brak w konkretnej operacji, ale nie zastępuje go zerem. `n_wazne` i `n_brak` zapisujemy obok miar, aby odbiorca wiedział, z ilu odpowiedzi pochodzą.

```
czas <- dane$czas_wyszukiwania
opis <- data.frame(
  n_osob = nrow(dane), n_wazne = sum(!is.na(czas)), n_brak = sum(is.na(czas)),
  srednia_min = mean(czas, na.rm = TRUE), mediana_min = median(czas, na.rm = TRUE),
  sd_min = stats::sd(czas, na.rm = TRUE), iqr_min = stats::IQR(czas, na.rm = TRUE),
  minimum_min = min(czas, na.rm = TRUE), maksimum_min = max(czas, na.rm = TRUE))
round(opis, 2)
```

```
##      n_osob n_wazne n_brak srednia_min mediana_min sd_min iqr_min minimum_min
## 1      148    142      6      10.13         8.25  5.85    7.18         1.6
##      maksimum_min
## 1          33.8
```

Wyświetlane dwie cyfry po przecinku służą czytelności, nie zwiększają dokładności pomiaru. Jeżeli czas zapisano z dokładnością do 0,1 minuty, nie interpretuj tysięcznych części minuty. Gdy wszystkie odpowiedzi są brakujące, nie ma średniej ani zakresu do opisanego; funkcja diagnostyczna lub własny warunek powinny taki przypadek wykazać.

Liczebności i odsetki kategorii

Liczebność grupy jest liczbą respondentów o danej etykietce. Jej odsetek dzielimy przez liczbę osób z ważną grupą, nie przez sumę minut ani przez liczbę wskazań kanałów. Mianownik może się zmienić między tabelami; podaj go jawnie.

```
liczebnosci <- table(dane$grupa, useNA = "no")
grupy <- data.frame(grupa = names(liczebnosci),
  n = as.integer(liczebnosci),
```

```
procent = as.numeric(100 * prop.table(liczebnosci)))
grupy
```

```
##          grupa  n procent
## 1 doświadczeni 74      50
## 2          nowi 74      50
```

```
sum(grupy$n)
```

```
## [1] 148
```

Różnica kilku punktów procentowych między grupami jest na razie opisem składu próby. Jeśli ankieta ma nieznaną populację i dobór ochotniczy, nawet równe liczebności nie gwarantują reprezentatywności. Nie uznawaj syntetycznych etykiet za dowód o faktycznym udziale studentów danego stopnia.

Dwa wykresy

Wykres ma odpowiadać konkretnemu pytaniu i skali. Słupki oddzielonych kategorii pokazują liczebności, histogram ciągłej zmiennej grupuje sąsiednie wartości w przedziały, a wykres pudełkowy streszcza rozkład w grupach. Nie używamy wykresu kołowego do pokazywania średnich czasów.

Przygotowujemy tylko ważne czasy do wykresów. Usunięcie braków z tej małej tabeli nie usuwa innych danych z głównego zbioru. Odczytaj N wykresu i zapisz je w podpisie.


```
wykres_dane <- dane[!is.na(dane$czas_wyszukiwania), ]
kolory <- badaniaZI::paleta_zi()
nrow(wykres_dane)
```

```
## [1] 142
```

Histogram

Histogram pokazuje, gdzie skupiają się wartości i czy rozkład ma jeden wyraźny szczyt. Liczba przedziałów wpływa na wygląd wykresu, dlatego traktujemy histogram jako narzędzie rozpoznawcze, a nie dowód formalny. Patrzymy na prawy ogon, który wskazuje nieliczne długie czasy szukania informacji.

```
histogram <- ggplot2::ggplot(wykres_dane, ggplot2::aes(x = czas_wyszukiwania)) +
  ggplot2::geom_histogram(
    ggplot2::aes(y = ggplot2::after_stat(density)),
    bins = 24,
    fill = kolory["secondary"],
    color = "white",
    alpha = 0.85
  ) +
  ggplot2::geom_density(color = kolory["accent"], linewidth = 1.1) +
  ggplot2::labs(
    title = "Rozkład czasu znalezienia informacji",
    x = "Czas znalezienia informacji (minuty)",
    y = "Gęstość"
  ) + badaniaZI::theme_zi()
histogram
```




Oś pionowa ma gęstość, ponieważ użyliśmy `after_stat(density)`. Pole histogramu wynosi w przybliżeniu 1; wysokość słupka nie jest procentem osób w punkcie. Pomarańczowa linia wygładza kształt i zależy od ustawień wygładzania. Przy dwóch grupach nie dopisuj takiej linii jako nowego, niezależnego zbioru odpowiedzi.

Sprawdź, czy wiele małych wartości łączy się z nielicznymi dużymi. Taki prawy ogon może sprawić, że średnia będzie większa od mediany. To typowy schemat, lecz kierunek i siłę asymetrii odczytaj z własnych danych; nie wklejaj zdania „rozkład prawoskośny”, jeśli wykres go nie uzasadnia.

Wykres pudełkowy

Boxplot streszcza rozkład przez medianę, kwartyle i potencjalne obserwacje odstające. Jest dobry do szybkiego porównania wielu grup, ale ukrywa szczegóły kształtu rozkładu. Patrzymy na położenie mediany, wysokość pudełka i punkty poza wąsami.

```
pudelko <- ggplot2::ggplot(wykres_dane,
  ggplot2::aes(x = grupa, y = czas_wyszukiwania, fill = grupa)) +
  ggplot2::geom_boxplot(alpha = 0.75, show.legend = FALSE, outlier.alpha = 0.65) +
  ggplot2::scale_fill_manual(values = unname(kolory[c("primary", "accent")])) +
  ggplot2::labs(
    title = "Czas znalezienia informacji według grupy: boxplot",
    x = "Grupa użytkowników",
    y = "Czas znalezienia informacji (minuty)"
  ) +
  badaniaZI::theme_zi() +
  ggplot2::theme(axis.text.x = ggplot2::element_text(angle = 20, hjust = 1))
pudelko
```



Linia w pudełku jest medianą, a dolna i górna krawędź to kwartyle. Wąsy sięgają najbardziej odległych obserwacji w granicach 1,5 IQR od kwartylów; nie muszą oznaczać minimum i maksimum. Punkty poza wąsami są sygnałem do sprawdzenia. Dopuszczalnej odpowiedzi nie usuwa się tylko dlatego, że została oznaczona jako odstająca.

Pudełko nie pokazuje, ile osób ma dokładnie tę samą wartość ani czy rozkład ma dwa szczyty. Dlatego czytamy je razem z liczebnością i histogramem. Podobne mediany mogą współistnieć z różnym rozproszeniem. Sama odległość pudełek nie jest formalnym testem porównania grup.

Jak napisać krótki opis

Zacznij od jednostki i N. Następnie podaj miarę typowego poziomu oraz jedną miarę zróżnicowania, odnosząc się do kształtu wykresu. Na koniec podaj ograniczenie zakresu wniosku. Przykładowa konstrukcja brzmi: „Wśród N ważnych odpowiedzi mediana czasu wyniosła M minut, a IQR Q minut. Średnia S minut była wyższa od mediany i histogram wskazywał prawy ogon. Jest to opis syntetycznej próby, a nie estymacja zachowań rzeczywistych użytkowników”. Zastąp N/M/Q/S własnymi liczbami i zmień opis, gdy wynik jest inny.

Nie pisz „większość osób miała średni czas”. Średnia jest podsumowaniem, a nie kategorią większości. Nie pisz „grupa magisterska pracuje wolniej przez brak kompetencji”: zbiór nie mierzy takiej przyczyny. Możesz napisać, jak różnią się opisowe mediany oraz czego jeszcze potrzeba do sprawdzenia wyjaśnienia.

Z03 — jedna tabela i dwa wykresy własnej ankiety

W `zadania/z03/analiza.R` odczytaj własny surowy CSV i jawnie zastosuj reguły C02, ewentualnie przez `przygotuj_ankiete()`. Dla czasu oblicz N osób, N ważne, braki, średnią, medianę, SD, IQR i zakres. Podaj liczebności i odsetki grup z mianownikami. Przygotuj histogram ważnych czasów oraz wykres pudełkowy według grupy z opisami osi i minutami.

Zapisz `opis.csv`, `histogram.png` i `boxplot.png` w `zadania/z03/wyniki`. Tabelę grup możesz dopisać jako `grupy.csv`. W `.md` odwołaj się do plików i uzasadnij wybór średniej lub mediany przez skalę, liczby

i asymetrię. Sformułuj własny opis 4–6 zdań; pozostałe miejsce w odpowiedzi przeznacz na mianowniki i ograniczenia.

Zapisujemy obiekt wykresu jawnie, żeby plik nie zależał od ostatniego obrazka w panelu Plots. Wybieramy rozmiar i rozdzielczość czytelne w raporcie. Otwórz oba PNG po zapisie i sprawdź, czy nie ucięto długich nazw grup.

```
wyniki <- "zadania/z03/wyniki"
dir.create(wyniki, recursive = TRUE, showWarnings = FALSE)
utils::write.csv(opis, file.path(wyniki, "opis.csv"),
  row.names = FALSE, fileEncoding = "UTF-8")
ggplot2::ggsave(file.path(wyniki, "histogram.png"), plot = histogram,
  width = 7, height = 4, dpi = 150)
ggplot2::ggsave(file.path(wyniki, "boxplot.png"), plot = pudełko,
  width = 7, height = 4, dpi = 150)
```

Kryterium	Punkty
Z03.1 N, liczebności/odsetki i miary z obsługą braków	3
Z03.2 Dwa wykresy, właściwe skale, osie i jednostki	3
Z03.3 Wybór miar uzasadniony typem i asymetrią	2
Z03.4 Własny opis liczbowy w granicach próby	2

Zapisz i uruchom skrypt od początku. Wywołaj `sprawdz_zadanie("Z03")`, potem `oddaj_zadanie("Z03")` i `status_oddania("Z03")`. Wyloguj pakiet i przeglądarkę. Pełne poziomy: `rubryka("Z03")`.

Dalsza lektura — poza zadaniem

Wykres Q–Q, wiolinowy, test normalności i dodatkowe miary kształtu są w galerii oraz kolejnych wykładach. Z03 nie wymaga Shapiro–Wilka. Małe p takiego testu nie stanowi automatycznej reguły doboru wszystkich innych testów: znaczenie mają pytanie, skala, projekt i liczebność.