

C05 — Co wiemy o średniej: efekt, przedział i dwa testy

Zarządzanie informacją — ćwiczenie i zadanie Z05 — 2026/27

ID: [UZUPELNIJ_ID]

2026/27

Spis treści

Początek pracy na tych zajęciach	2
Zespół chce wiedzieć więcej niż „średnia jest powyżej trzech”	2
Co robimy w 90 minut	3
LEARN 1: ustalamy cel i jednostkę	3
Dlaczego testujemy dwustronnie	3
Najpierw osoby i rozkład	3
LEARN 2: czytamy SE, t i stopnie swobody	4
Polecenie R jako zdanie	5
P mówi o modelu zerowym, nie o pożytku	5
LEARN 3: efekt i dwa różne przedziały	6
Co oznacza 95%	6
Efekt surowy i efekt standaryzowany	6
LEARN 4: bootstrap i zmiana znaków mają różne cele	7
Wiele replik i przedział bootstrapowy	7
Co zmienia procedura znaków	9
Wzór statystyki i skrajności	9
Gdy p znajduje się blisko umownego progu	10
Trzy rozkłady, które trzeba umieć nazwać	10
LEARN 5: od wyniku do pełnego opisu badania	11
Przykładowe akapity dla S02	11
Zero i próg praktyczny to nie to samo	12
CHALLENGE — samodzielna interpretacja oceny portalu	12
Scenariusz portalu i umownego odniesienia	12
CHALLENGE 1: Jaką wielkość oszacowano?	12
CHALLENGE 2: Odczytaj przedziały, nie tylko końce	13
CHALLENGE 3: Dwa testy i ich założenia	14
CHALLENGE 4: Wyniki osób, średnie replik i świat zerowy	14
CHALLENGE 5: Czy portal spełnia cel 3,5?	15
Zapis i oddanie	16
Rubryka	16
Rozwinięcia do powtórki — poza rdzeniem spotkania	16

Widzimy wszystkie możliwe znaki	16
Więcej losowań i więcej osób to różne decyzje	17
Stały efekt i zmieniająca się liczebność	17
Punkt odniesienia nie może być wybierany dla wyniku	18
Gdy interesuje nas powodzenie, zmienia się estymanda	19
Warsztat redakcyjny: pięć błędnych wniosków	19
„Z prawdopodobieństwem 95% osoby mają średnią w tym zakresie”	19
„ $P < 0,001$ dowodzi wysokich kompetencji”	19
„Bootstrap potwierdził hipotezę, bo większość średnich jest powyżej trzech”	19
„Permutacja nie ma założeń, więc zawsze jest ważniejsza”	20
„Dwa p są małe, więc ograniczenia próby nie mają znaczenia”	20
Średnia równa odniesieniu nie zapewnia symetrii	20
Niezależność jest własnością projektu	20
Co warto zapisać przed uruchomieniem testu	20

Początek pracy na tych zajęciach

Otwórz RStudio. Pakiet kursu jest już zainstalowany w sali; nie instalujesz go ponownie. W konsoli poniżej edytora wpisz swoje ID i adres prywatnego repozytorium otrzymany w kursie, a następnie wykonaj polecenia. Ten blok jest instrukcją do konsoli, nie chunkiem uruchamianym przy tworzeniu PDF.

```
library(badaniaZI)
ID <- "TWOJE_ID"
zaloguj_github()
rozpocznij_zajecia(
  "C05", id_studenta = ID,
  repo_url = "ADRES_TWOJEGO_PRYWATNEGO_REPOZYTORIUM"
)
```

Dokończ logowanie na stronie GitHub otwartej w przeglądarce. Hasło i drugi składnik podajesz wyłącznie tam, nie w konsoli R. Sprawdź potwierdzony login i ID odtworzonej pracy. ID wpisujesz raz w tej sesji; pliki pracy mają je zachować także po zamknięciu RStudio.

Polecenie otwiera własny `zadanie.Rmd` i zapamiętuje katalog pracy. Nie przełączaj teraz projektu przez `.Rproj`, bo nowa sesja R utraci logowanie. Pracuj w otwartym Rmd, nie w źródłach pakietu. Uruchom pierwszy chunk przygotowania, potem wykonuj LEARN i CHALLENGE. Przy problemie poproś prowadzącego o pomoc; nie usuwaj pracy ani nie wpisuj cudzego ID.

Pierwszy blok wczytuje gotową analizę wspólnego indeksu S02 oraz funkcje do małych demonstracji. Przygotowanie zachowuje reguły czyszczenia i indeksu z poprzednich spotkań. Nie zmieniamy odpowiedzi, aby uzyskać istotny wynik.

Zespół chce wiedzieć więcej niż „średnia jest powyżej trzech”

Biblioteka zobaczyła korzystną średnią ocenę katalogu i pyta, czy to wystarczy do podjęcia decyzji. Analityk powinien najpierw rozdzielić trzy sprawy: o ile średnia przewyższa odniesienie, jak precyzyjnie oszacowano tę różnicę i czy wynik jest nietypowy w określonym modelu zerowym. Dopiero potem można rozważyć znaczenie dla usługi.

Wspólny indeks S02 opisuje deklarowaną użyteczność katalogu według dydaktycznej reguły sześciu pozycji. Nie mierzy automatycznie całej kompetencji informacyjnej ani skuteczności działania. Wartość 3 przyjmujemy jako umowny punkt odniesienia związany ze środkiem skali. Nie jest normą populacyjną, granicą „kompetentny–niekompetentny” ani zatwierdzonym standardem biblioteki.

Pytanie główne brzmi: jaka jest średnia tego indeksu i jej różnica od 3 w modelu, którego działanie ćwiczymy? Wartość w próbie jest estymatą. Estymandę populacyjną trzeba opisać wraz z populacją i warunkami; syntetyczność danych nie pozwala przypisać otrzymanych liczb realnym użytkownikom.

Co robimy w 90 minut

Przeznacz około 5 minut na odtworzenie pracy, 30 minut na pięć bloków LEARN, 50 minut na pięć CHALLENGE i 5 minut na zapis oraz oddanie. W LEARN uruchamiasz gotowe przykłady i sprawdzasz ich wzorcowy odczyt. W CHALLENGE wpisujesz pięć własnych krótkich akapitów pod wynikami w tym samym Rmd. Pracujesz indywidualnie, a w razie trudności pytasz prowadzącego. Rozwinięcia po części obowiązkowej służą powtórcie, bez kolejnych zadań.

Scenariusz portalu w CHALLENGE zawiera gotowe indeksy po jawnej regule przygotowania. Nie musisz mieć własnego projektu badawczego ani tworzyć programu czyszczącego. Projekt zaliczeniowy zostanie przedstawiony na C09.

Nie programujesz testu ani pętli. Uruchamiasz gotowe funkcje z pliku `analiza.R`, sprawdzasz nazwy wielkości i tłumaczysz wynik na język problemu. W zadaniu indywidualnym samodzielne są odczyt, interpretacja oraz uzasadnienie, a nie odtworzenie kodu narzędzia.

LEARN 1: ustalamy cel i jednostkę

Element analizy	Definicja w S02
Jednostka	Osoba z ważnym indeksem
Zmienna	Indeks deklarowanej użyteczności katalogu, 1–5
Parametr średniej	μ w określonym modelu populacji
Wartość odniesienia	$\mu_0 = 3$ punkty
Estymanda różnicy	$\Delta = \mu - 3$
Estymata	$\widehat{\Delta} = \bar{x} - 3$
Hipoteza zerowa	$H_0 : \mu = 3$, równoważnie $\Delta = 0$
Alternatywa dwustronna	$H_1 : \mu \neq 3$

Wzrost indeksu ma kierunek korzystnej deklaracji po właściwym ukierunkowaniu pozycji. Dodatnia różnica nie oznacza poprawy w czasie: nie porównujemy tutaj wyniku przed zmianą i po zmianie interfejsu. Nie oznacza też efektu przyczynowego. Jest różnicą jednej średniej od ustalonej liczby.

Jeżeli w innym zadaniu analizowalibyśmy czas, dodatnia różnica oznaczałaby dłuższe wykonanie niż odniesienie. Znak ma sens dzięki definicji zmiennej i kolejności odejmowania. Ten sam znak nie jest zawsze „dobry” albo „zły”.

Dlaczego testujemy dwustronnie

Dwustronna alternatywa dopuszcza średnią wyższą i niższą od odniesienia. Kierunek obserwowanej różnicy odczytujemy z estymaty. Nie przechodzimy na test jednostronny dopiero po zobaczeniu, w którą stronę odchylił się wynik.

Jednostronne pytanie może być uzasadnione przed badaniem, lecz wymaga innej reguły i spójnego raportowania. W rdzeniu Z05 pozostajemy przy domyślnym teście dwustronnym. Dzięki temu słowo „bardziej skrajny” oznacza duże odchylenie w dowolnym kierunku.

Najpierw osoby i rozkład

W zbiorze po czyszczeniu pozostają osoby z różną kompletnością odpowiedzi. Reguła 5/6 daje brak indeksu tam, gdzie informacji jest za mało. N w teście jest liczbą ważnych indeksów, nie liczbą wszystkich odpowiedzi na pozycje.

Tabela pokazuje opis jednej zmiennej, z jedną wielkością w wierszu. Najpierw odczytaj N oraz braki, potem średnią i SD. Zauważ, że SE i d są innymi wielkościami niż SD, mimo że korzystają z tego samego rozrzutu.

```
opis <- opis_sredniej(wynik)
print(opis)
```


Osoby, średnia, niepewność i efekt

wielkosc	wartosc
N	147
braki	1
srednia	3.2923
SD	0.7269
SE	0.0599
odniesienie	3
roznica	0.2923
d	0.4021

Mamy 147 ważnych indeksów i jeden brak po zastosowaniu reguły. Średnia wynosi około 3,292, a SD około 0,727 punktu. Różnica od 3 to około 0,292 punktu. Te wartości opisują syntetyczną próbę przed jakąkolwiek oceną istotności.

Wykres wraca do danych pojedynczych osób. Linia przerywana oznacza 3, nie średnią próby ani granicę przedziału. Odczytaj zakres i skupienie odpowiedzi, pamiętając o ograniczonej skali indeksu.

```
osoby <- pokaz_wykres(wykres_danych)
print(osoby)
```



Wysokość słupka mówi o liczbie osób. Na późniejszym histogramie bootstrapu słupek będzie oznaczał liczbę replik, a na histogramie zerowym liczbę przestawień. Podobny kształt graficzny nie oznacza identycznej jednostki.

Indeks traktujemy w kursie jako przybliżoną zmienną ilościową. Ograniczony zakres i pochodzenie z pozycji porządkowych pozostają częścią opisu pomiaru. Test średniej nie dowodzi równych psychologicznych odległości między kategoriami.

LEARN 2: czytamy SE, t i stopnie swobody

$$SE = \frac{s}{\sqrt{N}}, \quad t = \frac{\bar{x} - \mu_0}{SE}.$$

SE opisuje oszacowaną zmienność średniej między hipotetycznymi niezależnymi próbami, pod standar-

dowym modelem. SD opisuje rozrzut osób w próbie. Dla naszych danych SE wynosi około 0,060 punktu, znacznie mniej niż SD. Nie znaczy to, że osoby są niemal identyczne.

Licznik t to różnica 0,292 punktu. Mianownik to około 0,060 punktu niepewności średniej. Statystyka wynosi zatem około 4,876 i nie ma jednostki. Odczyt: „średnia leży około 4,88 oszacowanego błędu standardowego powyżej odniesienia”.

Poniższy blok pokazuje klasyczny wynik w trzech kolumnach. Przeczytaj t wraz z df oraz p . Funkcja formatująca nie zamienia bardzo małego p w zero.

```
test <- test_sredniej(wynik)
print(test)
```

Dwustronny test t jednej średniej

t	df	p
4.8756	146	<1e-04

Stopnie swobody wynoszą $N - 1 = 146$. Identyfikują rozkład odniesienia, z którego odczytujemy skrajność t . Nie są liczbą grup, miarą jakości skali ani dowodem reprezentatywności.

Dla niezależnych obserwacji z populacji normalnej standardowy test ma dokładne uzasadnienie rozkładowe. Przy innych rozkładach wnioskowanie o średniej może korzystać z przybliżenia, którego jakość zależy od rozkładu i N . Nie stosujemy magicznego progu „powyżej 30 wszystko jest poprawne”, a sprawdzenie normalności nie zastępuje oceny niezależności.

Polecenie R jako zdanie

Oryginalny obiekt testu pokazuje także nazwę metody, alternatywę, przedział i estymatę. Odczytaj, którego parametru dotyczy napis „confidence interval”. W jednopróbkowym wywołaniu `t.test(x, mu=3)` jest to średnia, nie różnica od 3.

```
wydruk_R <- oryginal_testu_sredniej(wynik)
print(wydruk_R)
```

One Sample t-test

```
data:  wazne
t = 4.8756, df = 146, p-value = 2.8e-06
alternative hypothesis: true mean is not equal to 3
95 percent confidence interval:
 3.173809 3.410771
sample estimates:
mean of x
 3.29229
```

Argument μ określa wartość w hipotezie zerowej. Nie usuwa jej z danych ani nie zmienia obliczonej średniej. Jeśli zmienisz odniesienie, zmieni się różnica i wynik testu, ale standardowy dwustronny przedział tej samej średniej pozostanie taki sam.

Odczyt wyniku funkcji można sprawdzić w dokumentacji R dla `t.test`. W ćwiczeniu ważniejszy od zapamiętania nazwy argumentu jest jednak sens: porównujemy określony parametr z określoną wartością.

P mówi o modelu zerowym, nie o pożytku

Klasyczne p w przykładzie wynosi około $2,8 \cdot 10^{-6}$, czyli 0,0000028. Oznacza rzadkość statystyki co najmniej tak skrajnej przy H_0 i założeniach testu. Nie jest prawdopodobieństwem, że katalog jest użyteczny, ani procentem osób z pozytywną oceną.

Notacja $2.8e-06$ jest komputerowym zapisem $2,8 \cdot 10^{-6}$. To bardzo mała liczba dodatnia, nie ujemna i

nie zero. W raporcie można zapisać $p < 0,001$ z zachowaniem pozostałych elementów wyniku; sam próg nie powinien zastępować estymaty.

LEARN 3: efekt i dwa różne przedziały

Klasyczny przedział średniej zapisujemy:

$$CI_{95\%}(\mu) = [\bar{x} - t_{0,975;N-1}SE, \bar{x} + t_{0,975;N-1}SE]$$

Aby otrzymać przedział różnicy $\Delta = \mu - 3$, odejmujemy 3 od obu końców. Szerokość się nie zmienia, ponieważ to przesunięcie osi. Zmienia się natomiast parametr oraz jego wartość zerowa.

Tabela rozdziela oba parametry. Na razie czytamy wyłącznie wiersze metody t. Później porównamy je z przedziałami bootstrapowymi obliczonymi dla dokładnie tych samych wielkości.

```
przedzialy_t <- przedzialy_sredniej(wynik, metoda = "t")
print(przedzialy_t)
```

95% CI średniej [pkt]

metoda	estymata	dol	gora
t	3.2923	3.1738	3.4108

95% CI różnicy od odniesienia [pkt]

metoda	estymata	dol	gora
t	0.2923	0.1738	0.4108

Średnia ma CI około [3,174; 3,411] punktu. Różnica ma CI około [0,174; 0,411] punktu. Zdanie „różnica 0,292, CI [3,174; 3,411]” byłoby niejednoznaczne i w typowym odczycie błędne, ponieważ granice należą do innego parametru.

Dla pary dwustronny test t na poziomie 0,05 i odpowiadający mu przedział t 95% mamy zgodność: przedział średniej nie obejmuje 3, a przedział różnicy nie obejmuje zera. Nie przenosimy automatycznie tej reguły na dowolne inne testy i przedziały.

Co oznacza 95%

Poziom ufności jest własnością procedury powtarzanej przy jej założeniach. Nie mówimy, że 95% użytkowników ma indeks pomiędzy 3,174 a 3,411. Rozkład osób jest znacznie szerszy, co było widać na histogramie.

Nie mówimy też, że wszystkie wartości w przedziale są jednakowo prawdopodobne ani że wartości tuż poza nim są niemożliwe. Przedział jest podsumowaniem niepewności zgodnie z konkretną metodą. Ostry podział na „prawdziwe wewnątrz” i „fałszywe na zewnątrz” nie oddaje jego sensu.

Efekt surowy i efekt standaryzowany

Standaryzowany efekt d ma postać:

$$d = \frac{\bar{x} - \mu_0}{s}$$

Wynosi około 0,402, bo różnicę dzielimy przez SD osób, a nie przez SE. To standaryzowany opis wielkości. Statystyka t jest większa, ponieważ w jej mianowniku znajduje się mniejsze SE. Dodatkowo d nie dowodzi związku przyczynowego.

W praktyce pierwsza informacja nadal brzmi „około 0,292 punktu powyżej umownego odniesienia”. Czy to ważne, zależy od celu i jakości pomiaru. Małe p nie zamienia środka skali w standard biblioteki, a standaryzacja nie tworzy procentu kompetencji.

W poprzedniej tabeli efekt surowy miał jednostkę punktów indeksu, a d nie ma jednostki. Wzór t dzieli ten sam licznik przez SE; wzór d przez SD. Dlatego większe N może zmienić t bez zmiany wielkości efektu d . Nie odczytujemy żadnej z tych miar jako procentu osób.

LEARN 4: bootstrap i zmiana znaków mają różne cele

Bootstrap korzysta z posiadanej próby jako empirycznego przybliżenia rozkładu. Losujemy tyle obserwacji, ile było w próbie, ale z powtórzeniami. Potem liczymy średnią; jest ona jedną repliką estymaty, nie nową osobą.

W osobnej małej demonstracji sześć indeksów wynosi 2, 3, 3, 4, 4 i 5. Ich średnia to 3,5. Poniższa przykładowa replika wybiera osoby o numerach 2, 2, 6, 1, 4 i 4; nie zmienia odpowiedzi osoby, tylko liczbę jej wystąpień w tym losowaniu.

```
replika <- pokaz_tabele(jedna_replika, "Jedno losowanie sześciu osób ze zwracaniem")
print(replika)
```

Jedno losowanie sześciu osób ze zwracaniem

miejsce	osoba_zrodlowa	indeks
1	2	3
2	2	3
3	6	5
4	1	2
5	4	4
6	4	4

Replika zawiera wartości 3, 3, 5, 2, 4 i 4, więc jej średnia także wynosi 3,5. To przypadkowa równość w tej demonstracji; inne losowania dają inne średnie. Powtórzenie osoby nie jest duplikatem do usunięcia: w bootstrapie wynika z definicji procedury, inaczej niż w czyszczeniu surowego eksportu.


Nie tasujemy tu sześciu wartości bez powtórzeń, bo zwykle przestawienie kolejności nie zmieniłoby średniej. Słowo „losowanie” trzeba zatem czytać razem z informacją „z powtórzeniami” i z jednostką, którą losujemy.

Wiele replik i przedział bootstrapowy

Dla S02 gotowa funkcja tworzy 1999 replik. Każda obejmuje 147 losowań osób z powtórzeniami i jedną średnią. Poniższy histogram przedstawia rozkład tych średnich, nie histogram indeksów osób.

```
srednie_replik <- pokaz_wykres(wykres_bootstrap)
print(srednie_replik)
```

Bootstrap: niepewność średniej, nie rozkład zerowy



Linia oznacza średnią obserwowaną. Rozkład replik zwykle skupia się w jej pobliżu, a nie obowiązkowo wokół 3. W tej procedurze nie narzuciliśmy hipotezy zerowej. Dlatego samo liczenie, jaka część zwykłych replik leży po jednej stronie odniesienia, nie jest procedurą zmian znaków.

Percentylowy przedział bierze kwantyle 2,5% i 97,5% średnich bootstrapowych. Gotowa tabela pokazuje przedział średniej oraz przesunięty przedział różnicy. Odczytaj ich nazwy przed porównaniem z wynikiem klasycznym.

```
przedzialy_boot <- przedzialy_sredniej(wynik, metoda = "bootstrap")
print(przedzialy_boot)
```

95% CI średniej [pkt]

metoda	estymata	dol	gora
Bootstrap percentylowy	3.2923	3.173	3.4075

95% CI różnicy od odniesienia [pkt]

metoda	estymata	dol	gora
Bootstrap percentylowy	0.2923	0.173	0.4075


Przedział średniej wynosi około [3,173; 3,407], a różnicy [0,173; 0,407]. W tym przykładzie jest podobny do klasycznego. Podobieństwo dotyczy konkretnej próby i metod; nie dowodzi, że każdy bootstrap da poprawny przedział dla dowolnego parametru.

Prosty bootstrap zakłada odpowiednią reprezentację rozkładu i niezależność losowanych jednostek. W małej próbie nie odtworzy nieobserwowanego długiego ogona czasu, a przy danych zależnych trzeba zmienić jednostkę losowania. Więcej replik nie naprawia tych ograniczeń.

Wykres porównuje dwa przedziały tego samego parametru, czyli średniej. Oba punkty znajdują się w tym samym miejscu, bo estymata jest wspólna. Różnią się tylko reguły wyznaczania granic.

```
porownanie_ci <- pokaz_wykres(wykres_ci)
print(porownanie_ci)
```

Ten sam parametr, dwie metody przedziału



Nie nazywamy dłuższego przedziału „gorszym” tylko dlatego, że jest mniej korzystny dla oczekiwanego wniosku. Oceniamy założenia i działanie metody. Wybór metody po obejrzeniu granic byłby kolejną nieujawnioną decyzją analityczną.

Co zmienia procedura znaków

Dla testu zerowego tworzymy odchylenia $d_i = x_i - 3$. Symbol d_i z indeksem osoby oznacza tu pojedyncze odchylenie w punktach; nie jest standaryzowanym efektem d opisującym całą próbę. Pod H_0 i dodatkowym założeniem symetrii znak każdego niezależnego odchylenia można zmienić, zachowując jego bezwzględną wielkość. W każdym losowaniu liczymy średnią tak zmienionych odchyleń.

Nie zmieniamy tutaj kolejności odpowiedzi na pozycje ani nie losujemy nowych indeksów z rozkładu normalnego. Operujemy na odchyleniach osób od odniesienia. W materiale nazywamy to torem permutacyjnym przez zmianę znaków, wskazując dokładnie wykonywane przekształcenie.

Sama hipoteza o średniej równej 3 nie gwarantuje symetrii. Rozkład może mieć dużo małych ujemnych i kilka dużych dodatnich odchyleń, które równoważą się średnią. Prosty test zmian znaków nie ma wtedy automatycznie dokładnego uzasadnienia. Winkler i współautorzy omawiają warunki dopuszczalnych przedstawień; tu najważniejsze jest rozpoznanie różnicy między średnią a symetrią.

Wzór statystyki i skrajności

$$T_{\text{obs}} = \frac{1}{N} \sum_i (x_i - \mu_0), \quad T_b^* = \frac{1}{N} \sum_i s_{ib}(x_i - \mu_0), \quad s_{ib} \in \{-1, +1\}.$$

Obserwowana i przestawiona statystyka mają tę samą definicję: średnia odchyleń. T ma jednostkę punktów. Nie porównujemy więc bezpośrednio przestawionych różnic w punktach z klasycznym t , które nie ma jednostki.

Tabela pokazuje obserwowane T , liczbę skrajnych replik, B oraz p Monte Carlo. Przeczytaj ją razem ze wzorem, a nie jako drugą bezimienną wartość p . W tym przykładzie nie znaleziono skrajnej repliki w 1999 losowaniach.

```
znaki <- test_znakow_sredniej(wynik)
print(znaki)
```

Zmiana znaków: T w punktach, p Monte Carlo

$T_{\text{obserwowane}}$	skrajne	B	p_{MC}
0.2923	0	1999	5e-04

Stosujemy:

$$p_{MC} = \frac{1+k}{B+1}, \quad k = \#\{|T_b^*| \geq |T_{obs}|\}.$$

Dla $k=0$ i $B=1999$ wynik to 0,0005. Nie zapisujemy $p=0$ ani „efekt jest pewny”. Jest to najmniejsza wartość, jaką może zaraportować ten losowany schemat. Uzasadnienie poprawnego liczenia losowanych p rozwijają Phipson i Smyth (2010).

Histogram pokazuje rozkład zerowy różnic. Linie wskazują dodatnią i ujemną granicę skrajności równą bezwzględnej obserwowanej różnicy. Środek tego rozkładu jest bliski zeru z powodu konstrukcji, nie dlatego, że dane osób mają średnią zero.

```
skrajnosc <- pokaz_wykres(wykres_zerowy)
print(skrajnosc)
```



Klasyczne p około 0,0000028 i p Monte Carlo 0,0005 nie są równymi liczbami. Oba są małe w swoich procedurach, lecz wynik losowany ma ograniczoną rozdzielczość i dodatkowe założenie symetrii. Nie wyciągamy z ilorazu tych liczb wniosku, że jedna metoda „daje dwieście razy słabszy efekt”. Efekt w punktach jest nadal ten sam.

Gdy p znajduje się blisko umownego progu

W innym zbiorze wynik klasyczny i wynik Monte Carlo mogą znaleźć się po różnych stronach 0,05 albo jeden może wypaść dokładnie na tej granicy. Nie oznacza to, że jedna procedura odkryła efekt, a druga udowodniła jego brak. Porównaj estymatę, przedział, założenia i dokładność losowania. Mała zmiana p nie jest nagłą zmianą badanego zjawiska.

Jeżeli zapisujesz warunek „ $p < 0,05$ ”, równość 0,05 go nie spełnia. Nie zmieniaj znaku nierówności ani ziarna losowania po zobaczeniu wyniku. Podaj uzyskaną wartość p i wyjaśnij, że znajduje się przy umownym progu. Przy $B=1999$ losowe przybliżenie udziału około 0,05 ma orientacyjne SE około 0,0049; nie należy traktować czwartego miejsca po przecinku jako niepodważalnego rozstrzygnięcia.

Trzy rozkłady, które trzeba umieć nazwać

Obraz	Jeden element oznacza	Środek i pytanie
Histogram danych	Indeks osoby	Jak zróżnicowani są respondenci?
Histogram bootstrapu	Średnią repliki z powtórzeniami	Jak zmienia się estymata?
Histogram zerowy	Statystykę po dopuszczalnej zmianie znaków	Jak skrajny jest wynik przy modelu zerowym?

Wszystkie trzy mogą mieć podobny wizualnie kształt, ale nie wolno przekładać osi między nimi. Szerokość histogramu osób jest związana z SD, szerokość bootstrapowych średnich z niepewnością estymacji, a położenie obserwowanej statystyki na tle rozkładu zerowego służy obliczeniu p.

Samokontrola: ktoś pokazuje histogram z 1999 wartościami i mówi, że przebadano 1999 użytkowników. Jak rozpoznać błąd? Sprawdź, czy wartości są indeksami osób, średnimi replik czy statystykami zerowymi. Liczba punktów wygenerowanych przez komputer nie mówi, ilu niezależnych ludzi dostarczyło informacji.

Druga osoba mówi: „bootstrap ma średnią około 3,29, więc hipoteza zerowa musi mieć średnią 3,29”. To pomylenie celu procedur. Zwykły bootstrap odtwarza informację z zaobserwowanej próby, a test zerowy buduje inny rozkład odniesienia. Nazwanie rozkładu jest pierwszym krokiem do poprawnego odczytu.

LEARN 5: od wyniku do pełnego opisu badania

Przed wzorcowym akapitem zestawiamy wynik klasyczny, losowany oraz efekt z przedziałami. Każda tabela zachowuje nazwę parametru i metody. Odszukaj w niej liczby użyte w opisie, zamiast traktować akapit jako formułkę do przepisania.

```
raport <- podsumowanie_sredniej(wynik)
print(raport)
```

Efekt i N

N	roznica	d
147	0.2923	0.4021

Wynik klasyczny

t	df	p
4.8756	146	<1e-04

Wynik zmian znaków

T_obserwowane	skrajne	B	p_MC
0.2923	0	1999	5e-04

95% CI średniej [pkt]

metoda	estymata	dol	gora
t	3.2923	3.1738	3.4108
Bootstrap percentylowy	3.2923	3.1730	3.4075

95% CI różnicy od odniesienia [pkt]

metoda	estymata	dol	gora
t	0.2923	0.1738	0.4108
Bootstrap percentylowy	0.2923	0.1730	0.4075

Przykładowe akapity dla S02

W warstwie liczbowej możemy napisać: „Dla 147 ważnych indeksów średnia wyniosła 3,292 punktu (SD=0,727). Różnica od umownego odniesienia 3 wyniosła 0,292 punktu, z klasycznym 95% CI [0,174; 0,411]. Test t dał $t(146)=4,876$, $p<0,001$, a $d=0,402$ ”.

W drugiej części dodajemy metodę losowania: „Percentylowy bootstrap dał dla tej różnicy CI [0,173; 0,407]. W 1999 losowych zmianach znaków nie uzyskano równie skrajnej różnicy, stąd p Monte Carlo=0,0005 według użytej reguły. Odczyt tego testu wymaga dodatkowego założenia symetrii odchyleń pod H_0 ”.

W warstwie badawczej wynik oznacza przesunięcie średniej w stronę korzystnej deklaracji względem środka skali. Nie dowodzi wysokiej kompetencji, skuteczności wszystkich osób ani poprawy wywołanej interwencją. Dane są syntetyczne, a indeks dydaktyczny. Punkt odniesienia nie stanowi zwalidowanego progu decyzji.

Nie musisz umieszczać wszystkich liczb w jednym długim zdaniu. Dwa krótkie akapity z jasno nazwanymi przedziałami są czytelniejsze. Nie wolno jednak pominąć parametru przedziału, znaku różnicy lub warunku procedury tylko po to, by skrócić tekst.

Zero i próg praktyczny to nie to samo

Załóżmy wyłącznie na potrzeby dyskusji, że zespół uważa różnicę 0,20 punktu za wartą dalszej uwagi. Nie jest to norma dla tego indeksu, tylko hipotetyczna preferencja decydenta. Nasz przedział różnicy od około 0,174 do 0,411 leży powyżej zera, ale obejmuje wartości zarówno poniżej, jak i powyżej 0,20.

Nie można więc zamienić zdania „wykluczono zerową różnicę w odpowiadającej procedurze” na „wykazano przekroczenie progu 0,20”. To dwa twierdzenia o różnych granicach. Oszacowanie 0,292 jest powyżej progu, lecz jego niepewność obejmuje też mniejsze wartości.

Pytanie decydenta	Co w tym przykładzie czytamy?
Czy punktowe oszacowanie jest dodatnie?	Tak: około 0,292 punktu
Czy klasyczny CI obejmuje zero?	Nie: oba końce są dodatnie
Czy cały CI leży powyżej umownego 0,20?	Nie: dolna granica wynosi około 0,174
Czy wiemy, że zmiana katalogu spowodowała efekt?	Nie: nie badaliśmy tutaj takiej interwencji

Ta tabela pokazuje, dlaczego odpowiedź statystyczna powinna być dopasowana do decyzji. Można rekomendować dalsze sprawdzenie konkretnego elementu usługi, ale nie przedstawiać tego jako skutku udowodnionego przez test jednej średniej. W raporcie oddzielamy opis danych, interpretację modelową i rekomendację.

CHALLENGE — samodzielna interpretacja oceny portalu

Uzupełnij pięć pól odpowiedzi krótkimi akapitami. Pisz pod wynikami poza blokami R, zastępując znaczniki. Odczytaj liczby z portalu, nie ze wspólnego S02; gotowa funkcja oblicza wyniki, ale nie pisze za Ciebie wniosku.

Scenariusz portalu i umownego odniesienia

Portal studencki oceniono sześcioma pozycjami dotyczącymi deklarowanej przejrzystości procedur. Po ukierunkowaniu pozycji i regule minimum 5/6 uzyskano indeksy 1–5; dla jednej z 25 osób indeks jest niedostępny. To osobna syntetyczna demonstracja, a nie kolejny pomiar tych samych osób z katalogu.

Przed analizą ustalono pytanie o różnicę średniej od umownego odniesienia 3 oraz dwustronny test. Dodatkowo opiekun wskazał 3,5 jako hipotetyczny cel użytkowy. Ani punkt środkowy skali, ani ten cel nie są zwalidowaną granicą kompetencji. Nie zmieniaj odniesienia po zobaczeniu p.

CHALLENGE 1: Jaka wielkość oszacowano?

Zacznij od określenia populacyjnej wielkości i jej próbnego odpowiednika. Indeks jest średnią pozycji dotyczącą deklaracji, nie obserwowanym czasem. Brak indeksu wpływa na N analizy.

Blok wyświetla opis wyników portalu. Znajdź liczebność, braki i obie miary zmienności. Odczytaj wzór SE ze znaczeniem symboli, nie tylko wartość liczbową.

```
opis_portalu <- opis_sredniej(portal_wynik)
print(opis_portalu)
```

Osoby, średnia, niepewność i efekt

wielkosc	wartosc
N	24
braki	1
srednia	3.3125
SD	0.7042
SE	0.1437
odniesienie	3
roznica	0.3125
d	0.4438

Napisz krótki akapit: nazwij estymandę, podaj N osób i ważnych indeksów, średnią, SD, SE oraz różnicę od 3. Wyjaśnij słownie wzór SE oraz wskaż, którą z tych liczb opisujesz jako efekt w punktach.

[UZUPELNIJ_S01]

CHALLENGE 2: Odczytaj przedziały, nie tylko końce

Klasyczny przedział opiera się na rozkładzie t, a bootstrapowy na empirycznych percentylach replik. Oba próbują opisać niepewność tej samej średniej. Ich podobieństwo nie dowodzi reprezentatywności danych.

Tabela zawiera też przedziały różnicy od odniesienia. Na wykresie pokazano wyłącznie średnią. Sprawdź, do którego parametru odnosi się każda liczba w odpowiedzi.


```
przedzialy_portalu <- przedzialy_portalu_do_raportu()
print(przedzialy_portalu)
```

95% CI średniej [pkt]

metoda	estymata	dol	gora
t	3.3125	3.0151	3.6099
Bootstrap percentylowy	3.3125	3.0208	3.5833

95% CI różnicy od odniesienia [pkt]

metoda	estymata	dol	gora
t	0.3125	0.0151	0.6099
Bootstrap percentylowy	0.3125	0.0208	0.5833



Napisz krótki akapit: podaj obydwa 95% CI średniej i klasyczny CI różnicy. Popraw zdanie „95% studentów ma wynik w tym przedziale” i skomentuj precyzję oszacowania.

[UZUPELNIJ_S02]

CHALLENGE 3: Dwa testy i ich założenia

Test t sprawdza hipotezę o średniej, a procedura zmiany znaków potrzebuje symetrycznego modelu odchyleń pod H_0 . Nie traktujemy ich jako dwóch niezależnych badań. Obydwie korzystają z tych samych ważnych indeksów.

Odczytaj statystyki i p obu procedur. Przy Monte Carlo zapisz B oraz sposób liczenia skrajności dwustronnej. Wniosek musi wynikać z otrzymanych liczb, nie z oczekiwania istotności.

```
testy_portalu <- dwa_testy_sredniej(portal_wynik)
print(testy_portalu)
```

Dwustronny test t

t	df	p
2.1739	23	0.0403

Losowe zmiany znaków

T_obserwowane	skrajne	B	p_MC
0.3125	99	1999	0.05

Napisz krótki akapit: podaj H_0 , t , df , p , obserwowane T , B i p_{MC} . Wyjaśnij znaczenie p oraz warunek, bez którego zmiany znaków nie mają deklarowanego uzasadnienia.

[UZUPELNIJ_S03]


CHALLENGE 4: Wyniki osób, średnie replik i świat zerowy

Na dwóch wykresach nie ma rozkładu indywidualnych ocen. Pierwszy przedstawia średnie losowanych ze zwracaniem prób, drugi statystyki po zmianie znaków. Inne osie odpowiadają innym pytaniom.

Porównaj położenie histogramów z wynikiem CHALLENGE 1. Odczytaj, gdzie znajduje się obserwowany efekt na wykresie zerowym. Nie nazywaj 1999 replik liczbą uczestników.

```
rozklady_portalu <- rozklady_portalu_do_odczytu()
print(rozklady_portalu)
```

Bootstrap: losowanie osób ze zwracaniem



Model zerowy przy symetrii odchyleń



Napisz krótki akapit: opisz, co stanowi jedną wartość na każdym wykresie i jak powstała. Odróżnij N osób od B replik oraz wyjaśnij, który rozkład służy przedziałowi, a który ocenie skrajności.

[UZUPELNIJ_S04]

CHALLENGE 5: Czy portal spełnia cel 3,5?

Wynik testu wobec 3 nie jest automatycznie odpowiedzią na pytanie o osiągnięcie 3,5. Opiekun oczekuje wniosku o znaczeniu użytkowym, nie samej etykiety „istotne”. Masz też pamiętać o syntetyczności i wąskim znaczeniu indeksu.

Tabela ponownie pokazuje efekt oraz przedział średniej, aby wniosek był obok swojego dowodu. Porównaj cały zakres z obydwoimi odniesieniami. Nie zamieniaj tego porównania w nowy, dobrany po wyniku test.

```
wniosek_portalu <- efekt_i_cel_portalu()
print(wniosek_portalu)
```

Średnia i efekt od 3 [pkt]; d standaryzowane

srednia	odniesienie	roznica	d
3.3125	3	0.3125	0.4438

95% CI średniej względem odniesień 3 i 3,5

metoda	estymata	dol	gora
t	3.3125	3.0151	3.6099
Bootstrap percentylowy	3.3125	3.0208	3.5833

Napisz krótki akapit: odpowiedz osobno na pytanie o różnicę od 3 i o cel 3,5, wykorzystując efekt w punktach, d, przedział i wyniki CHALLENGE 3. Dodaj ograniczenie pomiaru oraz próby; nie formułuj rzeczywistej rekomendacji wdrożeniowej na podstawie symulacji.

[UZUPELNIJ_S05]

Zapis i oddanie

Sprawdź pięć własnych odpowiedzi. Przy każdym przedziale nazwij parametr, przy p procedurę, a przy efekcie kierunek i jednostkę. Zapisz ten Rmd w edytorze.

W konsoli wykonaj jedno polecenie. Funkcja oddania tworzy PDF z zapisanej pracy, sprawdza kompletność i wysyła go wraz z Rmd oraz `analiza.R` do Twojego prywatnego repozytorium z dostępem prowadzącego.

```
oddaj_zadanie("Z05")
```

Odczytaj potwierdzenie odbioru i SHA. Jeśli pojawi się błąd, popraw wskazany problem, zapisz plik i ponownie wywołaj tę samą funkcję. Nie przepisyjesz odpowiedzi do Markdown ani nie uruchamiasz osobno renderowania.

Po potwierdzonym oddaniu wykonaj w konsoli `wyloguj_github()`. Na komputerze współdzielonym wyloguj także przeglądarkę i zamknij RStudio bez zachowywania `.RData`. Przy braku sieci zachowaj źródła przed czyszczeniem komputera i poproś prowadzącego o pomoc.

Rubryka

Kryterium	Dowód rozumienia	Punkty
Z05.1	Właściwe N, estymata, przedział i poziom ufności	3
Z05.2	Bootstrap i zmiana znaków: odmienny cel oraz B	2
Z05.3	Oba tory, efekt, CI, t, df i p wraz z objaśnieniem	3
Z05.4	Precyzja, znaczenie praktyczne i ograniczenie próby	2

Wynik nieistotny nie obniża punktacji. Oceniane są poprawny odczyt, uzasadnienie i granice wniosku, a nie uzyskanie pożądanego p. Własny akapit jest częścią oddawanej pracy, nie dodatkiem wykonywanym tylko w myślach.

Rozwinięcia do powtórki — poza rdzeniem spotkania

Te przykłady pomagają dokładniej zrozumieć losowanie, dobór odniesienia i ograniczenia wnioskowania. Nie wymagają dodatkowych pól odpowiedzi ani kolejnego pliku do oddania.

Widzimy wszystkie możliwe znaki

W małej demonstracji trzy wartości indeksu wynoszą 2, 4 i 5, a odniesienie nadal 3. Odchylenia to -1 , 1 i 2 . Obserwowana średnia odchyłeń wynosi $2/3$ punktu. Dla trzech odchyłeń istnieje $2^3 = 8$ kombinacji znaków.

Tabela pokazuje wszystkie kombinacje, łącznie z układem obserwowanym. Kolumny z1–z3 wskazują mnożniki pierwotnych odchyłeń. Ostatnia kolumna mówi, czy bezwzględne T jest co najmniej tak duże jak obserwowane.

```
pelny_zbior <- pokaz_tabele(wszystkie_znaki, "Osiem układów znaków")
print(pelny_zbior)
```

Osiem układów znaków

z1	z2	z3	T	skrajne
-1	-1	-1	-0.667	TRUE
1	-1	-1	-1.333	TRUE
-1	1	-1	0.000	FALSE
1	1	-1	-0.667	TRUE
-1	-1	1	0.667	TRUE
1	-1	1	0.000	FALSE
-1	1	1	1.333	TRUE
1	1	1	0.667	TRUE

Sześć z ośmiu układów jest co najmniej tak skrajnych, więc dokładne p dla tego wyliczenia wynosi $6/8 = 0,75$. Tu nie dopisujemy korekty $+1$ do licznika i mianownika, ponieważ uwzględniliśmy całą przestrzeń równoprawdopodobnych układów, w tym obserwowany. Wzór z $+1$ dotyczył omawianego wcześniej schematu losowego pobierania przestawień.

Równe wartości T mogą pochodzić z różnych układów znaków. Nie usuwamy ich jako duplikatów, bo każdy układ jest częścią przestrzeni przestawień. Usunięcie powtarzających się statystyk zmieniłoby ich wagi, a zatem obliczane p .

Ten przykład ma dodatnią estymatę, ale duże p . Nie ma sprzeczności: różnica w próbie oraz jej skrajność pod modelem zerowym to dwie rzeczy. Małe N i dyskretna liczba układów ograniczają to, czego możemy dowiedzieć się z testu. Założenie symetrii pozostaje konieczne mimo pełnego wyliczenia.

Więcej losowań i więcej osób to różne decyzje

B steruje dokładnością komputerowego przybliżenia. N steruje ilością niezależnej informacji badawczej, jeśli projekt rzeczywiście dostarcza niezależnych jednostek. Nie zastępujemy jednej liczby drugą.

Tabela pokazuje najmniejsze raportowane p oraz orientacyjny błąd standardowy udziału skrajnych losowań przy p bliskim 0,05. Drugą wielkość przybliżamy wzorem $\sqrt{p(1-p)/B}$. To opis zmienności Monte Carlo, nie SE średniej indeksu.

```
dokladnosc <- dokladnosc_losowania()
print(dokladnosc)
```

Dokładność Monte Carlo, nie liczba osób

B	Najmniejsze p	Przybliżone SE udziału przy $p=0,05$
199	5e-03	0.01545
1999	5e-04	0.00487
19999	5e-05	0.00154

Przy $B=1999$ orientacyjne SE udziału bliskiego 0,05 wynosi około 0,0049. Wynik w pobliżu progu może się nieco zmieniać między ziarnami. W takiej sytuacji można zwiększyć B według jawnej reguły i opisać niepewność obliczenia. Nie wolno uruchamiać analizy do pierwszego korzystnego rezultatu i ukrywać wcześniejszych.

Ustawienie ziarna pozwala odtworzyć konkretny ciąg losowań. Nie powoduje, że losowanie staje się prawdziwsze ani że p przestaje być obarczone przybliżeniem. Ta sama próbka analizowana z milionem replik nadal ma te same ograniczenia doboru, pomiaru i N .

Zarówno S02, jak i portal w CHALLENGE używają $B=1999$. W innych analizach ta liczba może być inna, dlatego odczytuj ją z wyniku. Minimalne p zależy od schematu losowania, nie od samej nazwy testu.

Stały efekt i zmieniająca się liczebność

Wyobraźmy sobie trzy odrębne hipotetyczne badania ze średnią 3,2, $SD=0,8$ i odniesieniem 3. Nie kopiujemy tych samych osób, aby powiększyć próbę; rozważamy trzy zestawy statystyk opisowych z różnych

N. Naturalny efekt 0,2 punktu oraz $d=0,25$ są takie same.

Tabela zmienia tylko liczebność w rachunku t. Przeczytaj, co pozostaje stałe, a co zmniejsza się lub rośnie. W ostatniej kolumnie małe p jest formatowane tak, by nie pojawiło się mylące zero.

```
liczebosc <- efekt_i_liczebosc()
print(liczebosc)
```

Ten sam efekt, różne liczebności

N	roznica	d	SE	t	df	p
25	0.2	0.25	0.16	1.25	24	0.2234
100	0.2	0.25	0.08	2.50	99	0.0141
400	0.2	0.25	0.04	5.00	399	<1e-04

SE maleje, t rośnie i p maleje wraz ze wzrostem N. Nie wynika z tego, że efekt stał się większy. Wynik jest bardziej precyzyjny przy tej samej założonej wielkości różnicy.

Odwrotna pułapka pojawia się przy małej próbie: duży efekt może mieć szeroki przedział i nie przekroczyć progu istotności. Dlatego zdanie „w pierwszym badaniu efekt wystąpił, a w drugim nie” na podstawie samych dwóch p jest niewystarczające. Do porównania efektów potrzebne jest odpowiednie porównanie ich wielkości i niepewności.

Jeżeli osoba prowadząca bibliotekę pyta o użyteczność zmiany, pokaż najpierw punkty lub minuty oraz zakres zgodnych wartości. Dopiero potem wyjaśnij wynik testu. Kolejność opisu pomaga uniknąć utożsamienia dużej liczby obserwacji z dużą korzyścią.

Punkt odniesienia nie może być wybierany dla wyniku

Ten sam zbiór można porównać z różnymi wartościami. To nie znaczy, że wszystkie odpowiadają pierwotnemu pytaniu. Punkt 3 oznacza środek skali, 3,5 mógłby oznaczać umowny cel instytucji, a historyczna średnia innego badania wymagałaby uwzględnienia jej własnej niepewności.

Poniższa demonstracja używa tego samego S02 przy trzech z góry pokazanych odniesieniach. Przedział średniej pozostaje ten sam. Różnica, t i p zmieniają się, ponieważ testowane twierdzenie jest inne.

```
odniesienia <- zmiana_odniesienia()
print(odniesienia)
```

Niezmieniony 95% CI średniej

Dolna granica	Górna granica
3.1738	3.4108

Różne pytania zerowe

odniesienie	roznica	t	p
3.0	0.2923	4.8756	< 1e-04
3.2	0.0923	1.5395	0.125856
3.5	-0.2077	-3.4647	0.000697

Nie jest to instrukcja szukania najlepszego odniesienia. To ostrzeżenie: można łatwo zmienić odpowiedź przez zmianę pytania. W Z05 przy indeksie stosujemy 3 i opisujemy umowność. Ewentualne inne odniesienie wymaga uzasadnionego polecenia, a nie dopasowania do tabeli.

Jeśli odniesienie jest średnią oszacowaną w innej próbie, traktowanie go jak znanej stałej pomija jej błąd. Wtedy problem może wymagać porównania dwóch grup lub dwóch oszacowań. C06 rozszerzy rachunek o niepewność po obu stronach różnicy.

Gdy interesuje nas powodzenie, zmienia się estymanda

W osobnym przykładzie 26 z 40 osób znajduje dokument. Estymata proporcji wynosi 0,65, czyli 65%. Porównanie z umownym 50% dotyczy parametru π , prawdopodobieństwa powodzenia w zdefiniowanym modelu, a nie średniej indeksu.

Poniżej gotowy dokładny test dwumianowy pokazuje proporcję i przedział. Nie zastępujemy nim Z05, ponieważ zadanie główne dotyczy średniej. Przykład uczy rozpoznawać, kiedy problem wymaga innej definicji wyniku.

```
proporcja <- przyklad_proporcji_do_raportu()
print(proporcja)
```

Odrębne pytanie o proporcję: dokładny test dwumianowy

wielkosc	wartosc
sukcesy	26
N	40
proporcja	0.65
odniesienie	0.5
CI_dol	0.4832
CI_gora	0.7937
p	0.0807

Proporcja 0,65 ma przedział około [0,483; 0,794], a p około 0,081. Liczba 65% opisuje próbę; przedział wyraża niepewność proporcji populacyjnej przy modelu niezależnych prób Bernoulliego. Nie jest zakresem, w którym znajdują się wyniki 95% osób, ponieważ wynik osoby ma tylko wartości 0 i 1.

Nieodrzućenie odniesienia 50% nie dowodzi równości. Jednocześnie nie wolno twierdzić, że skuteczność wynosi dokładnie 65% w całej populacji. Tak jak przy średniej potrzebujemy wielkości, niepewności i warunków.

Dla tego problemu można symulować liczbę sukcesów z modelu dwumianowego przy $\pi_0 = 0,5$. Byłaby to symulacja parametrycznego modelu zerowego, nie przedstawianie niezmiennionej listy zer i jedynek. Samo przetasowanie tej listy nie zmieniłoby proporcji. To kolejny przykład, dlatego nazwa „Monte Carlo” nie wystarcza do określenia metody.

Warsztat redakcyjny: pięć błędnych wniosków

„Z prawdopodobieństwem 95% osoby mają średnią w tym zakresie”

W tym zdaniu połączono osoby, średnią i poziom ufności. Trzeba ustalić, czy mówimy o parametrze średniej, czy o rozkładzie indywidualnych wyników. Poprawny opis brzmi: „95% przedział dla średniej wynosi...; poziom odnosi się do procedury jego konstrukcji przy założeniach”.

Jeśli potrzebujemy opisu osób, wracamy do SD, kwantyli i histogramu. Jeśli chcemy przewidywać nową osobę, potrzebujemy odpowiedniego przedziału predykcji. Jedna para granic nie odpowiada na wszystkie trzy pytania.

„P<0,001 dowodzi wysokich kompetencji”

Test dotyczył średniej indeksu względem 3, a nie całej kompetencji cyfrowej. Nawet bardzo małe p nie poszerza treści pozycji. Poprawiona wersja mówi o średniej deklarowanej użyteczności według zastosowanego pomiaru i o różnicy od umownego odniesienia.

Do wniosku o kompetencjach potrzebny byłby adekwatny pomiar oraz dowody jego interpretacji. Do wniosku o skutku poprawy katalogu potrzebny byłby odpowiedni projekt porównawczy. Test jednej średniej nie dostarcza tych elementów.

„Bootstrap potwierdził hipotezę, bo większość średnich jest powyżej trzech”

Zwykły bootstrap skupia się wokół informacji z próby. Nie jest tym samym co rozkład zerowy. Można opisać bootstrapowy przedział i jego relację do odniesienia, ale trzeba nazwać procedurę, parametr i

ograniczenia, a nie traktować udziału replik jako prawdopodobieństwa hipotezy.

Poprawa nie polega na zamianie słowa „potwierdził” na „udowodnił”. Trzeba przestawić argument: jaka jest estymata, jaką niepewność pokazuje metoda i czego nie testuje dany histogram.

„Permutacja nie ma założeń, więc zawsze jest ważniejsza”

W naszym teście jednej próby potrzeba symetrii i niezależności odchyleń dla dokładnego uzasadnienia. Przy skośnym czasie sama równość średniej do odniesienia nie wystarcza. Brak założenia normalności nie oznacza braku wszelkich warunków.

Poprawiony opis wskazuje, co zmieniano i dlaczego takie przedstawienia miałyby być dopuszczalne pod H_0 . Jeśli warunek budzi wątpliwość, wynik można przedstawić jako demonstrację lub analizę pod dodatkowym modelem, nie jako bezwarunkowe rozstrzygnięcie.

„Dwa p są małe, więc ograniczenia próby nie mają znaczenia”

Obie procedury korzystają z tych samych danych i mogą dzielić ten sam problem doboru lub pomiaru. Zgodność nie jest niezależną replikacją badania. Nie usuwa nieodpowiedzi ani pominięcia osób, którym usługa sprawiała największą trudność.

Lepsze zdanie oddziela dwa poziomy: „Wyniki obu procedur przy ich założeniach wskazują na odchylenie od odniesienia; zakres uogólnienia ogranicza projekt i jakość pomiaru”. Nie ukrywamy ograniczeń za zgodnością obliczeń.

Średnia równa odniesieniu nie zapewnia symetrii

Rozważmy osobną demonstrację czasu: dziewięć osób kończy po 9 minutach, jedna po 19. Suma wynosi 100, a średnia 10 minut. Względem odniesienia 10 mamy dziewięć odchyleń -1 i jedno $+9$. Średnia odchyleń jest zerowa, ale ich rozkład wyraźnie nie jest symetryczny.

To mały przykład logiczny, nie test symetrii populacji. Pokazuje, że warunek „średnia równa 10” i warunek symetrycznych odchyleń znaczą różne rzeczy. Gdyby taki mechanizm kształtował populację czasów, proste niezależne zmiany znaków tworzyłyby również duże ujemne odchylenia, które nie odpowiadają temu mechanizmowi.

Nie rozwiązujemy problemu przez usunięcie osoby z czasem 19. To mogła być prawidłowa, ważna próba ujawniająca trudność usługi. Nie przechodzimy też automatycznie na medianę, jeśli pytanie dotyczyło średniego nakładu czasu. Zmiana parametru wymaga zmiany pytania i wyraźnego opisu.

Gdyby pytanie dotyczyło czasu zamiast indeksu, trzeba byłoby szczególnie ostrożnie odczytać tor zmian znaków. Można pokazać działanie algorytmu pod dodatkowym założeniem, ale nie ogłaszać, że rozwiązuje on problem dowolnej skośności. W rzeczywistym badaniu należałoby rozważyć metodę dopasowaną do celu i rozkładu, a nie wybrać procedurę wyłącznie według p .

Niezależność jest własnością projektu

Inny zespół bada 15 osób, z których każda wykonuje dziesięć zapytań. W arkuszu ma 150 wierszy i używa wzoru SE z $N=150$. Czy uzyskał dokładność odpowiadającą stu pięćdziesięciu osobom? Niekoniecznie: czasy tej samej osoby mogą być podobne z powodu jej umiejętności, sprzętu i sposobu pracy.

Samo sprawdzenie histogramu nie ujawni całej zależności. Potrzebujemy identyfikatora osoby i informacji o zadaniach. Można na przykład zdefiniować wynik osoby jako średni czas określonego zestawu albo zastosować model uwzględniający powtórzenia. Te wybory odpowiadają różnym celom i nie powinny być wykonywane automatycznie.

W kursowym S02 jednostkę określa scenariusz, a identyczne duplikaty usuwa jawna reguła. Nie zwiększamy N przez kopiowanie rekordów. Bootstrap osób i zmiany znaków mają sens dopiero po ustaleniu tej jednostki; poprawny kod losowania przy błędnym N nadal daje niewłaściwie uzasadnione wnioskowanie.

Co warto zapisać przed uruchomieniem testu

W krótkiej notatce analitycznej warto zapisać nazwę zmiennej, estymandę, odniesienie, kierunek odejmowania, regułę braków i powód zastosowania procedury. Dodaj poziom ufności oraz to, które porównanie

jest główne. Taka notatka nie musi być rozbudowanym dokumentem, aby ograniczać pokusę zmiany pytania po wyniku.

Po obliczeniu warto dopisać, czy zauważono odstępstwa lub dodatkowe analizy. Nie usuwaj wcześniejszego planu, aby pasował do rezultatu. Jeśli eksploracja ujawni ciekawy wzorzec, nazwij go eksploracyjnym i wskaż, jakie nowe badanie pozwoliłoby go sprawdzić. Uczciwa granica wniosku jest częścią kompetencji statystycznej, nie oznaką słabego raportu.

Na C06 porównamy dwie grupy użytkowników. Zamiast znanej stałej po drugiej stronie różnicy pojawi się druga oszacowana średnia. Pozostanie ta sama zasada: najpierw zdefiniuj kierunek i jednostkę efektu, potem czytaj niepewność, statystykę oraz warunki testu.