

W02 — Opis danych, jakość i pomiar ankietowy

Zarządzanie informacją — część ilościowa — 2026/27

Marek Deja

2026/27

Spis treści

Opis, który zachowuje znaczenie pomiaru	1
Organizacja odpowiedzi i jakość	2
Szeregi statystyczne	2
Histogram i wybór klas	2
Miary położenia	3
Średnia	3
Mediana	3
Moda, kwartyle i percentyle	3
Miary zróżnicowania	3
Wariancja i odchylenie standardowe	3
IQR i względne zróżnicowanie	4
Kształt rozkładu i asymetria	4
Pomiar samooceny, akceptacji i dystansu	4
Pozycje typu Likerta i skala złożona	5
Dystans społeczny Bogardusa	5
Skala kumulatywna Guttmana	5
Podejście Thurstona	5
Transformacja, agregacja i arkusz	6
Pytania do dyskusji	6

Opis, który zachowuje znaczenie pomiaru

Otrzymana tabela ankiety nie mówi sama, jaki wynik jest typowy, z ilu odpowiedzi pochodzi ani czy opis pasuje do skali. Czas, pojedyncza pozycja postawy i indeks wymagają różnych decyzji. Na tym wykładzie przechodzimy od organizacji danych przez miary położenia, rozproszenia i asymetrii do interpretacji pomiaru ankietowego. Obliczenia importu oraz opisu rozwijają C02–C04.

Układ 90 minut: 10 minut jednostek i jakości, 15 minut szeregów/mianowników, 20 minut miar położenia oraz zróżnicowania, 15 minut kształtu i wykresów, 20 minut pomiaru postaw, 10 minut transformacji i pytań. Rozkłady teoretyczne i prawdopodobieństwo rozwija W03. Wykład nie wymaga opanowania wszystkich funkcji R; przykłady można odczytać z gotowego HTML/PDF.

Organizacja odpowiedzi i jakość

W tabeli ankietowej jeden wiersz jest odpowiedzią jednej osoby, a kolumny są zmiennymi. Słownik ustala znaczenie, skalę, jednostki i kody. Manifest identyfikuje wariant, a dziennik czyszczenia zapisuje reguły i ich skutki. Nie zmieniamy surowego pliku na podstawie oczekiwanych wyników testu.

Brak odpowiedzi nie jest zerem, a „nie dotyczy” nie jest oceną neutralną. Identyczne kopie wierszy zwiększają N pozornie; sprzeczne odpowiedzi o tym samym ID wymagają wyjaśnienia. Obserwacja odstająca może być błędem albo prawidłowym rzadkim doświadczeniem. Przed usunięciem sprawdź zakres, źródło i jednostkę; sam boxplot nie rozstrzyga.

Załóżmy, że czas 120 sekund wpisano do kolumny minut. Poprawna konwersja daje 2 minuty, a nie brak. Jeżeli nie można ustalić jednostki z dokumentacji, nie zgaduj na podstawie tego, jaki wynik pasuje do średniej. Utrzymuj kopię danych, jawny kod i dziennik. Przy różnych regułach braków opisz również, jak zmienia się N używane w poszczególnych tabelach.

Szeregi statystyczne

Zanim przystąpimy do obliczeń, musimy uporządkować zebrane dane. W statystyce służą do tego **szeregi statystyczne** — uporządkowane zestawienia wartości zmiennej wraz z informacją o częstości ich występowania.

Szereg punktowy zestawia pojedyncze wartości lub kategorie i ich liczebności, np. odpowiedzi 1–5. Szereg przedziałowy grupuje liczbowe pomiary w klasy, np. 0–5, 5–10, 10–15 minut. Granice klas muszą jasno określać, do którego przedziału należy wartość na granicy. Szereg czasowy porządkuje obserwacje według kolejnych okresów; czas jako zmienna w jednej ankiecie nie tworzy automatycznie szeregu czasowego.

Zachowujemy mały wektor trzydziestu ocen, aby sprawdzić liczebności ręcznie. `factor(..., levels=1:5)` pokazuje również kategorię bez wskazań. Odczytaj sumę liczebności i mianownik procentów, a nie tylko najczęstszą ocenę.

```
oceny <- c(4, 5, 3, 4, 5, 4, 3, 5, 4, 4, 5, 3, 4, 4, 5,
           2, 4, 5, 4, 3, 4, 5, 4, 4, 5, 4, 3, 4, 5, 4)
tab <- table(factor(oceny, levels = 1:5))
data.frame(ocena = names(tab), n = as.integer(tab),
            procent_waznych = as.numeric(100 * prop.table(tab)))
```

```
##  ocena  n procent_waznych
## 1     1  0          0.000000
## 2     2  1          3.333333
## 3     3  5         16.666667
## 4     4 15         50.000000
## 5     5  9         30.000000
```

W pytaniu jednokrotnego wyboru procenty ważnych, rozłącznych odpowiedzi sumują się do 100. W wielokrotnym wyborze jedna osoba może zaznaczyć kilka opcji, więc procenty respondentów mogą przekroczyć 100. Gdy zamiast respondentów mianownikiem są wszystkie wskazania, otrzymujemy inny wskaźnik. Nazwa „procent” bez mianownika jest niewystarczająca.

Histogram i wybór klas

Histogram przedstawia szereg przedziałowy. Przy równych szerokościach wysokość może oznaczać liczebność; przy gęstości pole słupka odpowiada udziałowi w przedziale. Wartość gęstości w punkcie nie jest odsetkiem osób. Zbyt szerokie klasy mogą ukryć dwa skupienia, a zbyt wąskie pokazać przypadkowy szum. Dobór klas pomaga czytaniu, ale nie powinien służyć do podkreślenia oczekiwanego wyniku.

Miary położenia

Średnia

Średnia arytmetyczna to suma wartości podzielona przez liczbę ważnych obserwacji: $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$. x_i oznacza wartość osoby i , n liczbę znanych wartości, a $\bar{x}$ średnią z próby. Średnią populacji oznaczamy μ , a jej liczebność N . Oba wyniki mają jednostkę zmiennej, np. minuty.

Każda obserwacja ma równą wagę, lecz duża wartość może mocno zmienić wynik. Dla czasów 2, 3, 4, 5, 36 minut średnia wynosi 10 minut; żadna osoba nie podała 10. Średnia jest poprawnym podsumowaniem, lecz może słabo opisywać doświadczenie typowej osoby w skośnym rozkładzie. Nie zastępuj jej interpretacją samym określeniem „przeciętnie”.

Mediana

Mediana to wartość dzieląca uporządkowany zbiór danych na dwie równe części. Jest to miara **odporna** na wartości odstające.

Najpierw porządkujemy wartości. Dla nieparzystego n mediana jest środkowym elementem, a dla parzystego R uśrednia dwa środkowe pomiary liczbowe. W powyższym przykładzie wynosi 4 minuty. Dla kategorii porządkowych ważniejsze jest położenie w porządku niż arytmetyczne uśrednianie kodów; rozkład częstości zachowuje więcej informacji o pojedynczej pozycji ankiety.

Moda, kwartyle i percentyle

Moda jest najczęstszą wartością lub kategorią. Może być kilka równie częstych kategorii; wtedy nie wymuszaj jednej dominanty. Dla ciągłych pomiarów zależy od zaokrąglenia albo sposobu oszacowania gęstości. Moda nadaje się do danych nominalnych, dla których średnia kodów nie ma interpretacji.

Kwartyle Q1/Q2/Q3 wyznaczają progi dla około 25%, 50% i 75% uporządkowanych danych; Q2 jest medianą. Percentyl 90 opisuje próg, poniżej którego znajduje się około 90% obserwacji. Algorytmy wyznaczania kwantyli mogą się różnić, szczególnie przy małej próbie i remisach. R domyślnie interpoluje pomiary liczbowe; podaj metodę, gdy dokładne porównanie ma znaczenie.

Mały zbiór pokazuje różnicę średniej i mediany bez testu hipotezy. Obliczamy również kwartyle, aby opisać środkową część rozkładu. Odczytaj jednostki i zauważ, że maksimum 36 wpływa silniej na średnią niż medianę.

```
czasy <- c(2, 3, 4, 5, 36)
c(srednia = mean(czasy), mediana = median(czasy))
```

```
## srednia mediana
##      10      4
```

```
stats::quantile(czasy, probs = c(.25, .5, .75, .9))
```

```
## 25% 50% 75% 90%
## 3.0 4.0 5.0 23.6
```

Miary zróżnicowania

Dwie grupy mogą mieć tę samą średnią i zupełnie inne doświadczenia pojedynczych osób. Rozstęp $R = x_{max} - x_{min}$ używa tylko skrajnych wartości i rośnie wraz z możliwością zaobserwowania ekstremum. Nie przedstawiaj go jako typowego odchylenia od średniej. Do opisu dołącz SD albo IQR oraz N .

Wariancja i odchylenie standardowe

Wariancja mierzy średnie kwadratowe odchylenie od średniej. Podnoszenie do kwadratu eliminuje znaki ujemne.

Dla próby estymator ma postać $s^2 = \frac{1}{n-1} \sum_i (x_i - \bar{x})^2$. Dzielnik $n-1$ uwzględnia estymowanie średniej z tych samych danych; przy niezależnych obserwacjach i skończonej wariancji daje nieobciążony estymator wariancji populacji. Wariancja opisowa pełnej populacji może używać dzielnika N . Nie należy tych

konwencji mylić, gdy porównujesz arkusz z R.

Odchylenie standardowe to pierwiastek z wariancji. Przywraca ono wynik do oryginalnych jednostek pomiaru:

Zapis $s = \sqrt{s^2}$ przywraca jednostkę, np. minuty. SD nie jest błędem standardowym średniej: SD opisuje rozproszenie osób, a SE niepewność estymacji; wróćmy do niej na W03. Reguła „około 68% wartości w średnia $\pm$ SD” wymaga rozkładu zbliżonego do normalnego. Nie stosuj jej mechanicznie do skośnych czasów.

IQR i względne zróżnicowanie

Rozstęp międzykwartylowy $IQR = Q_3 - Q_1$ opisuje szerokość środkowej połowy danych. Jest mniej wrażliwy na pojedyncze ekstremum niż zakres lub SD. Pudełko ma granice Q_1 i Q_3 , a linia wewnątrz medianę. Wąsy kończą się na najbardziej odległych danych w odległości do 1,5 IQR od kwartylów; punkty dalej wymagają sprawdzenia, nie automatycznego odrzucenia.

Współczynnik zmienności $CV = 100s/\bar{x}$ odnosi SD do średniej. Ma sens przede wszystkim na skali z naturalnym zerem i przy dodatniej średniej oddalonej od zera. Nie używaj go do porównania dowolnych skal, np. roku kalendarzowego lub kodów Likerta. Przesunięcie umownego zera zmieniłoby wynik bez zmiany rozproszenia doświadczeń.

Kształt rozkładu i asymetria

Prawy ogon oznacza nieliczne duże wartości, lewy nieliczne małe. Skośność numeryczna opisuje asymetrię, ale pojedynczy współczynnik nie zastępuje histogramu. Bliskość średniej i mediany albo skośność bliska zeru nie dowodzą normalności. Dwa skupienia mogą mieć symetrię, lecz nie przypominać jednego dzwonowego rozkładu.


Poniższa demonstracja zachowuje trzy rozkłady pomocnicze, aby porównać kierunki ogonów. Wartości mają jednostkę umowną i nie są czasami rzeczywistych użytkowników. Odczytaj kierunek ogona i kształt każdej krzywej; wysokość gęstości nie jest prawdopodobieństwem w punkcie.

```
set.seed(111)
prawosk <- stats::rgamma(1000, shape = 2, rate = .5)
symetr <- stats::rnorm(1000, mean = 10, sd = 2)
lewosk <- 20 - stats::rgamma(1000, shape = 2, rate = .5)
rozklady <- data.frame(wartosc = c(lewosk, symetr, prawosk),
  typ = factor(rep(c("Lewoskośny", "Symetryczny", "Prawoskośny"), each = 1000),
    levels = c("Lewoskośny", "Symetryczny", "Prawoskośny")))
ggplot2::ggplot(rozklady, ggplot2::aes(wartosc, fill = typ)) +
  ggplot2::geom_density(alpha = .7) +
  ggplot2::facet_wrap(~typ, scales = "free", ncol = 3) +
  ggplot2::scale_fill_manual(values =
    unname(badaniaZI::paleta_zi()[c("primary", "success", "accent")])) +
  ggplot2::labs(x = "Wartość pomocnicza", y = "Gęstość") +
  badaniaZI::theme_zi() + ggplot2::theme(legend.position = "none")
```

Kurtoza dotyczy ciężaru ogonów i wrażliwości na rzadkie wartości, a nie wyłącznie wysokości szczytu. Dla rozkładu normalnego kurtoza wynosi 3, natomiast eksces — po odjęciu 3 — wynosi 0. Programy stosują różne konwencje i korekty dla próby, dlatego nazwę oraz definicję trzeba sprawdzić w dokumentacji. Z03 nie wymaga obliczania kurtozy. NIST: Measures of Skewness and Kurtosis.

Pomiar samooceny, akceptacji i dystansu

Postawa nie jest odczytem fizycznego miernika. Treść pytań, skala odpowiedzi i reguła łączenia wpływają na wynik. Poniższe podejścia są różnymi sposobami operacjonalizacji, a nie czterema nazwami tej samej ankiety. Przykłady dotyczą środowiska informacyjnego i służą objaśnieniu zasady, bez deklaracji walidacji narzędzia.



Rysunek 1: Trzy rozkłady pomocnicze; po 1000 wartości syntetycznych.

Pozycje typu Likerta i skala złożona

Respondent określa stopień zgody ze stwierdzeniami. Pojedyncza pozycja jest porządkowa, a sumowany lub uśredniany wynik kilku uzasadnionych pozycji wymaga sprawdzenia kierunku, reguły braków oraz znaczenia konstruktów. W C04 odwracamy pozycję 3 i liczymy średni indeks przy minimum 5/6 odpowiedzi. Nie utożsamiamy odpowiedzi neutralnej z brakiem ani alfa Cronbacha z trafnością.

Dystans społeczny Bogardusa

Skala bada gotowość do różnych form kontaktu z członkami określonej grupy, od relacji odległych do bliskich. W badaniu społeczności informacyjnej pytania mogłyby dotyczyć udziału w wspólnym wydarzeniu, współpracy nad kolekcją i bliskiej współpracy zespołowej. Adaptacja wymaga uzasadnienia porządku relacji; nie wolno uznać kolejnych kodów za równe odległości psychologiczne. To pomiar deklarowanej akceptacji kontaktu, nie dowód zachowania osoby. Bogardus (1925), *Measuring Social Distance*.

Skala kumulatywna Guttmana

Odpowiedzi mają tworzyć uporządkowany wzorec: zgoda na silniejszą pozycję powinna współwystępować ze zgodą na słabsze. W przykładowej skali umiejętności można sprawdzić kolejność wyszukania, zapisania i opracowania wyniku, ale ta kolejność nie jest oczywista dla każdej osoby. Trzeba obejrzeć rzeczywiste wzorce oraz błędy kumulatywności. Sama suma odpowiedzi tak/nie nie dowodzi spełnienia założenia. Guttman (1947), *The Cornell Technique for Scale and Intensity Analysis*.

Podejście Thurstonea

Sędziowie wcześniej porządkują stwierdzenia według stopnia wyrażanej postawy; dobiera się pozycje reprezentujące różne miejsca kontinuum. Respondent wskazuje zaakceptowane stwierdzenia, których ustalone wartości tworzą podstawę wyniku. To inne zadanie niż zaznaczanie zgody 1–5 przy każdej pozycji Likerta. Przygotowanie wymaga oceny stwierdzeń i sprawdzenia zgodności; numery pozycji nie są automatycznie ich wagami. Thurstone (1928), *Attitudes Can Be Measured*.

Podejście	Co określa wynik	Co wymaga uzasadnienia
Likert	Stopnie zgody i złożony wynik pozycji	Konstrukt, kierunek, łączenie i braki
Bogardus	Akceptowane poziomy kontaktu	Porządek i znaczenie relacji
Guttman	Kumulatywny wzorzec odpowiedzi	Hierarchia i odstępstwa od wzorca
Thurstone	Wcześniejsze wartości stwierdzeń	Dobór sędziów, zgodność i wybór pozycji

Transformacja, agregacja i arkusz

Sortowanie zmienia kolejność wierszy, ranking nadaje pozycje według wartości, a agregacja oblicza podsumowanie grup. Transpozycja zamienia wiersze z kolumnami; mieszane kolumny tekstowe i liczbowe mogą wtedy stać się jedną macierzą tekstową. Dlatego nie transponujemy całej ankiety bez celu i kontroli klas. W arkuszu filtruj i sortuj całe wiersze, aby nie rozłączyć ID od odpowiedzi.

Standaryzacja z odejmuje średnią i dzieli przez SD, a skalowanie min-max przenosi zakres do 0–1. Oba zabiegi zmieniają jednostkę, lecz nie czynią rozkładu normalnym. Wyraz „normalizacja” jest używany w różnych znaczeniach; zapisuj dokładny wzór. Przy stałych wartościach mianownik wynosi zero, więc takie skalowanie nie jest określone. Logarytm dodatniego czasu rozwija W03.

Trzy znane czasy pozwalają odczytać transformacje bez braków. `rank()` uśrednia pozycje remisów, `scale()` zwraca macierz, a `t()` macierz transponowaną. Odczytaj, co zmieniło jednostkę, a co tylko kolejność lub kształt tabeli.

```
male <- data.frame(grupa = c("A", "B", "A"), czas = c(2, 8, 2))
data.frame(czas = male$czas, ranking = rank(male$czas),
  z = as.numeric(scale(male$czas)),
  min_max = (male$czas - min(male$czas)) / diff(range(male$czas)))
```

```
##   czas ranking      z min_max
## 1    2      1.5 -0.5773503     0
## 2    8      3.0  1.1547005     1
## 3    2      1.5 -0.5773503     0
```

```
stats::aggregate(czas ~ grupa, data = male, FUN = mean)
```

```
##   grupa czas
## 1     A    2
## 2     B    8
```

```
t(as.matrix(male["czas"]))
```

```
##      [,1] [,2] [,3]
## czas    2    8    2
```

Eksport CSV zachowuje wartości tabeli, lecz nie formuły, kolory ani wiele arkuszy. Konwersja do XLSX nie nadaje danych nowej skali pomiarowej. Po konwersji sprawdź N, kolumny, jednostki, separator i kodowanie. W zadaniach źródłem odtworzenia jest skrypt R, a raport opisuje decyzje oraz odnosi się do zapisanych tabel i wykresów.

Pytania do dyskusji

Jak zmieni się średnia pięciu czasów, jeśli 36 zostanie zastąpione 360? Czy zmieni się mediana? Czy uporządkowany kod odpowiedzi oznacza równą odległość? Dlaczego z-scores nie naprawiają asymetrii? Co znaczy 70% przy pytaniu wielokrotnym? Jaki dowód trzeba zgromadzić, zanim nazwiesz sumę odpowiedzi skalą kumulatywną?