

W03 — Od wyniku próby do niepewności: estymacja i testowanie

Zarządzanie informacją — wykład — 2026/27

Marek Deja

2026/27

Spis treści

Jedna ankieta, kilka różnych pytań	2
Cztery słowa, których nie warto używać zamiennie	2
Populacja musi mieć granice	2
Prawdopodobieństwo punktu, przedziału i kwantyl	3
Rozkład osób i rozkład estymatora	4
Błąd standardowy jest odchyleniem standardowym estymatora	4
Nieobciążoność, precyzja i zgodność	5
Przedział ufności: procedura, nie pudełko z osobami	5
Przykład pierwszy: indeks względem środka skali	6
Statystyka t jako odległość w jednostkach niepewności	7
Wartość p jest warunkową oceną skrajności	7
Efekt naturalny, standaryzowany i praktyczny	8
Przykład drugi: czas z małej próby	8
Alfa, błędy i moc: własności procedury	9
Wiele prób znalezienia jednego wyniku	9
Losowanie komputerowe ma dwa odmienne zadania	10
Bootstrap: próba jako empiryczne przybliżenie populacji	10
Zmiana znaków: konkretny model zerowy	10
P z losowej liczby przestawień	10
Zgodność testu i przedziału ma warunki	11
Czytanie krótkiego raportu	11
Sprawdzenie rozumienia	11
Most do ćwiczenia i dalszych analiz	11

Towarzyszący skrypt oblicza przykłady z jawnie podanych statystyk oraz symulację powtarzanych prób. Symulacja jest modelem dydaktycznym, nie badaniem realnej biblioteki. Pozwala zobaczyć wielkości, których przy jednej rzeczywistej próbie nie obserwujemy bezpośrednio.

Jedna ankieta, kilka różnych pytań

Biblioteka otrzymała podsumowanie oceny katalogu: średni indeks jest wyższy od środka skali. Czy różnica jest duża? Jak precyzyjnie ją oszacowano? Czy taki wynik byłby nietypowy przy średniej równej wartości odniesienia? Czy wynik mówi o wszystkich użytkownikach? To cztery różne pytania.

Pierwsze dotyczy wielkości efektu w punktach. Drugie niepewności estymacji. Trzecie zgodności wyniku z określonym modelem zerowym. Czwarte wymaga przede wszystkim informacji o populacji, doborze próby, odmowach i pomiarze. Test statystyczny nie zastępuje odpowiedzi na pozostałe pytania.

W C04 ustaliliśmy, że wspólny indeks S02 podsumowuje dydaktyczne pozycje deklarowanej użyteczności katalogu. Nie jest zwalidowanym pomiarem wszystkich kompetencji. Na tym wykładzie nie zmieniamy jego znaczenia. Uczymy się, jak mówić o losowej niepewności wybranej liczby, nie przypisując jej nowej treści.

W ciągu 90 minut przejdziemy od pytania i estymandy do błędu standardowego oraz przedziału, następnie do statystyki t i wartości p , a na końcu do dwóch różnych zastosowań losowania komputerowego. Symulacje ilustrują argument; student ma je odczytać, nie samodzielnie implementować.

Cztery słowa, których nie warto używać zamiennie

Pojęcie	Znaczenie	Przykład
Estymanda	Dokładnie określona wielkość, którą chcemy oszacować	Średni czas tego zadania w określonej populacji i warunkach
Parametr	Liczba charakteryzująca populację lub model	μ , średnia czasu
Estymator	Reguła wykorzystująca dane do oszacowania	Średnia arytmetyczna z próby
Estymata	Konkretna otrzymana wartość	11,2 minuty w danej próbie

Parametr może być celem estymacji, czyli estymandą. Słowo „estymanda” podkreśla jednak, że trzeba określić populację, wynik, warunki i sposób podsumowania. Średni czas wszystkich prób i średni czas prób zakończonych sukcesem są różnymi estymandami, nawet jeśli oba rezultaty zapisujemy literą μ z odpowiednim indeksem.

Statystyka jest funkcją danych z próby. Średnia, SD, odsetek i statystyka testowa t są statystykami, ale pełnią inne role. Średnia może szacować parametr, SD opisuje rozrzut i pomaga oszacować niepewność, a t odnosi różnicę do jej błędu standardowego. Nie każda liczba z tabeli jest „efektem”.

Populacja musi mieć granice

„Wszyscy użytkownicy informacji” to zwykle zbyt szerokie określenie dla jednego zadania w katalogu. Bardziej precyzyjny cel mógłby dotyczyć nowych użytkowników konkretnej usługi, wykonujących określone zadanie w danym okresie i na określonym urządzeniu. Zmiana tych warunków może zmienić rozkład wyników.

W rzeczywistym badaniu potrzebujemy powiązania między sposobem doboru a populacją. Próba osób, które dobrowolnie wypełniły ankietę po udanym wyszukaniu, może nie reprezentować tych, którzy porzucili usługę. Nawet bardzo mały błąd standardowy nie opisuje automatycznie niepewności wynikającej z tej samoselekcji.

W danych syntetycznych kursu wnioskowanie jest ćwiczeniem procedury pod jawnymi założeniami. Nie ogłaszamy wyniku o bibliotece UJ. W projekcie trzeba umieć opisać hipotetyczną populację i projekt, a zarazem uczciwie wskazać dydaktyczny charakter danych.

Prawdopodobieństwo punktu, przedziału i kwantyl

Niepewność będziemy opisywać rozkładem. Zanim odczytamy pole pod krzywą testu, rozróżnijmy zmienną dyskretną, która przyjmuje policzalne wartości, i model ciągłego czasu. W obu przypadkach suma albo całka całego rozkładu prawdopodobieństwa wynosi 1; sposób odczytu pojedynczego punktu jest jednak inny.

Załóżmy trzy niezależne próby odnalezienia dokumentu, każda z prawdopodobieństwem powodzenia $\pi = 0,5$. Zmienna K liczy powodzenia. W tym modelu dwumianowym $P(K = k) = \binom{3}{k}\pi^k(1 - \pi)^{3-k}$: symbol dwumianowy liczy układy k powodzeń, a potęgi opisują prawdopodobieństwo każdego takiego układu. To model dydaktyczny, nie założenie, że prawdziwi użytkownicy zawsze działają niezależnie i równie skutecznie.

Pierwsza kolumna prawdopodobieństw dotyczy dokładnie k powodzeń. Druga to dystrybuenta $F(k) = P(K \leq k)$, czyli suma do wskazanej granicy. Odczytaj różnicę między „dokładnie dwa” a „najwyżej dwa”.

k	punktowe	skumulowane
0	0.125	0.125
1	0.375	0.500
2	0.375	0.875
3	0.125	1.000

Dokładnie dwa powodzenia mają prawdopodobieństwo $3/8$, najwyżej dwa $7/8$, a co najmniej dwa $1 - F(1) = 1/2$. Gdy trzy próby wykonuje ta sama osoba, uczenie się i wspólne cechy mogą naruszyć model niezależności. Rozkład nie zastępuje analizy sposobu powstawania danych.

Teraz przyjmijmy wyłącznie do demonstracji ciągły model czasu z gęstością $f(t) = 0,1e^{-0,1t}$ dla $t \geq 0$, czyli rozkład wykładniczy o średniej 10 minut. Gęstość $f(5)$ nie jest prawdopodobieństwem „dokładnie pięć minut”. Prawdopodobieństwo przedziału to pole pod krzywą: $P(a < T \leq b) = F(b) - F(a)$. W modelu ciągłym pojedynczy punkt ma prawdopodobieństwo zero, mimo że zmierzony czas zapisujemy z ograniczoną dokładnością.

Tabela rozdziela wysokość gęstości, pole do 5 minut i pole między 5 a 10 minutami. Ostatni wiersz odwraca pytanie: znajduje czas, do którego kończy się połowa prób w modelu. To kwantyl rzędu 0,5, czyli mediana.

wielkosc	wartosc
Gęstość $f(5)$ [1/min]	0.0607
$P(T \leq 5)$	0.3935
$P(5 < T \leq 10)$	0.2387
Mediana czasu [min]	6.9315

Mediana wynosi około 6,93 minuty, choć średnia modelowa wynosi 10. Nie dopasowaliśmy tu rozkładu do danych biblioteki. Model wykładniczy ma własne mocne założenia, m.in. brak pamięci czasu oczekiwania; nie przyjmujemy ich automatycznie dla złożonego wyszukiwania. W kolejnej symulacji użyjemy odrębnego dodatniego rozkładu lognormalnego.


W dokumentacji R prefiks **d** oznacza gęstość lub prawdopodobieństwo punktowe, **p** dystrybuentę, **q** kwantyl, a **r** losowanie. Przykładowo **pexp** liczy $F(t)$ i **qexp** odwraca to pytanie. Nie trzeba pisać tych wywołań w zadaniu; rozpoznanie ich znaczenia pomaga czytać gotowy wynik. Dokumentacja rozkładu wykładniczego w R.

Rozkład osób i rozkład estymatora

W jednej próbie osoby mają różne czasy. Gdyby pobierać kolejne próby z tej samej populacji według tej samej procedury, każda miałaby także inną średnią. Te dwa rodzaje zróżnicowania trzeba oddzielić.

Model symulacyjny poniżej generuje dodatnie czasy o średniej populacyjnej 10 minut i SD 4 minuty. Najpierw pokazuje czasy 40 osób, a potem średnie z 2000 oddzielnych prób po 40 osób. W drugim panelu każda liczba reprezentuje całą próbę, nie jednego użytkownika.

Rozrzut osób i rozrzut średnich



Osie poziome pozostają w minutach. Rozkład średnich jest jednak znacznie węższy niż rozkład indywidualnych czasów. Średnia z wielu niezależnych informacji mniej się waha niż pojedyncza obserwacja. Pionowa linia oznacza znaną średnią modelu; w zwykłym badaniu ta wartość byłaby nieznana.

Centralne twierdzenie graniczne pomaga rozumieć, dlaczego rozkład średniej może być bliski normalnemu nawet przy nienormalnych danych, pod odpowiednimi warunkami. Nie mówi, że rozkład samych czasów staje się normalny po zebraniu dużego N . Nie daje też jednego magicznego progu liczebności dla każdej skośności i każdego układu zależności.

Błąd standardowy jest odchyleniem standardowym estymatora

Dla niezależnych obserwacji o wspólnej skończonej wariancji standardowy wzór na oszacowanie błędu standardowego średniej to:

$$SE(\bar{x}) = \frac{s}{\sqrt{n}}.$$

Licznik mówi o zróżnicowaniu osób, mianownik o ilości niezależnej informacji. SE ma tę samą jednostkę

co średnia. Dla SD równego 4 minutom i $N=100$ błąd standardowy wynosi 0,4 minuty, nie 4 i nie 0,04.

Tabela utrzymuje SD równe 4 i zmienia tylko N . Odczytaj, ile razy trzeba zwiększyć próbę, aby zmniejszyć SE o połowę. To zależność modelowa, nie obietnica, że każdy większy zbiór automatycznie ma taki sam SD.

N	SD	SE
25	4	0.8
100	4	0.4
400	4	0.2

Czterokrotnie większa liczebność daje dwukrotnie mniejsze SE przy niezmienionym SD. Osiemdziesiąt kliknięć jednej osoby nie zastępuje jednak osiemdziesięciu niezależnych osób. Jeśli obserwacje są powiązane, potrzebujemy procedury uwzględniającej zależność. Proste dzielenie przez pierwiastek z liczby wierszy może zaniżyć niepewność.

Nieobciążoność, precyzja i zgodność

Estymator nieobciążony trafia w parametr przeciętnie w powtarzanych próbach w danym modelu. Nie znaczy to, że każda estymata jest równa parametrowi. Precyzja dotyczy małego rozrzutu estymat, a zgodność zbliżania się do celu wraz ze wzrostem liczebności pod odpowiednimi warunkami.

Wyobraź sobie bardzo dużą ankietę skierowaną tylko do najbardziej aktywnych użytkowników. Może dawać powtarzalną i precyzyjną ocenę tej grupy. Nie staje się przez to nieobciążonym opisem wszystkich użytkowników, jeżeli celem była szersza populacja.

Do poprawnej interpretacji potrzebujemy więc dwóch pytań: „jak bardzo waha się oszacowanie?” i „czy procedura kieruje nas do właściwej wielkości?”. Wąski przedział odpowiada tylko na część pierwszego pytania, zgodnie z przyjętym modelem.

Przedział ufności: procedura, nie pudełko z osobami


Dla średniej w standardowym modelu t dwustronny przedział 95% ma postać:

$$\bar{x} \pm t_{0,975; n-1} \frac{s}{\sqrt{n}}.$$

W środku jest estymata. Margines powstaje przez pomnożenie SE przez odpowiedni kwantyl rozkładu t . Liczba $n - 1$ to stopnie swobody; przy małej próbie kwantyl jest większy niż przy dużej. Szerszy poziom ufności, na przykład 99%, wymaga szerszego przedziału przy tych samych danych.

Poziom ufności odnosi się do długookresowego działania procedury. Przy spełnieniu warunków około 95% tak konstruowanych przedziałów obejmowałoby ustalony parametr. Po otrzymaniu konkretnego przedziału nie znamy faktu jego trafienia, ale wiemy, jaką procedurą powstał.

Poniższe odcinki to pierwsze 40 przedziałów z symulacji. Linia pionowa pokazuje znany parametr 10. Przedziały zmieniają położenie i długość; parametr w tym doświadczeniu komputerowym pozostaje stały.



Nie wymagamy dokładnie dwóch nietrafień w każdych czterdziestu próbach. Poziom 95% nie jest rozkładem obowiązkowych trafień w małej serii. Ponieważ symulowana populacja czasu jest skośna, standardowy przedział t ma tutaj uzasadnienie przybliżone, nie dokładne wynikające z normalności obserwacji.

Podsumowanie wykorzystuje wszystkie 2000 prób, a nie tylko odcinki na wykresie. Odczytaj empiryczny rozrzut średnich i udział przedziałów obejmujących parametr. N próby nadal wynosi 40; liczba 2000 to liczba powtórzeń eksperymentu komputerowego.

wielkosc	wartosc
liczba_prob	2000
osob_w_probie	40
parametr_mu	10
średnia_estymat	10.0032
SD_estymat	0.6355
pokrycie_procent	94.35

Przedział średniej nie jest zakresem, w którym znajduje się 95% indywidualnych czasów. Nie jest też przedziałem predykcji czasu nowej osoby. W dużej próbie średnią możemy oszacować dokładnie, mimo że ludzie nadal bardzo się różnią.

Przykład pierwszy: indeks względem środka skali

Rozważmy osobny, hipotetyczny opis próby: $N=100$, średni indeks 3,24 i $SD=0,80$ punktu. Porównujemy średnią z wartością 3. Jest to umowny punkt odniesienia oparty na środku skali, nie normatywna granica kompetencji ani oficjalny standard usługi.

Estymandą jest $\Delta = \mu - 3$, różnica średniej określonej populacji od punktu odniesienia. Estymata wynosi

$\widehat{\Delta} = 3,24 - 3 = 0,24$ punktu. Wartość dodatnia oznacza wyższy wynik w kierunku korzystnej oceny, a nie automatycznie poprawę spowodowaną zmianą katalogu.

Statystyka t jako odległość w jednostkach niepewności

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} = \frac{3,24 - 3}{0,80/\sqrt{100}} = 3.$$

Licznik to efekt w punktach, mianownik to SE średniej w punktach. Jednostki się skracają. Statystyka $t=3$ oznacza, że estymata leży trzy oszacowane błędy standardowe powyżej wartości zerowej hipotezy. Nie oznacza trzech punktów skali ani trzech SD osób.

Hipoteza zerowa brzmi $H_0 : \mu = 3$, a dwustronna alternatywa $H_1 : \mu \neq 3$. Rozkład t z 99 stopniami swobody jest rozkładem odniesienia w klasycznym modelu. Przy niezależnych normalnych obserwacjach ma uzasadnienie dokładne; przy innych rozkładach stosowanie do średniej wymaga oceny przybliżenia, skrajności danych i wielkości próby.

Zestawienie pokazuje wszystkie składniki obliczenia. Zwróć uwagę na dwa oddzielnie nazwane przedziały: jeden dotyczy średniej, drugi różnicy od 3. Przesunięcie obu końców o 3 zmienia parametr opisywany przez przedział.


wielkosc	wartosc
N	100
srednia	3.24
SD	0.8
SE	0.08
odniesienie	3
roznica	0.24
CI_srednia_dol	3.0813
CI_srednia_gora	3.3987
CI_roznica_dol	0.0813
CI_roznica_gora	0.3987
t	3
df	99
p	0.0034
d	0.3
jednostka	punkty

Średnia 3,24 ma 95% CI około [3,081; 3,399], a różnica 0,24 ma CI około [0,081; 0,399] punktu. Te zapisy przekazują zgodną informację, ale porównują się z innymi wartościami zerowymi: 3 dla średniej i 0 dla różnicy. Nie wolno podać efektu 0,24 z nienazwanym przedziałem [3,081; 3,399], jak gdyby dotyczył on tego efektu.

Wartość p jest warunkową oceną skrajności

Dwustronne p określa, jak często w modelu zerowym otrzymalibyśmy statystykę co najmniej tak skrajną w obu kierunkach. W przykładzie bierzemy pod uwagę t nie większe niż -3 oraz nie mniejsze niż 3 . Nie obliczamy prawdopodobieństwa prawdziwości hipotezy.

Wykres przedstawia rozkład odniesienia t przy H_0 . Zaznaczone ogony wyznaczają p , które wynosi około 0,0034. Położenie obserwacji w ogonie jest relacją do modelu, nie miarą korzyści dla biblioteki.



Odczyt pełnym zdaniem: „Przy hipotezie średniej równej 3 i założeniach testu wynik o takiej lub większej bezwzględnej wartości t byłby rzadki”. Nie: „szansa, że H_0 jest prawdziwa, wynosi 0,34%”. Nie: „99,66% użytkowników ocenia katalog pozytywnie”.

Stanowisko ASA z 2016 roku podkreśla ograniczenia przypisywania pojedynczemu p roli całego argumentu naukowego. W kursie zapisujemy efekt, niepewność i warunki analizy obok wyniku testu. Nie zastępujemy ich samą etykietą istotności.

Efekt naturalny, standaryzowany i praktyczny

W przykładzie efekt naturalny wynosi 0,24 punktu. Efekt standaryzowany jednej próby można zapisać jako $d = (\bar{x} - \mu_0)/s$, co daje $0,24/0,80 = 0,30$. Mianownikiem jest SD osób, nie SE. Dlatego $t=3$ i $d=0,30$ są jednocześnie poprawne.

Standaryzacja ułatwia pewne porównania, ale nie usuwa różnic pomiaru i populacji. To samo d może odpowiadać innym różnicom w minutach lub punktach. Większy rozrzut osób zmniejsza d przy niezmięnionej naturalnej różnicy.

Znaczenie praktyczne wymaga osobnego kryterium. Czy różnica kilku dziesiątych punktu zmienia decyzję o katalogu? Czy odpowiada zauważalnej zmianie wykonania? Czy instrument w ogóle ma dość dobrze uzasadnioną interpretację? Żadna uniwersalna etykieta „mały” lub „średni” nie rozstrzyga tych pytań.

Nie należy po obejrzeniu wyniku ogłaszać dowolnego progu praktycznego jako wcześniej ustalonego. Można uczciwie przedstawić eksploracyjną dyskusję kosztów, korzyści i zakresu zgodnych efektów. W projekcie dydaktycznym umowne progi muszą być nazwane umownymi.

Przykład drugi: czas z małej próby

W innej demonstracji $N=16$ osób, średni czas 11,2 minuty, $SD=6$ minut, a odniesienie wynosi 10. Estymata różnicy to 1,2 minuty. SE równa się $6/\sqrt{16} = 1,5$ minuty, a $t=0,8$.

Tabela pokazuje szeroki przedział, mimo że średnia w próbie jest wyższa od odniesienia. Jest to przykład rachunku z zadanych statystyk opisowych; bez surowych danych nie ocenimy skośności ani pojedynczych długich prób. Interpretacja inferencyjna wymaga więc wyraźnego zastrzeżenia o założeniach.

wielkosc	wartosc
N	16
srednia	11.2
SD	6
SE	1.5
odniesienie	10
roznica	1.2
CI_srednia_dol	8.0028
CI_srednia_gora	14.3972
CI_roznica_dol	-1.9972
CI_roznica_gora	4.3972
t	0.8
df	15
p	0.4362
d	0.2
jednostka	minuty

Przedział różnicy wynosi około $[-2,00; 4,40]$ minuty, a p około 0,436. Dane przy tym modelu są zgodne z różnicami w obu kierunkach, w tym z wartościami mogącymi mieć znaczenie dla usługi. Nieodrzućenie H_0 nie dowodzi, że średni czas wynosi dokładnie 10 ani że katalog spełnia standard.

Ten przykład pokazuje problem nieprecyzyjnego wyniku. Stwierdzenie „nie ma różnicy” usuwa z opisu możliwość kilku minut dłuższego wyszukiwania. Właściwa odpowiedź podaje oszacowanie i szerokość niepewności. Jeżeli instytucja chce wykazać wystarczającą bliskość do celu, potrzebuje wcześniej zdefiniowanej tolerancji i odpowiedniej procedury, a nie zwykłego nieistotnego testu różnicy.

Alfa, błędy i moc: własności procedury

Poziom α ustalamy przed oceną wyniku. W poprawnie skalibrowanym teście opisuje kontrolę częstości odrzucenia prawdziwej H_0 w powtarzanym stosowaniu procedury. Nie jest prawdopodobieństwem, że nasze konkretne odrzucenie jest błędem.

Stan modelowy	Nie odrzucamy H_0	Odrzucamy H_0
H_0 prawdziwa	Decyzja zgodna z H_0	Błąd I rodzaju
Określona alternatywa prawdziwa	Błąd II rodzaju	Wykrycie tej alternatywy

Moc to prawdopodobieństwo odrzucenia H_0 przy określonej alternatywie. Nie istnieje jedna moc badania bez wskazania wielkości efektu, zmienności, N i procedury. Mały efekt jest zwykle trudniejszy do wykrycia niż duży przy tych samych warunkach.

Większa próba może zwiększyć moc oraz zwięźić przedział, ale nie naprawia systematycznego błędu pomiaru. Nie planujemy N wyłącznie po to, aby „wyszło $p < 0,05$ ”. Warto rozważyć, jak mała różnica ma znaczenie i jakiej precyzji potrzebujemy do decyzji.

Wiele prób znalezienia jednego wyniku

Jeśli wykonamy 20 niezależnych testów przy prawdziwych H_0 i poziomie 0,05, prawdopodobieństwo co najmniej jednego odrzucenia wynosi $1 - 0,95^{20} \approx 0,64$. Liczba 64% dotyczy tego szczególnego układu niezależności, nie każdego zestawu analiz, ale pokazuje problem selektywnego wyboru.

Szukanie wielu podziałów grup, progów czasu i wariantów braków, a potem pokazanie tylko najniższego p , zmienia procedurę. Zapis jednego testu w raporcie nie usuwa wcześniejszego poszukiwania. Dlatego odróżniamy pytania zaplanowane od eksploracji i dokumentujemy decyzje.

Nie ma ostrej naukowej granicy między $p=0,049$ a $p=0,051$, choć przy umownej regule decyzji leżą po przeciwnych stronach. W obu przypadkach potrzebujemy efektu, przedziału i warunków. Dwa wyniki z takimi p nie są dowodem, że efekty między badaniami różnią się istotnie.

Losowanie komputerowe ma dwa odmienne zadania

Pytanie	Procedura	Co powstaje?
Jak zmieniałyby się estymata?	Bootstrap obserwacji z powtórzeniami	Przybliżenie niepewności estymatora
Jak skrajna jest statystyka przy modelu zerowym?	Dopuszczalne przestawienia lub zmiany znaków	Rozkład odniesienia testu

W obu przypadkach komputer wykonuje wiele powtórzeń, ale samo słowo „losowanie” nie mówi, jaki świat odtwarzamy. W bootstrapie próbujemy przybliżyć zmienność estymatora wokół informacji dostarczonej przez próbę. W teście zerowym celowo tworzymy układy odpowiadające określonej hipotezie.

Bootstrap: próba jako empiryczne przybliżenie populacji

W podstawowym bootstrapie nieparametrycznym losujemy z posiadanych n obserwacji n elementów z powtórzeniami i ponownie liczymy statystykę. Jedna osoba może pojawić się kilka razy, inna w danym losowaniu wcale. Powtarzamy procedurę B razy, zachowując po jednej estymacie.

Rozrzut tych estymat służy ocenie niepewności. Prosty przedział percentylowy bierze kwantyle 2,5% i 97,5% rozkładu bootstrapowego. Nie jest to przedział środkowych obserwacji surowych. Podstawy metody wiążą się z pracą Efrona (1979).

Bootstrap nie tworzy nowych niezależnych ludzi i nie ujawnia cech populacji nieobecnych w próbie. Przy małym N , skrajnych rozkładach, parametrach na granicy lub zależnościach prosty wariant może działać źle. Dla par i klastrów należy zachować strukturę losowania; dowolne tasowanie komórek niszczy to, co miało być oszacowane.

Zwiększenie B poprawia dokładność komputerowego przybliżenia, nie wielkość próby badawczej. Dziesięć tysięcy replik z dwudziestu osób nadal opiera się na dwudziestu osobach. Nie przedstawiamy B w raporcie jako N respondentów.

Zmiana znaków: konkretny model zerowy

Dla jednej próby można analizować odchylenia $d_i = x_i - \mu_0$. W procedurze zmian znaków mnożymy każde odchylenie niezależnie przez $+1$ albo -1 i liczymy tę samą statystykę, na przykład średnią odchylen. Porównujemy jej bezwzględną wartość z obserwowaną.

Uzasadnienie dokładne wymaga niezależności i symetrii rozkładu odchylen wokół zera pod H_0 . Sama równość średniej do μ_0 nie zapewnia symetrii. Skośne czasy mogą mieć średnią równą odniesieniu, lecz bardzo różne dodatnie i ujemne ogony. Zmiana znaków nie staje się wtedy automatycznie „testem bez założeń”. Warunki przestawień omawiają Winkler i współautorzy (2014).

Dla dwóch niezależnych grup będziemy tasować etykiety, jeśli odpowiednia wymienialność pod hipotezą zerową jest uzasadniona. Dla związku dwóch zmiennych przestawimy jedną względem drugiej. Schemat losowania musi pasować do projektu; nie wolno mieszać dowolnie obserwacji tej samej osoby.

P z losowej liczby przestawień

Przy B losowych przestawieniach stosujemy w kursie:

$$p_{MC} = \frac{1 + \#\{|T_b^*| \geq |T_{obs}|\}}{B + 1}.$$

Symbol $\#$ oznacza liczbę spełniających warunek replik. Znak $\geq$ uwzględnia także remisy. Dla $B=1999$ i 39 wyników co najmniej tak skrajnych otrzymujemy $40/2000 = 0,02$. Jeśli nie znajdziemy żadnego,

wynik wyniesie $1/2000 = 0,0005$, nie zero.

Takie postępowanie nie naprawia niewłaściwego schematu przestawień. Zapobiega natomiast traktowaniu braku skrajnych wyników w skończonej symulacji jako niemożliwości zdarzenia. Znaczenie poprawnego obliczania losowanych p omawiają Phipson i Smyth (2010).

B wpływa na rozdzielczość i losową dokładność obliczenia. W pobliżu progu dwa uruchomienia z różnymi ziarnami mogą znaleźć się po różnych stronach 0,05. Nie wybieramy ziarna dającego mniejszy wynik. Wspólne ziarno w materiale pozwala odtworzyć przykład, a nie zwiększa wiarygodności samego projektu.

Zgodność testu i przedziału ma warunki

W dwustronnym teście t na poziomie 0,05 i odpowiadającym mu dwustronnym przedziale t 95% wykluczenie wartości zerowej jest zgodne z odrzuceniem H_0 . Dla średniej sprawdzamy μ_0 , a dla różnicy zero. To związek konkretnej pary procedur.

Nie musimy otrzymać identycznej decyzji, gdy zestawimy klasyczny test t z percentylowym przedziałem bootstrapowym lub innym testem permutacyjnym. Mogą różnić się założenia, aproksymacje i sposób konstrukcji. Rozbieżność wymaga wyjaśnienia, nie wyboru bardziej atrakcyjnego wyniku.

W C05 przedstawimy klasyczny przedział i bootstrap osobno. Opiszemy, który parametr obejmuje każdą parę granic. Zgodne wnioski będą informacją o tych konkretnych analizach, a nie uniwersalnym certyfikatem poprawności.

Czytanie krótkiego raportu

Poprawny raport pierwszego przykładu można zacząć tak: „W hipotetycznej próbie 100 osób średni indeks wyniósł 3,24 punktu (SD=0,80). Różnica względem umownego odniesienia 3 wyniosła 0,24 punktu, 95% CI [0,081; 0,399]. W teście t uzyskano $t(99)=3,00$, $p=0,0034$; standaryzowana różnica $d=0,30$ ”.

Drugi akapit powinien mówić o sensie: „Odpowiedzi były przeciętnie przesunięte w stronę korzystnej oceny katalogu. Wielkość ta nie jest miarą całej kompetencji cyfrowej ani dowodem skutku zmiany interfejsu. Uogólnienie wymagałoby uzasadnienia projektu doboru i jakości pomiaru”.

Raport drugiego przykładu musi zachować szerokość niepewności: „Oszacowana różnica czasu wyniosła 1,2 minuty, lecz przedział od około $-2,0$ do $4,4$ minuty obejmuje różne praktycznie możliwe sytuacje”. Sama fraza „wynik nieistotny” jest znacznie uboższa od tej informacji.

Sprawdzenie rozumienia

W podanym akapicie odszukaj kolejno estymandę, N , efekt, jednostkę, przedział, statystykę, df i p . Rozróżnij liczbę opisującą zróżnicowanie osób od liczby opisującej niepewność średniej. Następnie sprawdź, czy ograniczenie rzeczywiście dotyczy projektu, a nie jest ogólnym zdaniem dodanym na końcu. Jest to kontrola odczytu przykładu, nie dodatkowy tekst do oddania.

Jeśli ktoś odczytuje p jako szansę prawdziwości H_0 , wracamy do rozkładu zerowego. Jeśli odczytuje CI jako 95% użytkowników, wracamy do dwóch paneli rozkładów. Jeśli t nazywa wielkością efektu w punktach, porównujemy mianowniki t i d .

Most do ćwiczenia i dalszych analiz

C05 zastosuje te pojęcia do wspólnego indeksu oraz własnego wariantu zadania. Na kolejnych spotkaniach zmieni się estymanda: różnica grup, związek kategorii, korelacja lub nachylenie. Pozostanie obowiązek określenia wielkości, jednostki, danych, niepewności i warunków.

Wykonanie testu jest krótką częścią analizy. Dłuższa praca polega na ustaleniu, czy jego pytanie jest tym, na które naprawdę chcieliśmy odpowiedzieć. W zarządzaniu informacją właśnie to rozróżnia obliczoną statystykę od użytecznego argumentu o działaniu usługi.