

W04 — Porównania: mapa projektu, efektu i testu

Zarządzanie informacją — handout — 2026/27

Marek Deja

2026/27

Najpierw ustal strukturę

Projekt	Wielkość główna	Kluczowa kontrola
Dwie niezależne grupy, wynik ilościowy	Różnica średnich	Inne osoby, N i SD w obu grupach
Dwa pomiary tych samych osób	Średnia różnica wewnątrz par	ID i kompletne pary
Dwie zmienne kategoryjne	Proporcje i związek w tabeli	Liczebności, mianowniki, oczekiwania
Wiele grup	Zaplanowany kontrast lub porównanie ogólne	Wielokrotność i właściwy model
Wynik interpretowany rangowo	Położenie/rangi według metody	Nie utożsamiać z testem średnich

Równe liczebności nie tworzą par. Wielokrotne zadania tej samej osoby nie są niezależnymi osobami. Grupy obserwacyjne nie są randomizowane przez użycie permutacji.

Jeden kierunek we wszystkich wynikach

$$\Delta = \mu_N - \mu_D, \quad \widehat{\Delta} = \bar{x}_N - \bar{x}_D.$$

Nowi minus doświadczeni: dodatni wynik czasu oznacza dłuższy czas nowych, dodatni indeks — wyższą deklarację zgodnie z kierunkiem skali. Po odwróceniu kolejności zmieniamy znak różnicy, t, g i granice CI: [L; U] przechodzi w [−U; −L]. Dwustronne p pozostaje takie samo.

Welch: obie średnie mają niepewność

$$SE = \sqrt{\frac{s_N^2}{n_N} + \frac{s_D^2}{n_D}}, \quad t_W = \frac{\widehat{\Delta}}{SE}, \quad CI_{95\%} = \widehat{\Delta} \pm t_{0,975;\nu} SE.$$

Welch nie wymaga równych wariancji, ale nadal wymaga właściwego projektu i uzasadnienia przybliżenia. Niecałkowite df jest normalnym wynikiem przybliżenia, nie błędem liczebności. Test normalności nie ocenia niezależności i nie jest uniwersalnym przełącznikiem metod.

Przykład hipotetyczny: po 5 osób, średnie czasu 12 i 8 minut, SD w obu grupach około 3,162. Różnica wynosi 4 minuty, SE=2, t(8)=2, p około 0,081, CI [−0,61; 8,61] minuty. To nieprecyzyjna dodatnia estymata, nie dowód równości.

$$s_p = \sqrt{\frac{(n_N - 1)s_N^2 + (n_D - 1)s_D^2}{n_N + n_D - 2}}, \quad g \approx \left(1 - \frac{3}{4(n_N + n_D) - 9}\right) \frac{\widehat{\Delta}}{s_p}.$$

G dzieli różnicę przez rozrzut osób, nie przez SE. Naturalna różnica w minutach lub punktach pozostaje podstawą sensu praktycznego. Duże g i p powyżej 0,05 mogą wystąpić jednocześnie przy małej próbie.

Pary: jedna różnica na osobę

$$d_i = x_{i,\text{po}} - x_{i,\text{przed}}, \quad t = \frac{\bar{d}}{s_d/\sqrt{n_{\text{par}}}}, \quad df = n_{\text{par}} - 1.$$

Ujemna zmiana czasu oznacza skrócenie. Założenie normalności dla dokładnego modelu dotyczy różnic, nie osobno kolumn przed i po. Bez kontroli zmiana może odzwierciedlać także uczenie się, a nie tylko interwencję.

Resampling musi pasować do projektu

Permutacja dwóch grup przestawia etykiety przy zachowaniu liczebności, jeśli pod H_0 dopuszcza to wymienialność lub mechanizm randomizacji. Sama równość średnich nie wystarcza przy dowolnie różnych rozkładach. Surowe tasowanie różnicy nie dziedziczy automatycznie odporności Welcha na nierówne wariancje.

Bootstrap dwóch grup losuje z powtórzeniami osobno w każdej grupie, aby szacować niepewność różnicy. Dla par zachowujemy całą parę. Zmiana znaków różnic ma własne uzasadnienie symetrii lub randomizacji; nie jest dowolnym mieszaniem wszystkich wartości.

Kategorie: od komórki do statystyki

$$E_{ij} = \frac{n_{i.}n_{.j}}{N}, \quad \chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}, \quad df = (r-1)(c-1).$$

O to liczebność obserwowana, E oczekiwana przy niezależności. E może być ułamkiem. Do testu podajemy liczebności, nie procenty. Małe oczekiwania mogą pogarszać przybliżenie chi-kwadrat; Fisher lub odpowiednie Monte Carlo wymagają jawnego opisu procedury.

Monte Carlo w omawianym teście tabel zachowuje marginesy. Fisher 2 na 2 ma interpretację warunkową przy tych marginesach. Słowo „dokładny” nie oznacza braku wymagań dotyczących projektu lub niezależności.

Wielkość związku nie jest p

$$V = \sqrt{\frac{\chi^2}{N \min(r-1, c-1)}}.$$

V jest nieujemne i nie ma kierunku. Nie jest procentem skuteczności. Prosty percentylowy bootstrap V może nie obejmować zera także przy niezależności populacyjnej, dlatego nie używamy jego dolnej granicy jako automatycznego testu związku.

W przykładzie 18/30 wobec 32/40:

Miara: nowi względem doświadczonych	Wynik	Odczyt
Różnica proporcji	-0,20	O 20 punktów procentowych mniej
Iloraz proporcji	0,75	Udział stanowi 75% udziału drugiej grupy
Iloraz szans	0,375	Inny iloraz: sukcesy do niepowodzeń

Przedział każdej miary trzeba nazwać. Wartością zerową różnicy jest 0, a brakiem związku dla ilorazów jest 1. Nie przenosimy granic między skalami bez odpowiedniego przekształcenia.

Rangi i wiele grup: granice skrótu

Test Manna–Whitneya nie jest automatycznym testem median. Interpretacja przesunięcia położenia wymaga dodatkowych warunków. Porównanie rang może odpowiadać innemu pytaniu niż przeciętny koszt czasu.

ANOVA pyta, czy wszystkie średnie są równe; wynik ogólny nie wskazuje pary. Zaplanowane kontrasty i analizy po obejrzeniu wyników wymagają odpowiednich reguł wielokrotności. Istotny wynik ogólny nie uprawnia do dowolnego wybierania kolejnych p.

W raporcie: projekt, grupy, N, wielkość i kierunek efektu, jednostka, CI, statystyka, df, p i ograniczenie. Wniosek o przyczynie wymaga uzasadnienia projektu, nie tylko małego p.

Definicje efektów: Lakens (2013). Warunki przestawień: Winkler i in. (2014).