

W04 — Porównania grup i zależności kategorii

Zarządzanie informacją — część ilościowa — 2026/27

Marek Deja

2026/27

Spis treści

Jedna usługa, trzy projekty porównania	2
Projekt przed nazwą testu	2
Oznaczenia wykładu W04	2
Różnica średnich ma ustalony kierunek	3
Mały przykład czasu	3
Test Welcha: niepewność z obu grup	4
Przedział, t i p w jednej historii	4
Wybór testu wyniku z projektu i pytania	5
Efekt standaryzowany i jego mianownik	6
Test permutacyjny: tasowanie etykiet grup	6
Te same osoby przed i po: analizujemy różnice	7
Rangi: porządek wyników i miara θ	10
Pytanie wyznacza estymandę	10
Wiele grup: analiza wariancji	11
Kategorie: najpierw tabela z liczebnościami	12
Chi-kwadrat: porównujemy O z E	13
Rozkład chi-kwadrat	14
Fisher i Monte Carlo: inne rozkłady odniesienia	16
Wielkość związku: V oraz kierunkowe różnice	17
Przedział bootstrapowy dla V	18
Cztery pytania do czytania artykułu LIS	18
Most do ćwiczeń C06 i C07	19
Literatura do dalszej pracy	19

Wykład W04 porównuje dwie grupy, pary pomiarów, kilka grup i tabele kategorii. Skrypt `analiza.R` zapisany w folderze wykładu liczy małe syntetyczne demonstracje przygotowane dla wykładu, osobne

względem zbioru S02; wyjątkiem jest wykres kwantylowy czasu S02. Kod skryptu pozostaje ukryty. Każda tabela podaje kierunek odejmowania, a każdy wykres ma w tekście słowny opis osi, wartości i wniosku.

Jedna usługa, trzy projekty porównania

Biblioteka chce poprawić korzystanie z katalogu. Może porównać nowych i doświadczonych użytkowników, zaprosić te same osoby do zadania przed instruktażem i po nim albo losowo przydzielić dwie wersje pomocy. Każdy projekt dostarcza innej informacji: różnicy między istniejącymi grupami, zmiany wewnątrz osoby albo skutku przydzielonej wersji pomocy.

Istniejące grupy różnią się wieloma cechami. Projekt przed–po zachowuje osobę i łączy zmianę usługi z uczeniem się oraz upływem czasu. Losowy przydział warunku wzmacnia wniosek przyczynowy, gdy wykonanie badania respektuje założenia. Uogólnienie na wszystkich użytkowników wymaga w każdym z trzech projektów uzasadnionego doboru próby.

Wykład najpierw rozpoznaje jednostkę i strukturę danych, a potem opisuje różnicę średnich z testem Welcha, porównanie par i tabelę kategorii. Testy rangowe i porównania wielu grup służą czytaniu literatury. Ćwiczenie C06 (Dwie grupy: różnica czasu lub samooceny i tasowanie etykiet) używa testu Welcha i testu permutacyjnego, a ćwiczenie C07 (Kategorie i zachowanie: tabela, chi-kwadrat i Monte Carlo) — tabel 2×2 .

Projekt przed nazwą testu

Tabela 1: Projekty porównania i ich jednostki

Sytuacja	Jednostka i powiązanie	Przedmiot porównania
Nowi i doświadczeni	Różne osoby w dwóch grupach	Średnie lub rozkłady wyników
Ta sama osoba przed i po	Para pomiarów jednej osoby	Zmiana wewnątrz osoby
Dwa warunki losowane	Osoby przydzielone według projektu	Wyniki między warunkami
Powodzenie w dwóch grupach	Jedna kategoria wyniku osoby	Proporcje lub struktura tabeli
Trzy wersje usługi	Trzy grupy albo trzy warunki tej samej osoby	Średnie trzech grup (ANOVA) albo trzech warunków tej samej osoby (pomiar powtarzane)

Parę tworzy wspólna jednostka, np. ta sama osoba przed i po. Dziesięciu nowych i dziesięciu doświadczonych użytkowników tworzy dwie niezależne grupy także przy równej liczebności. Przy brakującym pomiarze analiza obejmuje kompletne pary.

Niezależność obserwacji wynika z projektu badania. Wiele prób tej samej osoby albo użytkownicy pracujący wspólnie tworzą obserwacje zależne; prosty wzór z N równym liczbie wierszy daje wtedy zbyt wąskie przedziały.

Oznaczenia wykładu W04

Tabela „Oznaczenia wykładu W04” zbiera symbole wzorów wykładu; każdy symbol ma w tekście definicję w miejscu pierwszego użycia. Litery N i D w indeksie oznaczają grupy nowych i doświadczonych.

Tabela 2: Oznaczenia wykładu W04

Symbol	Znaczenie
$\Delta, \widehat{\Delta}$	Różnica średnich w populacji i jej estymata, kierunek nowi minus doświadczeni

Symbol	Znaczenie
$\bar{x}_N, s_N, n_N$	Średnia, SD i liczebność grupy nowych (analogicznie D)
SE, t_W, ν	Błąd standardowy różnicy, statystyka t Welcha, stopnie swobody Welcha (czytamy „ni”)
s_p, d, g	Łączone SD (ang. <i>pooled</i>), d Cohena, g Hedgesa
$d_i, \bar{d}, s_d, n_{\text{par}}$	Różnica pary i , średnia i SD różnic, liczba par
D^*, ε_i	Statystyka po przestawieniu etykiet; znak ± 1 w zmianie znaków
θ, R_N, U	Prawdopodobieństwo przewagi, suma rang grupy N, statystyka Manna–Whitneya
SS, MS, F, η^2	Suma kwadratów, średni kwadrat, statystyka F, udział sumy kwadratów
$n_{ij}, n_{i.}, n_{.j}, N$	Liczebność komórki, suma wiersza, suma kolumny, liczebność całej tabeli
$O_{ij}, E_{ij}, \chi^2, V$	Liczebność obserwowana i oczekiwana, statystyka chi-kwadrat, V Craméra
$\hat{p}_N, \hat{p}_D, \bar{p}, RR, OR$	Proporcje sukcesu w grupach i łącznie, iloraz proporcji, iloraz szans

Różnica średnich ma ustalony kierunek

W porównaniu nowych i doświadczonych przyjmujemy:

$$\Delta = \mu_N - \mu_D, \quad \widehat{\Delta} = \bar{x}_N - \bar{x}_D.$$

Litery N i D w indeksie nazywają grupy: nowi i doświadczeni; liczebności oznaczają n_N i n_D . Dodatnia różnica czasu oznacza, że nowi potrzebowali przeciętnie więcej minut, a dodatnia różnica indeksu — wyższą deklarowaną ocenę. Sens znaku wynika ze zmiennej wynikowej.

Hipoteza zerowa standardowego porównania średnich to $H_0 : \Delta = 0$, a dwustronna alternatywa dopuszcza różnicę w obu kierunkach. Materiał sprawdza zgodność znaku estymaty, znaku statystyki t i położenia przedziału.


Mały przykład czasu

Tabela „Dwie grupy po pięć osób” podaje czasy, średnie i SD: nowi mają czasy 8, 10, 12, 14 i 16 minut (średnia 12, SD 3,16), a doświadczeni 4, 6, 8, 10 i 12 minut (średnia 8, SD 3,16). Każda wartość dotyczy innej osoby.

Tabela 3: Dwie grupy po pięć osób

Grupa	N	Czasy [min]	Średnia [min]	SD [min]
Nowi	5	8, 10, 12, 14, 16	12,00	3,16
Doświadczeni	5	4, 6, 8, 10, 12	8,00	3,16

Wykres „Czasy w dwóch niezależnych grupach” ma na osi poziomej czas w minutach i dwa wiersze punktów. Koła oznaczają osoby, romb średnią grupy, a pionowa kreska medianę.



Rysunek 1: Czasy w dwóch niezależnych grupach. Oś pozioma: czas w minutach; dwa wiersze: nowi (8, 10, 12, 14, 16) i doświadczeni (4, 6, 8, 10, 12). Wartości 8, 10 i 12 minut występują w obu wierszach, a cały zestaw nowych leży 4 minuty dalej w prawo; romb i kreska mediany leżą przy 12 minutach u nowych i przy 8 minutach u doświadczonych.

Czasy 8, 10 i 12 minut występują w obu grupach. Różnica średnich opisuje grupy, a porównanie osób opisuje miara θ (definicja w części o rangach): losowo wybrany nowy użytkownik ma dłuższy czas od losowo wybranego doświadczonego z prawdopodobieństwem 0,82. Kwalifikacja do pomocy według długości próby obejmuje osoby z obu grup: czas 12 minut ma jedna osoba nowa i jedna doświadczona.

Test Welcha: niepewność z obu grup

$$SE(\widehat{\Delta}) = \sqrt{\frac{s_N^2}{n_N} + \frac{s_D^2}{n_D}}, \quad t_W = \frac{\widehat{\Delta} - 0}{SE(\widehat{\Delta})}.$$

Ćwiczenie C05 (Niepewność estymaty) porównywało średnią ze znaną liczbą, a test Welcha porównuje dwie oszacowane średnie. Niepewności obu średnich w modelu niezależnych grup sumują się pod pierwiastkiem, więc większy rozrzut lub mniejsze n w którejkolwiek grupie zwiększa SE różnicy. W przykładzie $SE = \sqrt{10/5 + 10/5} = 2$ minuty i $t_W = 4/2 = 2$.

Test Welcha dopuszcza różne wariancje grup i wymaga właściwej jednostki analizy, niezależności oraz uzasadnienia przybliżenia rozkładem t. Bardzo małe skośne próby z wpływowymi obserwacjami wymagają ostrożnej interpretacji. Stopnie swobody wyznacza przybliżenie Welcha–Satterthwaite’a:

$$\nu = \frac{(s_N^2/n_N + s_D^2/n_D)^2}{\frac{(s_N^2/n_N)^2}{n_N - 1} + \frac{(s_D^2/n_D)^2}{n_D - 1}}.$$

Wzór daje zwykle liczbę niecałkowitą, bo przybliża rozkład statystyki z dwiema oszacowanymi wariancjami; R używa liczby bez zaokrąglenia. Przy równych SD i równych liczebnościach, jak w przykładzie, $\nu = (2 + 2)^2 / (4/4 + 4/4) = 8$.

Przedział, t i p w jednej historii


Przedział różnicy ma postać $\widehat{\Delta} \pm t_{0,975;\nu} SE$. Tabela „Test Welcha: nowi minus doświadczeni” zawiera różnicę 4 minuty, SE 2, przedział $[-0,61; 8,61]$, $t = 2,00$, $\nu = 8$, $p = 0,0805$, łączone SD 3,16 i dwie miary standaryzowane: $d = 1,26$ i $g = 1,14$.

Tabela 4: Test Welcha: nowi minus doświadczeni

Wielkość	Wartość
Różnica nowi — doświadczeni [min]	4,00
SE różnicy [min]	2,00
95% CI różnicy [min]	[−0,61; 8,61]
Statystyka t Welcha	2,00
Stopnie swobody	8,00
Wartość p (dwustronna)	0,0805
Łączone SD s_p [min]	3,16
d Cohena	1,26
g Hedgesa	1,14

Dwustronne p testu Welcha

Pole obu ogonów = 0,0805




Rysunek 2: Dwustronne p testu Welcha. Oś pozioma: statystyka t przy H0 z 8 stopniami swobody; oś pionowa: gęstość. Krzywa jest symetryczna wokół zera; wyróżnione obszary na lewo od -2 i na prawo od 2 mają łączne pole $0,0805$.

Różnica 4 minuty ma 95% CI $[-0,61; 8,61]$. Dane są zgodne z różnicami od $-0,61$ do $8,61$ minuty: od niewielkiej przewagi nowych po wydłużenie ich czasu o ponad 8 minut. Wynik uzasadnia badanie z większą próbą: przy SD $3,16$ minuty połowa szerokości przedziału 1 minuta wymaga około 77 osób w grupie.

Wybór testu wynika z projektu i pytania

Test Shapiro–Wilka mierzy odchylenie od normalności, a jego moc rośnie z N : przy małym N wykrywa duże odchylenia, przy dużym także drobne. Ocenę rozkładu opiera się na wykresie kwantylowym i histogramie. Wykres kwantylowy zestawia uporządkowane wartości z kwantylami rozkładu normalnego standardowego; punkty wzdłuż prostej oznaczają zgodność z rozkładem normalnym.

Wykres kwantylowy względem rozkładu normalnego



Rysunek 3: Wykres kwantylowy względem rozkładu normalnego. Oś pozioma: kwantyle rozkładu normalnego standardowego; oś pionowa: uporządkowane wartości w minutach; linia przerywana przechodzi przez kwantyle. Lewy panel: sześć różnic par (od -4 do -1 minuty) leży blisko linii. Prawy panel: 142 czasy S02 leżą blisko linii w środku, a na prawym końcu wznoszą się wyraźnie powyżej linii aż do 33,8 minuty, co oznacza prawy ogon.

Rdzeń kursu używa wersji Welcha dla każdego porównania dwóch średnich; ocena projektu, wykresów, braków i wpływowych obserwacji towarzyszy każdej analizie.

Efekt standaryzowany i jego mianownik

Dla dwóch niezależnych grup różnicę dzieli się przez łączone SD:

$$s_p = \sqrt{\frac{(n_N - 1)s_N^2 + (n_D - 1)s_D^2}{n_N + n_D - 2}}, \quad d = \frac{\hat{\Delta}}{s_p} = \frac{4}{3,162} = 1,26.$$

Korekta Hedgesa zmniejsza obciążenie standaryzowanej różnicy w małych próbach:

$$g \approx \left(1 - \frac{3}{4(n_N + n_D) - 9}\right) d = 0,889 \cdot 1,26 = 1,14.$$

Mianownikiem g jest łączone SD osób (3,16 minuty), mianownikiem t_W — SE różnicy (2 minuty). Dlatego g opisuje wielkość względem rozrzutu osób, a t_W — relację różnicy do niepewności jej oszacowania. Przy nierównych wariancjach opis nazywa sposób standaryzacji i podaje różnicę w minutach.

Standaryzowana różnica jest duża, a jej oszacowanie nieprecyzyjne: przedział różnicy obejmuje wartości od $-0,61$ do $8,61$ minuty, a p przekracza $0,05$. Różne mianowniki efektów dla projektów niezależnych i zależnych opisuje Lakens (2013); opis efektu podaje projekt i definicję miary.


Test permutacyjny: tasowanie etykiet grup

Test permutacyjny (tasowanie etykiet) łączy wyniki obu grup, przypisuje etykiety grup na nowo z zachowaniem liczebności i ponownie liczy różnicę średnich. Dla dziesięciu czasów i dwóch grup po pięć istnieje $\binom{10}{5} = 252$ podziałów, więc rozkład zerowy daje się wyliczyć w całości:

$$D^* = \bar{x}_N^* - \bar{x}_D^*, \quad p = \frac{\#\{|D^*| \geq |D_{\text{obs}}|\}}{252} = \frac{32}{252} = 0,127.$$

Wszystkie podziały etykiet grup

Wszystkie układy: 252; $|T| \geq 4,00$: 32; $p = 32/252 = 0,127$



Rysunek 4: Wszystkie 252 podziały etykiet grup. Oś pozioma: różnica średnich D* w minutach; oś pionowa: liczba podziałów. Rozkład jest symetryczny wokół zera i leży od −5,6 do 5,6 minuty; linie przerywane przy −4 i 4 oznaczają obserwowaną różnicę i jej odbicie, a 32 podziały w wyróżnionych słupkach leżą na tych wartościach lub dalej.

Test permutacyjny daje $p = 0,127$, a test Welcha $p = 0,081$: dwie procedury opierają się na różnych rozkładach odniesienia, a przy pięciu osobach w grupie rozkład permutacyjny ma tylko 252 wartości. Uzasadnieniem przestawień jest wymienialność: przy H_0 każdy podział etykiet jest równie prawdopodobny. Wymienialność wymaga wspólnego rozkładu grup przy H_0 ; przy różnych wariancjach i nierównych liczebnościach tasowanie surowej różnicy średnich zmienia poziom α , a statystyka t_W jako miara skrajności (studentyzowany test permutacyjny) zachowuje poziom w przybliżeniu.

W grupach obserwacyjnych test permutacyjny sprawdza wymienialność etykiet; różnice wieku, zadań i wcześniejszego korzystania z usługi pozostają wyjaśnieniami alternatywnymi. Ćwiczenie C06 opisuje tor permutacyjny razem z ograniczeniem wynikającym z grup obserwacyjnych. Bootstrap różnicy losuje osoby z powtórzeniami osobno w każdej grupie, zachowuje przynależność do grupy i przybliża niepewność różnicy.

Te same osoby przed i po: analizujemy różnice

W drugim projekcie sześć osób (a–f) wykonuje zadanie przed instruktażem i po nim. Kierunek to „po minus przed”, więc liczba ujemna oznacza skrócenie. Parę definiuje osoba: identyfikator łączy czas przed i po, a N wynosi sześć par. Tabela „Sześć par przed i po” zawiera czas przed, po i różnicę każdej osoby.


Tabela 5: Sześć par przed i po instruktażu

Osoba	Przed [min]	Po [min]	Różnica po – przed [min]
a	6	5	-1
b	8	6	-2

Osoba	Przed [min]	Po [min]	Różnica po – przed [min]
c	10	9	-1
d	12	9	-3
e	14	12	-2
f	16	12	-4

Różnice wynoszą -1 , -2 , -1 , -3 , -2 i -4 minuty, a pytanie dotyczy ich średniej. Poziomy osób różnią się od 6 do 16 minut; sparowanie porównuje każdą osobę z nią samą.

Każda linia łączy dwa pomiary jednej osoby



Rysunek 5: Każda linia łączy dwa pomiary jednej osoby. Oś pozioma: pomiar przed i po; oś pionowa: czas w minutach. Sześć odcinków z etykietami a–f; wszystkie opadają, o 1 minutę (a, c), 2 minuty (b, e), 3 minuty (d) i 4 minuty (f).

Test t dla par jest testem jednej średniej różnic:

$$d_i = x_{i,\text{po}} - x_{i,\text{przed}}, \quad t = \frac{\bar{d}}{s_d / \sqrt{n_{\text{par}}}}.$$

Warunek normalności dotyczy rozkładu różnic d_i , a różnice osób są niezależne. Przy brakach analizę tworzą kompletne pary, a raport podaje ich liczbę. Sparowanie zmniejsza SE, bo SD różnic zależy od korelacji pomiarów tej samej osoby:

$$s_d^2 = s_{\text{przed}}^2 + s_{\text{po}}^2 - 2r s_{\text{przed}} s_{\text{po}},$$

gdzie r to korelacja czasów przed i po. Przy $s_{\text{przed}} = 3,74$, $s_{\text{po}} = 2,93$ i $r = 0,97$ otrzymujemy $s_d = 1,17$ minuty; SD dwunastu czasów połączonych w jedną kolumnę wynosi 3,40 minuty. Tabela „Test t dla par” podaje wynik w minutach zmiany.

Tabela 6: Test t dla par: po minus przed

Wielkość	Wartość
Liczba par	6
Średnia zmiana po – przed [min]	–2,17
SD różnic [min]	1,17
95% CI zmiany [min]	[–3,39; –0,94]
Statystyka t	–4,54
Stopnie swobody	5
Wartość p (dwustronna)	0,0062


Zmiana –2,17 minuty, 95% CI [–3,39; –0,94], $t(5) = -4,54$, $p = 0,0062$, łączy trzy mechanizmy: działanie instruktażu, zapamiętanie zadania i oswojenie z procedurą. Projekt z grupą kontrolną lub losową kolejnością warunków rozdziela trzy mechanizmy.

Test zmian znaków dla par zmienia znak różnicy wewnątrz osoby. Sześć par daje $2^6 = 64$ układy znaków:

$$\bar{d}^* = \frac{1}{6} \sum_{i=1}^6 \varepsilon_i d_i, \quad p = \frac{2}{64} = 0,031.$$

Wszystkie układy znaków sześciu różnic

Wszystkie układy: 64; $|T| \geq 2,17: 2$; $p = 2/64 = 0,031$



Rysunek 6: Wszystkie 64 układy znaków sześciu różnic. Oś pozioma: średnia różnica po zmianie znaków w minutach; oś pionowa: liczba układów. Rozkład jest symetryczny wokół zera i leży od –2,17 do 2,17 minuty; linie przerywane przy $\pm 2,17$ oznaczają obserwowaną średnią i jej odbicie, a dwa wyróżnione skrajne słupki zawierają po jednym układzie.


Dwa z 64 układów osiągają wartość $\pm 2,17$: wszystkie znaki ujemne (obserwowany układ) i wszystkie dodatnie. Wartość $p = 2/64 = 0,031$ jest najmniejszą osiągalną przy sześciu parach, więc rozdzielczość testu ogranicza liczba par; test t daje $p = 0,0062$ dzięki założeniu rozkładu t.

Rangi: porządek wyników i miara θ

Test sumy rang Wilcozona, nazywany też testem Manna–Whitneya, opiera się na położeniu obserwacji w uporządkowanym wspólnym zbiorze obu grup. Wartościom równym przypisuje się średnią ich rang. Miara probabilistyczna θ opisuje przewagę jednej grupy nad drugą:

$$\theta = P(X_N > X_D) + \frac{1}{2}P(X_N = X_D), \quad U = R_N - \frac{n_N(n_N + 1)}{2}, \quad \hat{\theta} = \frac{U}{n_N n_D},$$

gdzie R_N to suma rang grupy nowych. Dla czasu „wyższy” oznacza „dłuższy”. Wykres „25 par nowy–doświadczony” zestawia każdego nowego użytkownika z każdym doświadczonym.



Rysunek 7: 25 par nowy–doświadczony. Oś pozioma: czas nowego użytkownika (8–16 minut); oś pionowa: czas doświadczonego (4–12 minut). Każda komórka zawiera znak porównania: 19 komórek „>” (nowy dłużej), 3 komórki „=” (remis przy 8, 10 i 12 minutach) i 3 komórki „<” (doświadczony dłużej, w lewym górnym rogu); $\theta = (19 + 1,5)/25 = 0,82$.

W przykładzie $\hat{\theta} = (19 + 1,5)/25 = 0,82$; w konwencji R statystyka wynosi $W = U = 20,5$, a test z przybliżeniem normalnym daje $p = 0,114$. Wartość $\theta = 0,5$ oznacza równowagę porządku dwóch grup; rozkłady z $\theta = 0,5$ mogą różnić się rozrzutem. Test Manna–Whitneya sprawdza hipotezę $\theta = 0,5$, a odczyt wyniku jako przesunięcia mediany wymaga rozkładów o tym samym kształcie.

W teście rang podpisanych dla par wykorzystuje się znaki i rangi bezwzględnych różnic; odczyt wyniku jako przesunięcia zakłada symetrię rozkładu różnic. Szczegóły i definicje estymowanych wielkości podaje dokumentacja `wilcox.test`.

Pytanie wyznacza estymandę

Planowanie przeciętnego nakładu minut na obsługę wymaga średniej. Porównanie uporządkowania odpowiedzi porządkowych odpowiada pytaniu o θ . Wybór między średnią a rangami wynika z pytania; skośność wpływa na jakość przybliżenia.

Analiza dodatkowa nazywa swoją estymandę: test Welcha dotyczy różnicy średnich, test Manna–Whitneya — miary θ . Zgodne kierunki dwóch wyników opisują dwie estymandy.

Wiele grup: analiza wariancji

Trzy wersje katalogu wymagają porównania trzech średnich. W jednoczynnikowej analizie wariancji (ANOVA) hipoteza zerowa mówi o równości wszystkich średnich, a alternatywa — że co najmniej dwie średnie się różnią. Wskazanie pary wymaga kontrastów lub porównań par z kontrolą wielokrotności.


Suma kwadratów dzieli się na część między grupami i część wewnątrz grup, a średni kwadrat to suma kwadratów podzielona przez jej stopnie swobody:

$$SS_{\text{między}} = \sum_g n_g (\bar{x}_g - \bar{x})^2, \quad SS_{\text{wewn}} = \sum_g \sum_i (x_{gi} - \bar{x}_g)^2, \quad MS = \frac{SS}{df}, \quad F = \frac{MS_{\text{między}}}{MS_{\text{wewn}}}.$$

W demonstracji trzy grupy mają czasy A: 4, 5, 6; B: 7, 8, 9; C: 4, 6, 8 minut. Średnie grup wynoszą 5, 8 i 6 minut, a średnia ogólna 6,33 minuty; rachunek na dziewięciu osobach ilustruje wzory.

Trzy wersje katalogu

Linia przerywana: średnia ogólna 6,33




Rysunek 8: Trzy wersje katalogu. Oś pozioma: wersja A, B, C; oś pionowa: czas w minutach. Koła to czasy osób: A 4, 5, 6; B 7, 8, 9; C 4, 6, 8. Romby oznaczają średnie grup 5, 8 i 6 minut, linia przerywana średnią ogólną 6,33 minuty, a pionowe odcinki odległość średniej grupy od średniej ogólnej: 1,33 w dół dla A, 1,67 w górę dla B i 0,33 w dół dla C.

$SS_{\text{między}} = 3[(5 - 6,33)^2 + (8 - 6,33)^2 + (6 - 6,33)^2] = 14$, a $SS_{\text{wewn}} = 2 + 2 + 8 = 12$. Tabela „Analiza wariancji trzech grup” podaje MS równe 7 i 2 oraz $F = 7/2 = 3,5$ przy stopniach swobody 2 i 6.

Tabela 7: Analiza wariancji trzech grup

Źródło	SS	df	MS	F	p
Między grupami	14	2	7	3,50	0,0983
Wewnątrz grup	12	6	2		
Całkowita	26	8			

F jest liczbą bez jednostki: stosunkiem dwóch średnich kwadratów. Przy H_0 statystyka ma rozkład $F(k-1, N-k)$, tu $F(2, 6)$, a wartość krytyczna $F_{0,95;2,6} = 5,14$. Obserwowane 3,5 leży poniżej wartości krytycznej, a pole prawego ogona wynosi 0,098.



Rysunek 9: Prawy ogon rozkładu F z 2 i 6 stopniami swobody. Oś pozioma: statystyka F przy H_0 ; oś pionowa: gęstość. Krzywa maleje od zera i ma długi prawy ogon; wyróżnione pole na prawo od linii przerywanej przy 3,5 wynosi 0,0983.

$\eta^2 = SS_{\text{między}}/SS_{\text{całk}} = 14/26 = 0,538$ oznacza, że 53,8% sumy kwadratów odchyleń od średniej ogólnej przypada na różnice między średnimi grup. Klasyczna ANOVA zakłada niezależność i wspólną wariancję błędów; wersja Welcha dopuszcza różne wariancje, a test Kruskala–Wallisa porównuje rozkłady rang trzech grup. Powtarzane pomiary tych samych osób wymagają modelu zachowującego bloki osób. Kontrasty zaplanowane przed analizą raportuje się niezależnie od wyniku testu ogólnego; porównania par wybrane po obejrzeniu wyników wymagają kontroli wielokrotności, np. poprawki Holma.

Kategorie: najpierw tabela z liczebnościami


W osobnym przykładzie nowi mają 18 sukcesów na 30 osób, a doświadczeni 32 na 40. Jedna osoba wnosi jeden wynik w tabeli dwóch rozłącznych kategorii. Tabela „Sukces zadania w dwóch grupach” zawiera liczebności i sumy brzegowe: nowi — 18 sukcesów i 12 niepowodzeń (30 osób), doświadczeni — 32 i 8 (40 osób); łącznie 50 sukcesów i 20 niepowodzeń.

Tabela 8: Sukces zadania w dwóch grupach (liczebności)

Grupa	Sukces	Niepowodzenie	Suma
Nowi	18	12	30
Doświadczeni	32	8	40
Suma	50	20	70

W pierwszej grupie sukces odnosi 60%, w drugiej 80%. Różnica –20 punktów procentowych jest różnicą bezwzględną; względnie odsetek nowych stanowi 75% odsetka doświadczonych ($0,60/0,80 = 0,75$).

Liczba i odsetek sukcesów w grupach 30 i 40 osób



Rysunek 10: Liczba i odsetek sukcesów w grupach 30 i 40 osób. Lewy panel: liczba sukcesów — 18 z 30 nowych i 32 z 40 doświadczonych. Prawy panel: odsetek sukcesów w grupie — 60,0% nowych i 80,0% doświadczonych.

Udział nowych wśród wszystkich sukcesów, $18/50 = 36\%$, opisuje skład grupy sukcesów; skuteczność nowych opisuje odsetek $18/30 = 60\%$. Mianownik odpowiada zdaniu w raporcie.

Chi-kwadrat: porównujemy O z E

Przy niezależności grupy i wyniku oczekiwana liczebność komórki wynosi:


$$E_{ij} = \frac{n_{i.} \cdot n_{.j}}{N}.$$

Kropka zastępuje sumowanie po drugim indeksie: $n_{1.}$ to suma wiersza 1, a $n_{.1}$ — suma kolumny 1. W pierwszej komórce $E_{11} = 30 \cdot 50/70 = 21,43$ sukcesu nowych. Oczekiwana liczebność 21,43 jest wartością modelu niezależności i może być ułamkiem. Tabela „Liczebności oczekiwane przy niezależności” podaje: nowi 21,43 sukcesu i 8,57 niepowodzenia, doświadczeni 28,57 i 11,43; nowi mają 18 sukcesów, o 3,43 mniej od oczekiwanych.

Tabela 9: Liczebności oczekiwane przy niezależności

Grupa	Sukces	Niepowodzenie
Nowi	21,43	8,57
Doświadczeni	28,57	11,43

Liczebności obserwowane i oczekiwane



Rysunek 11: Liczebności obserwowane i oczekiwane. Dwa panele: nowi i doświadczeni; w każdym dwie komórki (sukces, niepowodzenie) z parą słupków: pełny obserwowany O i jasny oczekiwany E. Nowi: O 18 wobec E 21,43 sukcesu i O 12 wobec E 8,57 niepowodzenia. Doświadczeni: O 32 wobec E 28,57 i O 8 wobec E 11,43.

Statystyka chi-kwadrat sumuje wkłady komórek:

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}.$$

Kwadrat usuwa znak, a dzielenie przez E_{ij} odnosi odchylenie do skali oczekiwanej komórki. Statystyka χ^2 mierzy odległość tabeli od niezależności; kierunek odczytuje się z proporcji. Tabela „Wkłady komórek do χ^2 ” podaje wkłady 0,549 i 1,371 (nowi) oraz 0,411 i 1,029 (doświadczeni), suma 3,36. Największe wkłady mają komórki niepowodzeń, bo ich oczekiwane liczebności są mniejsze.

Tabela 10: Wkłady komórek do χ^2

Grupa	Sukces	Niepowodzenie
Nowi	0,549	1,371
Doświadczeni	0,411	1,029


Statystyka χ^2 rośnie proporcjonalnie do N przy stałych proporcjach, więc funkcja `chisq.test()` przyjmuje liczebności: tabela procentów ($N = 200$) daje $\chi^2 = 9,52$, a tabela liczebności ($N = 70$) — 3,36.

Rozkład chi-kwadrat

Rozkład chi-kwadrat o df stopniach swobody to rozkład sumy kwadratów df niezależnych zmiennych o rozkładzie normalnym standardowym:


$$\chi_{df}^2 = Z_1^2 + \dots + Z_{df}^2, \quad \chi_{0,95;1}^2 = 3,84 = 1,96^2.$$

Dla tabeli r na c stopnie swobody wynoszą $(r-1)(c-1)$; w tabeli 2×2 jest to 1. Wykres „Rozkłady χ^2 o 1, 2 i 4 stopniach swobody” przedstawia trzy krzywe.



Rysunek 12: Rozkłady χ^2 o 1, 2 i 4 stopniach swobody. Oś pozioma: wartość statystyki χ^2 od 0 do 12; oś pionowa: gęstość. Wszystkie krzywe mają prawy ogon; krzywa dla $df = 1$ (ciągła) jest najwyższa przy zerze, krzywa dla $df = 2$ (przerywana) maleje od 0,5, a krzywa dla $df = 4$ (kropkowo-kreskowa) ma szczyt przy 2. Wartości krytyczne 0,95 wynoszą 3,84; 5,99 i 9,49.

Przybliżenie rozkładem χ^2 wymaga dużych oczekiwanych liczebności; reguła praktyczna: każde $E_{ij} \geq 5$. W przykładzie $\chi^2(1) = 3,36$ leży poniżej wartości krytycznej 3,84, a $p = P(\chi_1^2 \geq 3,36) = 0,067$.



Rysunek 13: Prawy ogon rozkładu χ^2 z 1 stopniem swobody. Oś pozioma: statystyka χ^2 przy H_0 ; oś pionowa: gęstość. Krzywa maleje od zera; wyróżnione pole na prawo od linii przerywanej przy 3,36 wynosi 0,0668.

Test dwóch proporcji łączy rozkład normalny z rozkładem χ^2 :

$$z = \frac{\hat{p}_N - \hat{p}_D}{\sqrt{\bar{p}(1-\bar{p})\left(\frac{1}{n_N} + \frac{1}{n_D}\right)}} = -1,833, \quad z^2 = 3,36 = \chi^2, \quad \bar{p} = \frac{50}{70},$$

gdzie $\bar{p}$ to łączna proporcja sukcesu. W tabeli 2×2 test z i test χ^2 bez korekty ciągłości dają tę samą wartość p.

Fisher i Monte Carlo: inne rozkłady odniesienia

Test Fishera liczy p z rozkładu hipergeometrycznego przy ustalonych marginesach tabeli, więc działa przy małych liczebnościach; wymaga niezależnych jednostek i poprawnej tabeli. Rozkład hipergeometryczny podaje prawdopodobieństwo k sukcesów w pierwszym wierszu:

$$P(n_{11} = k) = \frac{\binom{n_{1\cdot}}{k} \binom{n_{2\cdot}}{n_{1\cdot}-k}}{\binom{N}{n_{1\cdot}}}.$$

Wersja Monte Carlo testu niezależności losuje tabele o tych samych sumach wierszy i kolumn i porównuje ich statystykę χ^2 z obserwowaną; schemat i rolę B określa dokumentacja chisq.test. Tabela „Trzy procedury dla tabeli 18/30 i 32/40” zestawia wyniki: $\chi^2 = 3,36$, df = 1, p = 0,0668 (bez korekty ciągłości); Monte Carlo p = 0,108 (B = 1999); Fisher p = 0,108.

Tabela 11: Trzy procedury dla tabeli 18/30 i 32/40

Procedura	Statystyka	Wartość p
χ^2 bez korekty ciągłości	$\chi^2(1) = 3,36$	0,0668
Monte Carlo (B = 1999, marginesy stałe)	$\chi^2 = 3,36$	0,108
Dokładny test Fishera	—	0,108
Test z dwóch proporcji	$z = -1,833$; $z^2 = 3,36$	0,0668

Przybliżenie χ^2 daje mniejsze p niż dwie procedury warunkowe. Raport podaje metodę wybraną przed analizą i pozostałe wyniki jako analizę wrażliwości.

W tabeli rzadkiej pierwsza grupa ma 1 sukces na 10, druga 7 na 10. Tabela „Tabela rzadka” zawiera: nowi — 1 sukces i 9 niepowodzeń, doświadczeni — 7 i 3; łącznie 8 sukcesów i 12 niepowodzeń.


Tabela 12: Tabela rzadka (liczebności)

Grupa	Sukces	Niepowodzenie	Suma
Nowi	1	9	10
Doświadczeni	7	3	10
Suma	8	12	20

Jakość przybliżenia ocenia się po liczebnościach oczekiwanych: oczekiwane liczebności sukcesów wynoszą po 4, poniżej progu 5. Przy marginesach 10, 10, 8 i 12 rozkład hipergeometryczny n_{11} obejmuje wartości od 0 do 8.

Rozkład hipergeometryczny tabeli rzadkiej

Wyróżnione wartości 0, 1, 7, 8: łącznie 0,020



Rysunek 14: Rozkład hipergeometryczny tabeli rzadkiej: liczba sukcesów nowych n11 przy marginesach 10, 10, 8 i 12. Oś pozioma: n11 od 0 do 8; oś pionowa: prawdopodobieństwo. Słupki są symetryczne wokół 4 (0,350); wyróżnione słupki 0, 1, 7 i 8 mają prawdopodobieństwa 0,0004; 0,0095; 0,0095 i 0,0004, łącznie 0,020.

Słowo „dokładny” oznacza, że p wynika z pełnego rozkładu hipergeometrycznego; dwustronne p sumuje prawdopodobieństwa tabel o prawdopodobieństwie mniejszym lub równym obserwowanemu: $P(0) + P(1) + P(7) + P(8) = 0,020$. Szczegóły podaje dokumentacja fisher.test.

Wielkość związku: V oraz kierunkowe różnice

V Craméra ma postać:

$$V = \sqrt{\frac{\chi^2}{N \min(r-1, c-1)}} = \sqrt{\frac{3,36}{70}} = 0,219.$$

W tabeli 2×2 mianownik pod pierwiastkiem upraszcza się do N. V = 0,219 opisuje siłę związku na skali od 0 (niezależność) do 1 (pełna zależność); kierunek podaje różnica proporcji. Iloraz proporcji i iloraz szans zapisuje się z liczebnościami komórek:

$$RR = \frac{\hat{p}_N}{\hat{p}_D} = \frac{0,60}{0,80} = 0,75, \quad OR = \frac{n_{11}/n_{12}}{n_{21}/n_{22}} = \frac{n_{11}n_{22}}{n_{12}n_{21}} = \frac{18 \cdot 8}{12 \cdot 32} = 0,375.$$

Tabela „Miary efektu dla tabeli 2×2” zachowuje kierunek nowi względem doświadczonych: różnica −0,20, 95% CI [−0,415; 0,015] (przybliżenie Walda bez korekty ciągłości), iloraz proporcji 0,75, iloraz szans 0,375, V = 0,219.

Tabela 13: Miary efektu dla tabeli 2×2


Miara	Wartość
Różnica proporcji nowi — doświadczeni	−0,20
95% CI różnicy (Wald)	[−0,415; 0,015]

Miara	Wartość
Iloraz proporcji RR	0,75
Iloraz szans OR	0,375
V Craméra	0,219

Szansa sukcesu to stosunek sukcesów do niepowodzeń: 1,5 u nowych (18/12) i 4 u doświadczonych (32/8). Przy częstym sukcesie iloraz szans (0,375) leży dalej od 1 niż iloraz proporcji (0,75). Wykres „Iloraz proporcji 0,75 a iloraz szans” przedstawia obie miary przy stałym ilorazie proporcji.

Iloraz proporcji 0,75 a iloraz szans

Linia kropkowana: 80% sukcesów doświadczonych w przykładzie



Rysunek 15: Iloraz proporcji 0,75 a iloraz szans. Oś pozioma: odsetek sukcesów w grupie odniesienia od 5 do 95%; oś pionowa: wartość ilorazu. Linia ciągła RR pozostaje przy 0,75; linia przerywana OR wynosi 0,74 przy 5% sukcesów i maleje coraz szybciej, do 0,375 przy 80% (linia kropkowana).

Przy rzadkim sukcesie obie miary są bliskie; przy odsetkach powyżej 50% iloraz szans oddala się od ilorazu proporcji, więc raport nazywa użytą miarę.

Przedział bootstrapowy dla V

Prosty percentylowy przedział bootstrapowy V ma dodatnią dolną granicę także przy niezależności w populacji, bo V jest ograniczone od dołu zerem, a losowe próby odchylają się od dokładnej niezależności. Percentylowy przedział bootstrapowy V opisuje zmienność V; związek testuje się testem χ^2 , Fishera lub Monte Carlo. Ćwiczenie C07 przedstawia niepewność różnicy proporcji i osobno opisową miarę V.

Cztery pytania do czytania artykułu LIS

Pierwszy artykuł podaje średni czas dwóch grup i pomija opis powiązań pomiarów. Mianownik statystyki t zależy od tego, czy grupy tworzą inne osoby, czy te same osoby w dwóch zadaniach, więc pierwsze pytanie brzmi: kogo porównano?

Drugi artykuł nazywa wynik testu rangowego różnicą średnich. Test rangowy dotyczy miary θ , więc drugie pytanie brzmi: jaką estymandę ma metoda i jak autor definiuje efekt?

Trzeci artykuł przedstawia χ^2 i p bez tabeli. Kierunek i skalę różnicy skuteczności podają liczebności, proporcje i miara efektu, więc trzecie pytanie brzmi: jakie są liczebności komórek?

Czwarty artykuł pisze, że doświadczenie „wpływa” na skuteczność na podstawie grup obserwacyjnych.

Wniosek przyczynowy wymaga projektu przyczynowego; poprawny opis związku jest pełnowartościowym wynikiem.

Most do ćwiczeń C06 i C07

Ćwiczenie C06 porównuje dwie grupy z jednym ustalonym kierunkiem efektu, testem Welcha, przedziałami i testem permutacyjnym. Ćwiczenie C07 przechodzi od liczebności do proporcji, liczebności oczekiwanych, testu niezależności i efektu. Każde ćwiczenie zachowuje własne mianowniki i ograniczenia.

Pełne zdanie wyniku daje się sprawdzić w tabeli. Odpowiedź na problem biblioteki podaje wielkość, niepewność oraz grupy i warunki porównania.

Literatura do dalszej pracy

- Lakens, D. (2013). *Calculating and reporting effect sizes to facilitate cumulative science: a practical primer for t-tests and ANOVAs*. *Frontiers in Psychology*, 4, 863. DOI.
- Winkler, A.M., Ridgway, G.R., Webster, M.A., Smith, S.M., Nichols, T.E. (2014). *Permutation inference for the general linear model*. *NeuroImage*, 92, 381–397. Pełny tekst.
- Dokumentacja R: `wilcox.test`, `chisq.test`, `fisher.test`.

Przykłady liczbowe wykładu są dydaktyczne; wyniki cytowanych prac zawierają ich publikacje.