

W04 — Kogo z kim porównujemy: średnie, pary i kategorie

Zarządzanie informacją — wykład — 2026/27

Marek Deja

2026/27

Spis treści

Jedna usługa, trzy projekty porównania	1
Projekt przed nazwą testu	2
Różnica średnich ma ustalony kierunek	2
Mały przykład czasu	2
Test Welcha: niepewność z obu grup	3
Przedział, t i p w jednej historii	3
Dlaczego nie wybieramy testu tylko po p z testu założeń	4
Efekt standaryzowany i jego mianownik	4
Permutacja etykiet: co musi być wymienialne	5
Te same osoby przed i po: analizujemy różnice	5
Rangi: inne spojrzenie, nie automatyczny test median	6
Jak wybrać pytanie, nie tylko nazwę	7
Wiele grup: co mówi test ogólny	7
Kategorie: najpierw tabela z liczebnościami	8
Chi-kwadrat: porównujemy O z E	8
Fisher i Monte Carlo: inne rozkłady odniesienia	9
Wielkość związku: V oraz kierunkowe różnice	10
Ostrożnie z przedziałem bootstrapowym dla V	11
Cztery pytania do czytania artykułu LIS	11
Most do C06 i C07	11

Skrypt towarzyszący oblicza małe demonstracje porównań. Są to osobne dane syntetyczne, nie rekordy wspólnego S02. Wszystkie znaki i przedziały wynikają z jawnie zapisanej kolejności odejmowania.

Jedna usługa, trzy projekty porównania

Biblioteka chce poprawić korzystanie z katalogu. Może porównać nowych i doświadczonych użytkowników, zaprosić te same osoby do zadania przed instruktażem i po nim albo losowo przydzielić dwie wersje pomocy. W każdym projekcie pojawia się słowo „porównanie”, lecz nie ta sama informacja.

Istniejące grupy mogą różnić się wieloma cechami. Przed–po zachowuje osobę, ale łączy zmianę usługi z uczeniem się i upływem czasu. Losowy przydział warunku może wzmacniać wniosek przyczynowy, jeśli wykonanie badania respektuje założenia. Żaden z tych projektów nie zapewnia automatycznie uogólnienia na wszystkich użytkowników.

Na wykładzie najpierw rozpoznajemy jednostkę i strukturę danych. Następnie uczymy się różnicy średnich oraz testu Welcha, porównania par i tabeli kategorii. Testy rangowe oraz wiele grup tworzą mapę do czytania literatury; ich szczegółowa implementacja nie jest rdzeniem C06–C07.

W 90 minut przeznaczamy około 15 na projekty, 25 na średnie i niepewność, 10 na pary, 25 na kategorie oraz 15 na dobór języka i dyskusję. Fragmenty o rangach, wielu grupach i ilorazach stanowią także materiał do powtórki.

Projekt przed nazwą testu

Sytuacja	Jednostka i powiązanie	Co porównujemy?
Nowi i doświadczeni	Inne osoby w dwóch grupach	Średnie lub rozkłady wyników
Ta sama osoba przed i po	Para pomiarów jednej osoby	Zmianę wewnątrz osoby
Dwa warunki losowane	Osoby przydzielone według projektu	Wyniki między warunkami
Powodzenie w dwóch grupach	Jedna kategoria wyniku osoby	Proporcje lub strukturę tabeli
Trzy wersje usługi	Trzy grupy albo powtarzane warunki	Zależnie od schematu badania

Równa liczebność grup nie oznacza sparowania. Dziesięciu nowych i dziesięciu doświadczonych użytkowników to nadal dwie niezależne grupy, jeśli nie istnieje merytoryczna para. Odwrotnie, brak jednego pomiaru po zadaniu nie zamienia pozostałych par w niezależne osoby.

Niezależność ustala projekt, nie test normalności. Wiele prób tej samej osoby albo użytkownicy pracujący wspólnie w grupach mogą tworzyć zależności. Użycie prostego wzoru z N równym liczbie wierszy może wtedy dać nadmiernie wąskie przedziały.

Różnica średnich ma ustalony kierunek

W porównaniu nowych i doświadczonych przyjmujemy:

$$\Delta = \mu_N - \mu_D, \quad \widehat{\Delta} = \bar{x}_N - \bar{x}_D.$$

Indeksy N i D oznaczają grupy, nie liczebność. Liczebności zapisujemy n_N i n_D . Dodatnia różnica czasu oznacza, że nowi potrzebowali przeciętnie więcej minut. Dodatnia różnica indeksu oznacza wyższą deklarowaną ocenę w kierunku skali. Sens znaku zależy od wyniku, nie od samego testu.

Hipoteza zerowa standardowego porównania średnich to $H_0 : \Delta = 0$. Dwustronna alternatywa dopuszcza różnicę w obu kierunkach. W materiale zawsze sprawdzamy, czy znak estymaty zgadza się ze znakiem statystyki t oraz położeniem przedziału.

Mały przykład czasu


Nowi mają czasy 8, 10, 12, 14 i 16 minut, a doświadczeni 4, 6, 8, 10 i 12. Każda wartość dotyczy innej osoby. Zestawienie pokazuje N , średnią i SD w obu grupach.

grupa	N	średnia	SD
Nowi	5	12	3.162
Doświadczeni	5	8	3.162

Średnie różnią się o 4 minuty, ale część indywidualnych czasów się pokrywa. To nie sprzeczność. Różnica grupowa nie oznacza, że każdy nowy użytkownik ma dłuższy czas od każdego doświadczonego.

Na wykresie każda kropka oznacza osobę. Odczytaj wspólne wartości 8, 10 i 12 minut oraz przesunięcie całych zestawów. Same kropki nie mówią, dlaczego grupy się różnią.

Czasy w dwóch niezależnych grupach



Jeżeli celem biblioteki jest wsparcie wszystkich osób z długimi próbami, sama etykieta grupy może być niewystarczająca do kwalifikacji pomocy. Opis rozkładów pomaga dostrzec zróżnicowanie wewnątrz każdej grupy. Późniejszy test nie unieważnia tej informacji.

Test Welcha: niepewność z obu grup

$$SE(\hat{\Delta}) = \sqrt{\frac{s_N^2}{n_N} + \frac{s_D^2}{n_D}}, \quad t_W = \frac{\hat{\Delta} - 0}{SE(\hat{\Delta})}.$$

W C05 porównywaliśmy średnią ze znaną liczbą. Teraz obie średnie są oszacowane. Ich niepewności w standardowym modelu niezależnych grup składają się pod pierwiastkiem. Większy rozrzut lub mniejsze N w którejkolwiek grupie może zwiększać SE różnicy.

Welch nie wymaga równości wariancji grupowych. Nie oznacza to braku innych warunków: nadal potrzebujemy właściwej jednostki, niezależności i odpowiedniego uzasadnienia rozkładowego lub przybliżenia. Bardzo małe skośne próby z wpływowymi obserwacjami wymagają ostrożności.

Stopnie swobody są wyznaczone przybliżeniem:

$$\nu = \frac{(s_N^2/n_N + s_D^2/n_D)^2}{\frac{(s_N^2/n_N)^2}{n_N - 1} + \frac{(s_D^2/n_D)^2}{n_D - 1}}.$$

Nie musimy liczyć tego wzoru ręcznie, ale powinniśmy rozumieć, dlaczego df może być niecałkowite. To wynik przybliżenia uwzględniającego niepewność wariancji, nie błąd eksportu. Nie zaokrąglamy df do liczby osób przed obliczeniem p.

Przedział, t i p w jednej historii

Przedział różnicy ma postać $\hat{\Delta} \pm t_{0,975;\nu} SE$. W małym przykładzie $SE=2$ minuty, $t=2$, a $df=8$. Przedział jest szeroki, ponieważ obie grupy liczą tylko po pięć osób.

Tabela rozdziela efekt, SE, granice przedziału, statystykę i p. Wszystkie wielkości dotyczą kierunku nowi minus doświadczeni. Odczytaj znak przed spojrzeniem na istotność.

wielkosc	wartosc
roznica_nowi_minus_doswiadczeni	4
SE	2
CI_dol	-0.612
CI_gora	8.612
t	2
df	8
p	0.0805
Hedges_g	1.1425

Otrzymujemy różnicę 4 minut z 95% CI około $[-0,61; 8,61]$ minuty i p około 0,081. Jest to dodatnia estymata z dużą niepewnością. Nie wolno napisać, że czas jest identyczny w populacjach, ani że doświadczenie na pewno skraca go o 4 minuty.

W tym modelu wartości zgodne z przedziałem obejmują zarówno niewielką różnicę przeciwną, jak i duże wydłużenie czasu u nowych. Wynik może być ważny jako sygnał do lepiej zaprojektowanego badania. Nie jest wystarczającą podstawą do kategorycznego przypisania przyczyny.

Dlaczego nie wybieramy testu tylko po p z testu założeń

Test Shapiro–Wilka może informować o odchyleniu od normalności, ale nie mierzy wszystkich problemów wnioskowania. Przy małym N może nie wykryć ważnej cechy rozkładu, a przy dużym wykryć drobną. Nie traktujemy $p > 0,05$ jako dowodu normalności.

Analogicznie test wariancji nie jest automatycznym przełącznikiem między dowolnymi analizami. W rdzeniu porównania średnich używamy jawnie wybranej wersji Welcha. Ocenę projektu, wykresów, braków i wpływowych obserwacji wykonujemy niezależnie od tego wyboru.

Efekt standaryzowany i jego mianownik

Dla dwóch niezależnych grup można podzielić różnicę przez łączone SD:

$$s_p = \sqrt{\frac{(n_N - 1)s_N^2 + (n_D - 1)s_D^2}{n_N + n_D - 2}}, \quad d = \frac{\widehat{\Delta}}{s_p}.$$

Korekta Hedgesa ogranicza obciążenie małopróbkowego estymatora standaryzowanej różnicy w odpowiednim modelu. W kursie wykorzystujemy przybliżenie:

$$g \approx \left(1 - \frac{3}{4(n_N + n_D) - 9}\right) d.$$

Nie jest to ten sam mianownik co SE Welcha. Dlatego g opisuje wielkość względną do rozrzutu osób, a t relację różnicy do niepewności jej oszacowania. Przy nierównych wariancjach warto szczególnie jasno nazwać sposób standaryzacji i zachować naturalną różnicę na pierwszym planie.

W małym przykładzie g wynosi około 1,14, mimo że dwustronne p przekracza 0,05. To możliwe: standaryzowana różnica może być duża, a jej oszacowanie nieprecyzyjne. Nie zastępujemy przedziału etykietą „duży efekt”.

Różne mianowniki efektów dla projektów niezależnych i zależnych trzeba odróżniać także przy czytaniu publikacji. Lakens (2013) jest przydatnym źródłem dotyczącym ich raportowania. Własny opis musi podawać projekt i zastosowaną definicję, nie tylko literę d .

Permutacja etykiet: co musi być wymienialne

W dwóch niezależnych grupach możemy połączyć wyniki, losowo przestawić etykiety z zachowaniem liczebności i ponownie policzyć różnicę średnich. Powtarzamy tę samą statystykę w tych samych jednostkach. Dwustronną skrajność oceniamy przez wartość bezwzględną.

Uzasadnienie wymaga dopuszczalności takich przestawień pod rozpatrywaną hipotezą zerową. W prostym modelu dwóch prób wspólny rozkład pod H_0 daje wymienialność. W eksperymencie regułę przestawień może wyznaczać rzeczywisty mechanizm losowego przydziału i odpowiednia hipoteza randomizacyjna.

Równość samych średnich nie gwarantuje wspólnego rozkładu. Jeśli wariancje znacznie się różnią, zwłaszcza przy nierównych liczebnościach, surowe tasowanie różnicy średnich nie jest automatycznie odpornym odpowiednikiem Welcha. Istnieją odpowiednio standaryzowane i asymptotyczne procedury, ale nie należy przypisywać ich własności prostemu algorytmowi.

W obserwacyjnych grupach nowi–doświadczeni samo przetasowanie etykiet nie tworzy randomizowanego badania. Nawet poprawnie uzasadniony test nie usuwa różnic wieku, zadań czy wcześniejszego korzystania z usługi. W C06 opiszemy tor losowany wraz z jego ograniczeniem.

Bootstrap różnicy działa inaczej: losujemy osoby z powtórzeniami osobno w każdej grupie, zachowując jej tożsamość. Powstaje przybliżenie niepewności różnicy. Nie zrywamy w nim związku między grupą a wynikiem po to, by narzucić zero.

Te same osoby przed i po: analizujemy różnice


W drugim projekcie sześć osób wykonuje zadanie przed instruktażem i po nim. Dane mają identyfikator osoby oraz dwa czasy. Wybieramy kierunek po minus przed, zatem liczba ujemna oznacza skrócenie.

Tabela pokazuje każdy rekord i jego różnicę. Nie dobieramy par przez sortowanie czasów; parę definiuje osoba. N wynosi sześć par, nie dwanaście niezależnych respondentów.

osoba	przed	po	roznica_po_minus_przed
a	6	5	-1
b	8	6	-2
c	10	9	-1
d	12	9	-3
e	14	12	-2
f	16	12	-4

Różnice to -1 , -2 , -1 , -3 , -2 i -4 minuty. Pytanie dotyczy średniej tych różnic. Wcześniejsze poziomy osób mogą się mocno różnić, ale dzięki sparowaniu porównujemy każdą osobę z nią samą.

Wykres zachowuje połączenia między pomiarami. Linie pokazują, kto zmienił wynik i o ile. Odczytaj kierunek sześciu zmian bez nazywania go jeszcze skutkiem instruktażu.



Test t dla par jest testem jednej średniej różnic:

$$d_i = x_{i,\text{po}} - x_{i,\text{przed}}, \quad t = \frac{\bar{d}}{s_d / \sqrt{n_{\text{par}}}}.$$

Warunek normalności dla dokładnego modelu dotyczy rozkładu różnic, nie osobno obu surowych kolumn. Różnice między osobami powinny być niezależne. Przy brakach analizę tworzą kompletne pary, których N należy podać.

Wynik odczytujemy w minutach zmiany. Przedział i t mają kierunek zgodny z po minus przed. Zauważ, że SD różnic jest inną liczbą niż SD wszystkich czasów połączonych w jedną kolumnę.

wielkosc	wartosc
N_par	6
zmiana	-2.1667
SD_roznic	1.169
CI_dol	-3.3935
CI_gora	-0.9398
t	-4.5398
df	5
p	0.00617

Średnia zmiana wynosi około $-2,17$ minuty. Nie wynika z tego automatycznie, że instruktaż ją spowodował: osoby mogły zapamiętać zadanie lub oswoić się z procedurą. Projekt z kontrolą lub losowaniem kolejności może lepiej rozdzielać te mechanizmy.

W torze zmian znaków dla par przekształcamy różnice wewnątrz osób przy odpowiednim uzasadnieniu symetrii lub randomizacji. Nie tasujemy wszystkich pomiarów dowolnie między osobami. Struktura projektu określa, co wolno zmienić.

Rangi: inne spojrzenie, nie automatyczny test median

Jeśli interesuje nas porządek wyników, możemy użyć rang. W dwóch niezależnych grupach test sumy rang Wilcozona, nazywany też testem Manna–Whitneya, opiera się na położeniu obserwacji w uporząd-

kowanym wspólnym zbiorze. Remisy wymagają odpowiedniego uwzględnienia w obliczeniu.

Użyteczną miarą probabilistyczną jest:

$$\theta = P(X_N > X_D) + \frac{1}{2}P(X_N = X_D).$$

Szacujemy, jak często losowo wybrany nowy użytkownik ma wyższy wynik od losowo wybranego doświadczonego, z połową wagi dla remisu. Dla czasu „wyższy” oznacza dłuższy, a nie lepszy. Wartość 0,5 tej miary nie zapewnia identyczności wszystkich cech rozkładów.

Standardowy rangowy test zerowy ma warunki dotyczące rozkładów i wymienialności. Nie jest uniwersalnym testem równości samych median. Interpretacja jako przesunięcie położenia lub różnica median wymaga dodatkowych warunków, takich jak porównywalny kształt. Dwie grupy mogą mieć tę samą medianę, a inną strukturę rang.

W parowanym teście rang podpisanych wykorzystuje się znaki i rangi bezwzględnych różnic. Również tu ważna jest symetria dla typowej interpretacji przesunięcia. Nie jest to automatycznie metoda bez warunków dla dowolnego zbioru różnic. Szczegóły i definicje estymowanych wielkości podaje dokumentacja `wilcox.test`.

Jak wybrać pytanie, nie tylko nazwę

Jeśli biblioteka planuje przeciętny nakład minut na obsługę, średnia ma bezpośrednią interpretację. Jeśli porównuje uporządkowanie odpowiedzi porządkowych, podejście rangowe może odpowiadać innemu sensownemu pytaniu. Samo stwierdzenie skończoności nie rozstrzyga, który cel jest ważniejszy.

Można przedstawić analizę dodatkową, ale trzeba nazwać zmianę estymandy lub hipotezy. Nie piszemy, że dwa testy „potwierdzają tę samą średnią”, jeśli jeden nie testuje średniej. Zgodne kierunki są informacją, lecz nie usuwają różnicy pytań.

Wiele grup: co mówi test ogólny

Trzy wersje katalogu mogą wymagać porównania trzech średnich. W klasycznej jednoczynnikowej analizie wariancji hipoteza zerowa mówi o równości wszystkich średnich. Alternatywa: nie wszystkie są równe. Wynik ogólny nie identyfikuje automatycznie różniące się pary.

$$F = \frac{MS_{\text{między}}}{MS_{\text{wewnątrz}}}.$$

W liczniku znajduje się zmienność średnich grupowych przeliczona na odpowiednie stopnie swobody, w mianowniku zmienność wewnątrz grup. F jest ilorazem, nie różnicą w minutach. Dlatego obok niego potrzebujemy średnich, kontrastów i ich niepewności.

W dodatkowej małej demonstracji trzy grupy mają czasy A: 4, 5, 6; B: 7, 8, 9; C: 4, 6, 8. Tabela pokazuje rozkład sum kwadratów i statystykę ogólną. Jest to ćwiczenie rachunku przy klasycznym modelu, nie ocena stabilnego rezultatu z dziewięciu osób.

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Między grupami	2	14	7	3.5	0.098
Wewnątrz grup	6	12	2	NA	NA

Suma kwadratów między grupami wynosi 14, a wewnątrz 12. Przy df równych 2 i 6 otrzymujemy $F=3.5$. Udział międzygrupowej sumy kwadratów w całkowitej, $\eta^2 = 14/26 \approx 0.538$, jest opisem zróżnicowania w tym modelu, nie procentem osób, którym pomogła usługa.

Klasyczna ANOVA zakłada między innymi odpowiednią niezależność i wspólną wariancję błędów. Wersja Welcha pozwala na nierówność wariancji, a test Kruskala–Wallisa pracuje na rangach i nie jest automatycznie testem średnich ani samych median. Powtarzane pomiary tych samych osób wymagają osobnego modelu lub procedury zachowującej bloki.

Zaplanowane kontrasty można analizować zgodnie z wcześniej określoną procedurą; nie zawsze wymagają uprzednio istotnego testu ogólnego. Natomiast wybieranie po wyniku wielu par i raportowanie tylko korzystnej wymaga kontroli wielokrotności oraz uczciwego opisu. Sama istotna ANOVA nie legalizuje dowolnej liczby niekorygowanych testów.

Kategorie: najpierw tabela z liczebnościami

Przechodzimy od czasu do powodzenia zadania. W osobnym przykładzie nowi mają 18 sukcesów na 30 osób, a doświadczeni 32 na 40. Jedna osoba wnosi jeden wynik w tabeli dwóch rozłącznych kategorii.


Tabela zawiera liczebności, nie procenty. Sumy wierszy to liczebności grup, a sumy kolumn pokazują łączną liczbę sukcesów i niepowodzeń. Zanim obliczymy test, trzeba sprawdzić te mianowniki.

	Sukces	Niepowodzenie
Nowi	18	12
Doświadczeni	32	8

W pierwszej grupie sukces odnosi 60%, w drugiej 80%. Różnica nowi minus doświadczeni wynosi -20 punktów procentowych. To nie znaczy, że nowi mają o 20% mniej sukcesów w sensie względnym, ani że każdy nowy użytkownik radzi sobie gorzej.

Wykres pokazuje udziały na wspólnej osi 0–100%. Podpis nad słupkiem zawiera licznik i mianownik. Liczby bezwzględne oraz procenty służą odmiennym pytaniom, więc zachowujemy obie informacje.

Porównanie udziałów z jawnymi mianownikami



Jeśli zamiast procentu w grupie obliczylibyśmy udział nowych wśród wszystkich sukcesów, otrzymalibyśmy inne pytanie. To nadal dopuszczalny opis, lecz nie miara skuteczności nowych. Mianownik musi odpowiadać zdaniu w raporcie.

Chi-kwadrat: porównujemy O z E

Przy niezależności grupy i wyniku oczekiwana liczebność komórki wynosi:

$$E_{ij} = \frac{n_{i.}n_{.j}}{N}.$$

W pierwszej komórce oczekivalibyśmy $30 \cdot 50/70 \approx 21,43$ sukcesu nowych, gdyby udziały wynikały z niezależności przy tych marginesach. Ułamkowa oczekiwana liczebność jest poprawna: to wartość modelowa, nie część konkretnej osoby.

Tabela oczekiwań odpowiada tej samej strukturze co tabela obserwacji. Porównaj komórki zamiast tylko sum wierszy. Sumy są zachowane, ale rozmieszczenie sukcesów może odbiegać od niezależności.

	Sukces	Niepowodzenie
Nowi	21.43	8.57
Doświadczeni	28.57	11.43

Statystyka sumuje wkłady:

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}.$$

Kwadrat usuwa znak, a podzielenie przez E odnosi odchylenie do skali oczekiwanej komórki. Chi-kwadrat nie mówi więc samo, która grupa ma wyższą skuteczność. Kierunek odczytujemy z proporcji i różnic.

Poniżej każdy element tabeli jest wkładem do sumy chi-kwadrat. Zwróć uwagę, że podobna różnica liczebności może mieć większy wkład przy mniejszym E. To jeden z powodów, dla których nie podajemy do funkcji tabeli procentów zamiast liczebności.

	Sukces	Niepowodzenie
Nowi	0.549	1.371
Doświadczeni	0.411	1.029

Dla tabeli r na c stopnie swobody wynoszą $(r-1)(c-1)$. W 2 na 2 jest to 1. W standardowym przybliżeniu porównujemy obliczoną statystykę z odpowiednim rozkładem chi-kwadrat. Przy małych oczekiwanych liczebnościach przybliżenie może być niewłaściwe.

Fisher i Monte Carlo: inne rozkłady odniesienia

Dokładny test Fishera dla tabeli 2 na 2 wyznacza wynik warunkowo przy ustalonych marginesach. Nie wymaga użycia dużopróbkowego przybliżenia chi-kwadrat dla rzadkich komórek. Nadal wymaga odpowiedniego projektu, niezależnych jednostek i poprawnej tabeli.

W wersji Monte Carlo testu niezależności losujemy tabele przy ustalonych marginesach i porównujemy ich statystykę chi-kwadrat z obserwowaną. Nie jest to bootstrap respondentów ani tworzenie tabel o dowolnych sumach. Dokumentacja `chisq.test` określa ten schemat i rolę B.

Tabela zestawia wyniki dla przykładu 18/30 i 32/40. Klasyczny chi-kwadrat obliczono bez korekty ciągłości; metoda i korekta są częścią opisu. Różnice między p nie dają prawa wyboru najniższej wartości po obejrzeniu wyniku.

wielkosc	wartosc
chi2	3.36
df	1
p_chi2	0.0668

wielkosc	wartosc
p_MC	0.108
p_Fisher	0.108
B	1999

Dla rzadkiej tabeli wybór procedury staje się szczególnie ważny. W kolejnej demonstracji pierwsza grupa ma 1 sukces na 10, druga 7 na 10. Oczekiwane liczebności sukcesów wynoszą po 4, więc część komórek jest mała.

	Sukces	Niepowodzenie
Nowi	1	9
Doświadczeni	7	3

Sama obecność małej liczby obserwowanej nie jest całą diagnozą; w chi-kwadrat sprawdzamy oczekiwania. Praktyczne reguły liczebności są wskazówką jakości przybliżenia, nie prawem interpretacji. Dla tej małej tabeli można sięgnąć po dokładny test Fishera i jasno podać używaną metodę.

Wynik Fishera ma warunkową interpretację i własną definicję dwustronnej skrajności. Nie jest dokładnym odpowiednikiem dowolnego innego p wyłącznie z powodu słowa „dokładny”. Szczegóły znajdują się w dokumentacji `fisher.test`.

Wielkość związku: V oraz kierunkowe różnice

V Craméra ma postać:

$$V = \sqrt{\frac{\chi^2}{N \min(r-1, c-1)}}.$$

W tabeli 2 na 2 mianownik pod pierwiastkiem upraszcza się do N . V jest nieujemne i nie ma jednostki. Nie mówi, która grupa ma większy odsetek, ani nie oznacza procentu sukcesów czy procentu wyjaśnionej zmienności.

Dla dwóch proporcji warto pokazać naturalną różnicę. Można także obliczyć ich iloraz albo iloraz szans, ale są to różne miary. Poniższe zestawienie zachowuje kierunek nowi względem doświadczonych; CI dotyczy różnicy proporcji z przybliżenia bez korekty ciągłości.

wielkosc	wartosc
roznica_proporcji	-0.2
CI_dol	-0.4147
CI_gora	0.0147
iloraz_proporcji	0.75
iloraz_szans	0.375
V	0.2191

Iloraz proporcji $0,60/0,80 = 0,75$ oznacza, że udział sukcesów nowych stanowi 75% udziału doświadczonych, czyli jest względnie o 25% niższy. Różnica bezwzględna nadal wynosi -20 punktów procentowych.

Szanse sukcesu to stosunek sukcesów do niepowodzeń. Iloraz szans wynosi $(18/12)/(32/8) = 0,375$. Nie oznacza proporcji sukcesu 37,5% ani takiego samego ilorazu prawdopodobieństw. Przy częstym wyniku szansy i prawdopodobieństwo wyraźnie się różnią.

Ostrożnie z przedziałem bootstrapowym dla V

Prosty percentylowy bootstrap V może dać dodatnią dolną granicę także przy braku związku w populacji. V jest ograniczone od dołu zerem, a losowe próby zwykle wykazują pewne dodatnie odchylenie od dokładnej niezależności. Taki przedział nie powinien służyć jako automatyczny test „czy V różni się od zera”.

W C07 pokażemy niepewność kierunkowej różnicy proporcji i osobno opisową miarę V . Jeśli oglądamy percentyle bootstrapu V , nazywamy ograniczenie przy granicy parametru. Nie stawiamy diagnozy istotności na podstawie dodatniego końca takiego przedziału.

Cztery pytania do czytania artykułu LIS

Artykuł podaje średni czas dwóch grup, ale nie opisuje powiązań pomiarów. Zanim przeczytasz t , zapytaj, czy to inne osoby, czy dwa zadania tych samych osób. Bez tej informacji nie można ocenić mianownika statystyki.

Drugi artykuł nazywa wynik testu rangowego różnicą średnich. Sprawdź, czy metoda rzeczywiście estymuje średnią oraz jak autor definiuje efekt. Być może liczby są policzone poprawnie, ale język przypisuje im inne pytanie.

Trzeci przedstawia chi-kwadrat i p bez tabeli. Nie możesz z nich odczytać kierunku ani skali różnicy skuteczności. Potrzebujesz liczebności, proporcji i miary efektu w kontekście usługi.

Czwarty pisze, że doświadczenie „wpływa” na skuteczność na podstawie grup obserwacyjnych. Nawet małe p , duży efekt i wąski przedział nie zastępują projektu przyczynowego. Poprawny opis związku jest wartościowy bez dopisywania nieuzasadnionej przyczyny.

Most do C06 i C07

C06 przeprowadzi porównanie dwóch grup z jednym ustalonym kierunkiem efektu, klasycznym Welchem, przedziałami i tasowaniem etykiet. C07 przejdzie od liczebności do proporcji, oczekiwań, testu niezależności i efektu. Każde ćwiczenie zachowa własne mianowniki oraz ograniczenia.

W obu przypadkach pełne zdanie wyniku powinno dać się sprawdzić w tabeli. Nazwa metody nie jest odpowiedzią na problem biblioteki. Odpowiedź wymaga wielkości, niepewności oraz jasnego wskazania, kogo i w jakich warunkach porównano.